

Ética de la Inteligencia Artificial

Principios, retos y oportunidades

Guía de estudio ampliada

Basada en la obra de **Luciano Floridi**

The Ethics of Artificial Intelligence: Principles, Challenges, and Opportunities
(Oxford University Press, 2023 / Herder, ed. española 2024)

Contexto general y tesis del libro

Luciano Floridi, filósofo italiano especializado en filosofía de la información y ética digital, ubica la inteligencia artificial (IA) dentro de un fenómeno mucho más amplio: la **revolución digital**. Para él, no estamos ante una simple actualización tecnológica, sino ante un **parteaguas histórico** comparable con las grandes revoluciones científicas del pasado. Este libro es parte de una tetralogía (junto con *Filosofía de la Información*, *Ética de la Información* y *Lógica de la Información*) y debe leerse en ese marco más amplio.

La **tesis central** del libro es que la IA representa un fenómeno inédito en la historia: por primera vez existen artefactos capaces de **actuar con éxito (agencia) sin necesidad de comprender, pensar o ser inteligentes** en un sentido humano. A esto Floridi lo llama el **divorcio entre agencia e inteligencia**. Un algoritmo puede ganarle al campeón mundial de Go, diagnosticar un cáncer o traducir un idioma sin "saber" nada de lo que está haciendo. Esta separación es filosóficamente novedosa y tiene enormes consecuencias éticas.

Los dos objetivos del libro son:

- **1. Meta-teórico** (Parte I): construir una interpretación filosófica de qué es la IA a partir de su pasado, presente y futuro.
- **2. Normativo-práctico** (Parte II): analizar cómo esta nueva forma de agencia puede usarse ética o no éticamente, y qué principios, riesgos, políticas y prácticas deben acompañarla.

La obra se organiza en **13 capítulos** divididos en dos grandes partes: "*Entendiendo la IA*" (caps. 1–3) y "*Evaluando la IA*" (caps. 4–13). Floridi no pretende un tratado exhaustivo, sino un análisis ético del uso de la IA como herramienta en manos humanas, integrando trabajos académicos previos suyos y de su equipo.

PARTE I — Entendiendo la IA

Capítulo 1 — Pasado: la emergencia de la IA

Floridi reconstruye la génesis del campo desde la conferencia fundacional de Dartmouth (1956), donde John McCarthy acuñó el término "artificial intelligence", pasando por la propuesta contrafáctica de Turing (¿puede una máquina imitar comportamiento inteligente?), los inviernos de la IA y el resurgimiento reciente gracias al **machine learning** y las redes neuronales profundas.

La clave del capítulo es situar la IA dentro de un cambio civilizatorio más amplio: la transición de un **mundo analógico** a un **mundo digital**. Floridi utiliza la analogía **hardware/software**: durante milenios vivimos solo en el "hardware" del mundo físico; hoy vivimos también en una capa de "software" —datos, algoritmos, servicios— que ha dejado de ser accesorio para convertirse en constitutiva de la realidad. En este punto introduce dos conceptos centrales de su filosofía:

- **Infoesfera**: el entorno global de información —agentes, procesos, datos, servicios— dentro del cual vivimos. No es "lo virtual" opuesto a "lo real": la infoesfera **ya es** nuestra realidad.
- **Onlife**: la vida contemporánea en la que la distinción entre "estar en línea" y "estar fuera de línea" ha perdido sentido. Vivimos permanentemente conectados/desconectados en simultáneo. Compramos, trabajamos, amamos y protestamos en un continuo híbrido.

Este capítulo también introduce la idea de la "**cuarta revolución**": después de Copérnico (la Tierra no es el centro del cosmos), Darwin (el ser humano no es el centro del reino biológico) y Freud (la mente consciente no es dueña de sí misma), la revolución de Turing descentra al humano como **único agente inteligente y racional**. Ya no somos los únicos capaces de procesar información con éxito.

Capítulo 2 — Presente: la IA como agencia sin inteligencia

Floridi critica la definición popular de IA como "máquinas que piensan". Para él, esta definición es engañosa y filosóficamente perezosa. Propone entender la IA como una **reserva de agencia**: un conjunto de artefactos capaces de resolver problemas y ejecutar tareas con éxito, pero **sin** consciencia, comprensión, intencionalidad o experiencia. La IA no piensa: ejecuta con eficacia estadística.

El éxito reciente de la IA —desde AlphaGo hasta los modelos de lenguaje— no proviene de haber replicado la mente humana, sino de dos factores muy distintos:

- Enorme disponibilidad de datos y capacidad de cómputo.
- La transformación del mundo para hacerlo **legible** por máquinas. Este proceso Floridi lo llama "**enveloping**" (envolvimiento): en lugar de fabricar robots que caminen por escaleras humanas, fabricamos entornos —almacenes, autopistas, formularios digitales— diseñados para que la IA los recorra sin dificultad. Adaptamos el mundo a la IA, no al revés.

La consecuencia filosófica es fuerte: la inteligencia biológica y la agencia artificial se están separando. Podemos delegar tareas complejas en sistemas que **no entienden** lo que hacen. Esto reconfigura problemas clásicos como la responsabilidad moral, la explicación de las decisiones y la confianza en las instituciones automatizadas.

Capítulo 3 — Futuro: hacia dónde va (y hacia dónde no) la IA

Floridi **rechaza como distracción** los escenarios de **superinteligencia** y **singularidad tecnológica** al estilo Kurzweil, Bostrom o parte del movimiento transhumanista. No niega que

sean escenarios lógicamente posibles, pero sostiene que:

- No hay evidencia científica de que estemos cerca de una IA general consciente.
- Estos debates absorben la atención pública y desvían recursos del análisis de los problemas éticos **reales y presentes**: sesgo algorítmico, vigilancia, concentración de poder, huella ambiental.

El verdadero riesgo no es una IA "demasiado inteligente", sino una **IA tonta pero eficaz** desplegada a escala masiva con supervisión insuficiente. El futuro relevante para la ética es el de una sociedad en la que sistemas automáticos toman millones de microdecisiones sobre nuestras vidas —crédito, empleo, salud, seguridad, información— sin que nadie sepa bien cómo ni por qué.

PARTE II — Evaluando la IA

Capítulo 4 — Un marco unificado de principios éticos

Este capítulo es probablemente el más citado del libro. Floridi (junto con Josh Cowls) revisa más de 40 declaraciones éticas sobre IA publicadas por gobiernos, empresas tecnológicas, organismos internacionales y grupos de expertos (AI4People, la Comisión Europea, la OCDE, IEEE, etc.) y muestra que convergen en un pequeño núcleo común. Toma los **cuatro principios clásicos de la bioética** (Beauchamp y Childress) y añade un **quinto principio específicamente digital**:

- **1. Beneficencia:** la IA debe promover el bienestar humano, la dignidad y la sostenibilidad del planeta. No basta con no dañar: hay que hacer el bien activamente.
- **2. No-maleficencia:** evitar daños. Incluye tanto el **mal uso** (usos criminales, militares, manipulativos) como el **uso excesivo** ("overuse": desplegar IA donde no hace falta y generar riesgos innecesarios). Cubre privacidad, seguridad y prevención del abuso de capacidad militar autónoma.
- **3. Autonomía:** preservar el poder humano de decidir. Introduce el concepto de **meta-autonomía** o "autonomía sobre la autonomía": los humanos deben conservar el derecho de decidir **cuándo** delegar decisiones en la IA y **cuándo** retomar el control. Toda delegación debe ser reversible.
- **4. Justicia:** promover la prosperidad compartida, preservar la solidaridad, evitar la discriminación y la creación de nuevas desigualdades. Incluye la lucha contra el sesgo algorítmico y la protección de los grupos vulnerables.
- **5. Explicabilidad** (aporte propio de Floridi): principio novedoso que combina dos exigencias: **inteligibilidad** epistemológica (¿cómo funciona esta IA? ¿cómo llegó a esta decisión?) y **rendición de cuentas** ética y jurídica (¿quién es responsable de lo que hace?). Sin explicabilidad, los otros cuatro principios se vuelven inaplicables: no podemos verificar beneficencia, prevenir daños, respetar autonomía ni exigir justicia si no entendemos cómo decide el sistema y quién responde por él.

Capítulo 5 — Los cinco riesgos del "ser no ético"

Floridi advierte que tener buenos principios en papel no basta. Existen **cinco patologías** típicas de la ética aplicada a la IA que socavan su implementación real:

- **Ethics shopping:** "comprar" a la carta los principios éticos más convenientes para la propia empresa o gobierno, ignorando los que resultan incómodos. Genera una ética "a medida" que no compromete a nada.
- **Ethics bluewashing:** hacer marketing ético sin sustancia real. Equivalente digital del *greenwashing*: publicar principios sin cambiar prácticas. "Nuestra IA es ética" impreso en el sitio web mientras nada cambia dentro.
- **Ethics lobbying:** usar el discurso ético como **excusa para retrasar o evitar regulación** necesaria. "No necesitamos leyes, ya somos éticos." La ética se instrumentaliza para bloquear la ley.
- **Ethics dumping:** exportar prácticas no éticas a jurisdicciones con estándares laxos. Se hace investigación o despliegue en países donde la regulación es débil y luego se importa el producto "limpio".

- **Ethics shirking:** reducir el esfuerzo ético en proporción inversa a la recompensa percibida. Cuando "portarse bien" no se premia y "portarse mal" no se castiga, la ética se abandona por costo-beneficio.

Capítulo 6 — Ética dura, ética blanda y gobernanza digital

Distingue con precisión tres niveles complementarios:

- **Hard ethics (ética dura):** la que **configura y da forma a la ley**. Debate sobre qué debería ser legal o ilegal. Interviene antes de la norma.
- **Soft ethics (ética blanda) o "post-compliance ethics":** la que actúa **por encima y más allá** del cumplimiento legal. Empieza donde la ley termina: *¿qué debemos hacer aunque no estemos obligados?* Es el terreno voluntario del "buen actor" ético. En regiones con marcos regulatorios fuertes (como la UE), la soft ethics tiene sentido porque hay un piso legal robusto sobre el cual construir. En regiones sin ese piso, es peligrosa porque puede usarse como sustituto de la ley faltante.
- **Gobernanza digital:** el conjunto de prácticas, procedimientos e instituciones que orquestan cómo se desarrolla, despliega y usa la tecnología. Se distingue de la *regulación* (leyes) y de la *ética digital* (valores). Los tres niveles son complementarios: sin gobernanza, la regulación no se implementa y la ética se queda en discurso.

Capítulo 7 — Desafíos éticos del desarrollo y uso de la IA

Catálogo de los principales problemas concretos generados por el despliegue de IA:

- **Sesgo algorítmico:** los sistemas aprenden de datos históricos que reflejan desigualdades pasadas y las reproducen o amplifican (racismo en reconocimiento facial, sexismo en selección de personal, clasismo en scoring crediticio).
- **Opacidad y "cajas negras":** muchos sistemas de deep learning son intrínsecamente opacos; ni sus propios diseñadores pueden explicar decisiones específicas. Esto choca con el principio de explicabilidad.
- **Privacidad y autodeterminación informacional:** la IA se alimenta de datos personales masivos. Erosiona el control del individuo sobre su propia información y perfila comportamientos con precisión inédita.
- **Impacto en el empleo:** automatización de tareas cognitivas rutinarias, polarización del mercado laboral, precarización de plataformas digitales, reconfiguración de sectores enteros.
- **Manipulación del comportamiento:** desde el *nudge* algorítmico en redes sociales hasta la microsegmentación política. Erosión de la deliberación democrática.
- **Responsabilidad distribuida ("problem of many hands"):** cuando un sistema falla, la culpa se reparte entre tantos actores (desarrolladores, empresa, usuario, regulador) que nadie responde. Se genera una **brecha de responsabilidad** ("responsibility gap") difícil de cerrar.

Capítulo 8 — Usos malignos de la IA

Aquí Floridi analiza el uso **deliberado** de la IA para el mal, distinguiéndolo de los daños no intencionales del capítulo anterior:

- **Ciberdelito potenciado por IA:** phishing personalizado, ingeniería social automatizada, ataques adaptativos a infraestructuras críticas.

- **Desinformación y deepfakes:** generación masiva de contenido falso creíble (imágenes, audio, video, texto), con impacto electoral, reputacional y social. Erosión del "terreno común" epistémico.
- **Armas autónomas letales (LAWS):** sistemas que seleccionan y atacan objetivos sin intervención humana. Plantean problemas de derecho internacional humanitario, atribución de responsabilidad y escalamiento sin control humano en el circuito.
- **Vigilancia masiva y capitalismo de datos:** despliegue de reconocimiento facial, análisis predictivo y scoring social por parte de Estados y corporaciones, con impacto sobre libertades civiles.

En este capítulo introduce distinciones jurídico-morales relevantes, como la del **actus reus** (el acto material del delito), para pensar cómo atribuir responsabilidad cuando el agente ejecutor no es una persona sino un sistema.

Capítulo 9 — Buenas prácticas al aplicar la IA

Traduce los principios abstractos del capítulo 4 en **recomendaciones operativas** para organizaciones que desarrollan o despliegan IA:

- **Auditorías algorítmicas** internas y externas, periódicas y con acceso real a los sistemas.
- **Evaluaciones de impacto ético** previas al despliegue, análogas a los estudios de impacto ambiental.
- **Mecanismos de recurso** para que las personas afectadas por decisiones automatizadas puedan pedir explicación, revisión humana o corrección.
- **Transparencia por diseño:** incorporar la explicabilidad desde la arquitectura del sistema, no como parche posterior.
- **Participación de stakeholders:** incluir a los afectados en el diseño, no solo a ingenieros.

Introduce el concepto de "**dual advantage**" (doble ventaja): una IA bien diseñada éticamente beneficia **simultáneamente** a la organización que la despliega (menor riesgo reputacional, legal y operativo) y a la sociedad (menores daños, mayor confianza). La ética no es un costo: es una ventaja competitiva sostenible.

Capítulo 10 — IA para el Bien Social (AI4SG)

Uno de los capítulos más influyentes y citados. Floridi, con Cowls, King y Taddeo, propone una definición operativa de **AI for Social Good** y enumera **siete factores esenciales** que un proyecto de IA debería cumplir para ser considerado socialmente benéfico:

- **1. Falsabilidad y despliegue incremental:** el sistema debe ser probable de falsar (poder saber cuándo se equivoca) y desplegarse por etapas, no todo de una vez.
- **2. Salvaguardas contra la manipulación de predictores:** proteger al sistema de que sus variables sean manipuladas por actores interesados ("gaming the system").
- **3. Intervención contextualizada que respete la autonomía del receptor:** la IA no debe imponer conductas: debe informar y facilitar, dejando la decisión al usuario.
- **4. Explicación contextualizada de los propósitos del receptor:** la explicabilidad debe adaptarse a quién recibe la explicación (un médico, un juez, un ciudadano común).
- **5. Protección de la privacidad y consentimiento del sujeto de datos:** respeto estricto de la privacidad, con mecanismos reales de consentimiento (no simples casillas).

- **6. Equidad situacional ("context-aware fairness"):** la noción de justicia debe adaptarse al contexto de aplicación; no hay una definición universal de "fair" que sirva para todo.
- **7. Semantización amigable de los datos:** los datos deben etiquetarse y estructurarse de modo que su significado sea claro, actualizable y utilizable por diversos actores.

Capítulo 11 — IA y medio ambiente: el doble filo ecológico

Floridi es enfático: la IA tiene un **doble impacto ambiental**, y hay que verlo completo.

- **Impacto negativo:** entrenar y operar modelos grandes consume enormes cantidades de electricidad, agua para refrigeración de data centers, y minerales como litio, cobalto y tierras raras (con impactos geopolíticos y de derechos humanos en la extracción). La huella de carbono de un solo modelo puntero puede equivaler a cientos de vuelos transatlánticos.
- **Impacto positivo:** la IA es también una herramienta poderosa contra la crisis ambiental. Permite modelado climático más preciso, optimización energética de redes eléctricas, agricultura de precisión (menos agua, menos fertilizantes), monitoreo de biodiversidad, detección temprana de incendios, eficiencia logística que reduce emisiones.

El principio ético que propone es que los **costos y riesgos ambientales deben ser evitados o minimizados** cuando es posible, y compensados con beneficios netos verificables cuando no. La pregunta no es "¿IA sí o no?" sino "**¿esta IA, para este fin, con este costo, vale la pena?**".

Capítulo 12 — IA y los Objetivos de Desarrollo Sostenible (ODS)

Floridi mapea sistemáticamente cómo la IA puede apoyar (o socavar) los **17 ODS de la ONU (Agenda 2030)**:

- **Impactos claramente positivos** (con buen diseño): salud y bienestar (diagnóstico precoz, epidemiología), educación de calidad (personalización del aprendizaje), energía asequible y no contaminante (redes inteligentes), ciudades sostenibles (movilidad, gestión de residuos), acción climática.
- **Impactos ambivalentes o potencialmente negativos:** trabajo decente (automatización sin transición justa), reducción de desigualdades (la IA puede ampliar la brecha digital global), instituciones sólidas (vigilancia estatal, manipulación electoral).

El mensaje central: **la IA no es automáticamente aliada del desarrollo sostenible**; lo es solo si se diseña y gobierna con esa intención explícita.

Capítulo 13 — El matrimonio del Verde y el Azul (Green & Blue)

El capítulo final es programático y da nombre a lo que Floridi propone como agenda del siglo XXI: un **"nuevo matrimonio"** entre dos proyectos que suelen pensarse por separado:

- **Green:** todos nuestros hábitats naturales, urbanos y sociales. La sostenibilidad ambiental, la biodiversidad, el clima, la vida humana digna.
- **Blue:** todas nuestras tecnologías digitales. Datos, algoritmos, infraestructura de red, inteligencia artificial.

La tesis final es que la **ética de la IA solo tiene sentido pleno si integra ambos proyectos**: no puede haber una infoesfera saludable en una biosfera enferma, ni una biosfera saludable sin una infoesfera bien gobernada. Es un llamado a un **humanismo digital** que ponga las tecnologías al servicio simultáneo de la humanidad y del planeta. Este es el horizonte normativo del libro entero: no una IA "buena" en abstracto, sino una IA al servicio de una sociedad mejor y una biosfera más

sana.

Glosario de conceptos clave

Estos son los conceptos que suelen aparecer en preguntas de examen o de trabajo final sobre esta obra. Conviene fijarlos con precisión.

Infoesfera: Entorno global de información en el que vivimos: personas, agentes artificiales, procesos y datos. No es un "mundo virtual" opuesto al real; es la textura informacional de la realidad contemporánea.

Onlife: Condición existencial en que la distinción entre "en línea" y "fuera de línea" ha perdido sentido. Vivimos permanentemente en un continuo híbrido físico-digital.

Cuarta revolución: Tras Copérnico, Darwin y Freud, la revolución de Turing descentra al humano como único agente inteligente y racional. No somos ya los únicos capaces de procesar información con éxito.

Divorcio agencia-inteligencia: Tesis metafísica central del libro: la IA muestra que la agencia exitosa puede darse sin inteligencia, consciencia o comprensión. Un sistema puede actuar con éxito sin "saber" lo que hace.

Enveloping: Estrategia por la cual adaptamos el mundo para que la IA lo pueda recorrer con éxito, en lugar de construir IA que se adapte al mundo humano. Almacenes robotizados, formularios digitales, etc.

Cinco principios éticos: Beneficencia, no-maleficencia, autonomía, justicia y explicabilidad. Los cuatro primeros vienen de la bioética; el quinto es el aporte propio de la ética digital.

Explicabilidad: Principio compuesto por inteligibilidad (¿cómo funciona?) y accountability (¿quién responde?). Es condición de posibilidad de los otros cuatro principios.

Meta-autonomía: "Autonomía sobre la autonomía": el derecho humano de decidir cuándo delegar decisiones en la IA y cuándo retomar el control. Toda delegación debe ser reversible.

Hard ethics: Ética que interviene antes de la ley: debate sobre qué debe ser legal o ilegal.

Soft ethics: Ética "post-compliance": la que actúa por encima y más allá del cumplimiento legal. Pregunta qué debemos hacer aunque no estemos obligados.

Gobernanza digital: Conjunto de prácticas, procedimientos e instituciones que orquestan cómo se desarrolla y despliega la tecnología. Complementaria a la regulación y a la ética.

Ethics shopping: Elegir a la carta los principios éticos convenientes, ignorando los incómodos.

Ethics bluwashing: Marketing ético sin sustancia. Equivalente digital del greenwashing.

Ethics lobbying: Usar el discurso ético como excusa para evitar o retrasar regulación necesaria.

Ethics dumping: Exportar prácticas no éticas a jurisdicciones con estándares laxos.

Ethics shirking: Reducir el esfuerzo ético cuando no hay recompensa percibida por hacerlo bien.

AI4SG (AI for Social Good): IA orientada al bien social, definida operativamente por siete factores esenciales (falsabilidad, salvaguardas anti-manipulación, intervención contextualizada, explicación contextualizada, privacidad, equidad situacional y semantización amigable de datos).

Dual advantage: Idea de que una IA bien diseñada éticamente beneficia simultáneamente a la organización y a la sociedad. La ética como ventaja competitiva.

Responsibility gap: Brecha de responsabilidad: cuando un sistema autónomo causa daño, la responsabilidad se diluye entre tantos actores que nadie responde plenamente.

Green & Blue: Síntesis final del libro: matrimonio necesario entre sostenibilidad ambiental (Green) y tecnologías digitales (Blue). Horizonte normativo de la obra.

Ideas fuerza para el examen

Si tenés que llevarte pocas ideas de este libro, que sean éstas:

1. La IA no es "máquinas que piensan": es **agencia sin inteligencia**. Todo el análisis ético parte de allí.
2. El marco ético fundamental son los **cinco principios**: beneficencia, no-maleficencia, autonomía, justicia y **explicabilidad** (memorizá este quinto: es lo distintivo de Floridi).
3. Tener principios no basta: hay **cinco patologías de la ética aplicada** (shopping, bluewashing, lobbying, dumping, shirking) que hay que reconocer y combatir.
4. La ética digital tiene **tres niveles**: hard ethics (configura la ley), soft ethics (post-cumplimiento) y gobernanza digital (prácticas e instituciones).
5. La IA para el Bien Social (**AI4SG**) tiene **siete factores** operativos concretos.
6. El horizonte final del libro es el **matrimonio Green & Blue**: sostenibilidad ambiental + tecnología digital, al servicio de una sociedad mejor y un planeta más sano.

Guía elaborada como material de estudio. Para citas académicas, remitirse siempre al texto original de Floridi.