

LIC. EN INTELIGENCIA ARTIFICIAL · PRIMER CUATRIMESTRE

Clase magistral de Ética en Inteligencia Artificial

Un recorrido completo por los cinco módulos de la materia, explicado desde cero. Si nunca estudiaron ética ni regulación, este es el lugar para empezar.

Bibliografía base: Floridi (2019) 5 módulos · 15 semanas Código 0104 · EIA

Buenos días a todos y todas. Antes de arrancar, quiero sacarles un miedo: **no necesitan saber filosofía para esta materia**. Vamos a construir cada concepto desde el piso, con ejemplos cotidianos. Les voy a pedir una sola cosa: que cada vez que aparezca una palabra nueva, se detengan y la entiendan antes de seguir, porque en ética las palabras son herramientas de trabajo.

Cuando la gente escucha "ética en IA" se imagina robots asesinos o máquinas con conciencia. Nosotros vamos a hacer lo contrario: **bajar a tierra**. Para un profesional de la IA, la ética no es una charla de café. Es un **requisito de ingeniería**, tan importante como que el sistema sea eficiente o escalable (que pueda crecer para atender a millones de usuarios sin romperse).

EL HILO CONDUCTOR DE TODA LA MATERIA

Las máquinas actúan, pero no entienden. Por eso **la responsabilidad siempre es humana**. Todo lo que veamos, desde los principios hasta las leyes, sirve para que esa responsabilidad humana se ejerza bien.

MÓDULO 0

La materia por dentro

Empecemos por entender el "contrato" de la materia: para qué existe, qué se espera de ustedes y cómo se evalúa.

Propósito

La materia busca que ustedes comprendan los **principios, desafíos y marcos regulatorios** (conjuntos de leyes y normas) que organizan el desarrollo y uso responsable de la IA en el siglo XXI. La ética aparece como un pilar para garantizar tres cosas en la innovación: **equidad, inclusión y respeto de los derechos humanos**. Se trabaja con casos reales, riesgos, dilemas, impacto social y respuestas normativas, con atención especial a los modelos globales y a la mirada de **América Latina**.

Objetivos y resultados de aprendizaje

Los objetivos y los cinco Resultados de Aprendizaje (RA) dicen lo mismo con distinto verbo. Al terminar, ustedes deberían poder:

RA	QUÉ VAN A PODER HACER	MÓDULO DONDE SE TRABAJA
RA1	Evaluar críticamente los fundamentos éticos de la IA y su impacto en tecnologías responsables y alineadas con valores humanos.	1
RA2	Identificar y aplicar los principios de equidad, justicia, transparencia, responsabilidad, privacidad y no maleficencia en el diseño de sistemas confiables.	2
RA3	Implementar estrategias y herramientas para detectar y mitigar sesgos algorítmicos.	3
RA4	Comparar marcos regulatorios de Europa, Estados Unidos, Asia y América Latina, e interpretar desafíos de adaptación en la región.	5
RA5	Evaluar el impacto de la IA en la sociedad, el empleo y la equidad social con mirada crítica.	4

Competencias de egreso

Una **competencia** es una capacidad profesional que la carrera se compromete a formar. Cada materia "aporta" a algunas con nivel ninguno, bajo, medio o alto. Esta materia aporta así:

Sociales, políticas y

Genéricas tecnológicas (CG)

actitudinales (CSPA)

Alto: desempeño en equipos (CSPA6), acción ética y responsable (CSPA8), evaluación del impacto social en el contexto global y local (CSPA9), aprendizaje continuo (CSPA10).

Medio: comunicación efectiva (CSPA7). **Bajo:** acción emprendedora (CSPA11).

Medio: resolver problemas complejos con ciencia de datos e IA (CG1); gestionar proyectos de IA con trazabilidad (CG3).

Bajo: diseñar proyectos con principios éticos (CG2), usar herramientas especializadas (CG4), generar innovaciones (CG5).

Específicas (CE)

Medio: desarrollo de modelos considerando requisitos éticos (CE 1.1), seguridad de datos (CE 2.1), métricas de calidad (CE 3.1), certificación, riesgos y auditoría (CE 4.1), dirección y mantenimiento de soluciones (CE 5.1).

Bajo: infraestructura de datos (CE 1.2), software de modelos (CE 1.3).

Además, el programa cruza cada RA con cada competencia. Por ejemplo, RA3 (mitigar sesgos) aporta nivel **alto** a casi todas las competencias tecnológicas, porque es la parte más "manos en el código" de la materia. Las competencias específicas siguen la Resolución ME 1254/2018 y los Estándares RedUNCI (2018).

Datos administrativos

- **Correlatividades:** ninguna. No necesita una materia previa ni habilita a una posterior. Primer cuatrimestre, 4 horas semanales, 45 horas totales.
- **Contenidos mínimos:** fundamentos éticos en tecnología (principios, privacidad y datos); sesgos en IA (detección y mitigación); impacto social (sociedad, economía, empleo); regulación y políticas (legislación global, normas éticas).
- **Bibliografía obligatoria:** Floridi, L. (2019). *Ética de la Inteligencia Artificial*.

Madrid: Alianza. La complementaria incluye a UNESCO (2021), OCDE (2019), Danesi (2021 y 2022), Corvalán / IALAB (2023), Jobin, Ienca y Vayena (2019), Bostrom (2014), Eticas Foundation (2023), Algorithm Audit (2024), Fabris et al. (2023), la Comisión Europea (AI Act y ECAT), Balmaceda et al. (2019, *Caja de herramientas humanistas*), Tuomi / JRC / INTEF (2025) y Naciones Unidas (2024).

Planificación: cuánto pesa cada módulo

M1 · 25%

M2 · 25%

M3 · 20%

M4

M5 · 20%

Repartido en 15 semanas, aproximadamente: Módulo 1 en las semanas 1 a 4, Módulo 2 de la 5 a la 8, Módulo 3 de la 9 a la 11, Módulo 4 en la 12 y Módulo 5 de la 13 a la 15. La **primera parte de la Evaluación Integradora** se hace al terminar el Módulo 3; la **segunda parte**, al terminar el Módulo 5.

Metodología

La materia se dicta a distancia, según el Sistema Institucional de Educación a Distancia (SIED) de la Universidad Blas Pascal (Res. MECCYT N.º 197/2019).

Cuentan con:

- Contenidos y actividades en la plataforma **miUBP**, bibliografía seleccionada, clases en video asincrónicas (las ven cuando quieren) y tutorías virtuales.
- Actividades **optativas y obligatorias**: unas para apropiarse de los conceptos teóricos y otras para transferirlos a la práctica (casos, reflexión, dilemas).
- **Agrupamiento** principalmente individual, aunque pueden juntarse libremente para estudiar.
- **Interacción** por foros, mensajería interna y tutorías.
- **Formación práctica** centrada en resolver problemas éticos y regulatorios en situaciones reales o simuladas: aplicar criterios, analizar riesgos y proponer gobernanza.

Evaluación

Escala de 1 a 100; se aprueba con **50**. Para ser **alumno regular** hay que aprobar la Evaluación Integradora en los plazos del cursado (si no se aprueba, se puede reelaborar). El **examen final** es escrito, presencial e integrador. El material también incluye códigos QR que llevan a videos del docente.

MÓDULO 1 · 25% DE LA MATERIA

Fundamentos ontológicos y técnicos de la ética en IA

Primera palabra difícil: **ontología**. En filosofía, la ontología estudia "qué es" algo. Aplicada a la IA, significa analizar su **naturaleza técnica**: qué es, cómo está compuesta y cuáles son sus capacidades y límites. ¿Por qué empezamos por acá? Porque no se puede juzgar éticamente algo que no se entiende. Si creemos que la IA "piensa", vamos a culparla a ella; si entendemos lo que realmente es, vamos a buscar a los responsables correctos.

Al terminar este módulo van a poder distinguir agencia de inteligencia, analizar cómo el diseño, los datos y el entorno condicionan el comportamiento de un sistema, reconocer la responsabilidad distribuida a lo largo del ciclo de vida, y aplicar el método de análisis ético de Floridi a casos simples.

1. El contexto: la Cuarta Revolución

Luciano Floridi, el filósofo italiano que es nuestra bibliografía base, dice que no estamos viviendo solo una mejora tecnológica, sino un **cambio en cómo nos entendemos a nosotros mismos**. Lo llama la **Cuarta Revolución**. Para entenderla, miremos las tres anteriores, cada una de las cuales nos sacó de un "centro" en el que nos creíamos:

REVOLUCIÓN	QUÉ NOS QUITÓ
1. Copérnico	La Tierra no es el centro del universo.
2. Darwin	El ser humano no es una creación aparte: es parte del reino animal.
3. Freud	Ni siquiera dominamos del todo nuestra propia mente: existe el inconsciente.
4. Turing	Ya no somos los únicos capaces de procesar información para actuar con éxito.

Alan Turing, pionero de la computación, nos **desplazó del centro del mundo de la información**. Hoy compartimos la **Infosfera** (el entorno informacional global: todos los datos y las interacciones con ellos) con **agentes artificiales**.

De ahí surge otro concepto: la experiencia **"Onlife"** (online + life). Ya no hay una frontera clara entre estar conectado y desconectado. Vivimos en una realidad híbrida donde los algoritmos toman decisiones que afectan el mundo físico al instante. Ejemplo: una app de tránsito que redirige autos reales por otras calles. El algoritmo es digital, pero el embotellamiento en tu barrio es muy físico.

2. Naturaleza técnica: el **"divorcio"** entre **agencia e inteligencia**

Este es probablemente **el concepto más importante de toda la materia**. Durante siglos creímos que para hacer algo complejo, como jugar al ajedrez o traducir un texto, hacía falta ser inteligente. La IA moderna demuestra que eso es falso.

Floridi dice que la IA tiene éxito no porque imite al cerebro humano, sino porque logramos **divorciar la agencia de la inteligencia**. Definamos ambas:

Agencia

Capacidad de interactuar con el entorno y **lograr un objetivo con éxito**. Se mide por la efectividad: ¿cumplió la tarea? Ejemplo: clasificar correctamente una radiografía.

Inteligencia

Implica ser consciente, semántico (entender significados) o biológico. Son procesos cognitivos que permiten **comprender e interpretar** el mundo con sentido. No es solo hacer, sino entender qué se hace y por qué.

EJEMPLO DEL LAVAVAJILLAS

Un lavavajillas lava los platos perfectamente: eso es **agencia**. Pero no sabe qué es la suciedad, no se aburre, no piensa "qué asco". No tiene **inteligencia**. La IA es lo mismo, pero muchísimo más sofisticada: **agencia sin inteligencia biológica**.

Floridi dice que ustedes, como ingenieros, están construyendo una reserva de **agencia inteligente "on tap"**, es decir, a demanda, como el agua de la canilla: se abre cuando se necesita. Sus sistemas hacen cosas, pero no piensan ni comprenden significados.

CONSECUENCIA ÉTICA

Si la IA tiene agencia pero **carece de conciencia moral**, no se le puede atribuir culpa. La responsabilidad por sus acciones recae **íntegramente en el diseño humano**.

3. Ingeniería del entorno: enveloping y datos

Si la IA es "estúpida" en el sentido de que no comprende nada, ¿por qué parece tan inteligente? Por dos estrategias que aplican los ingenieros.

A. Enveloping (envoltura)

Floridi argumenta que **no adaptamos la IA al mundo, sino el mundo a la IA**. El enveloping es el proceso de modificar el entorno para que la IA pueda operar con éxito dentro de sus capacidades limitadas. Es como "envolver" a la máquina en un mundo a su medida.

- **Ejemplo industrial:** los robots de fábrica trabajan dentro de "jaulas" donde todo está medido y en su lugar.
- **Ejemplo cotidiano:** la casa inteligente. Compramos una aspiradora robot y, para que funcione, levantamos las sillas y escondemos los cables. Somos **nosotros** los que nos adaptamos para que la máquina no falle.

POR QUÉ IMPORTA ÉTICAMENTE

Si cada vez adaptamos más el mundo, y a las personas, a lo que la máquina necesita, corremos el riesgo de que sean los humanos los que terminen "funcionando" para el algoritmo y no al revés.

B. La materia prima: datos históricos vs. sintéticos

La segunda estrategia son los **datos masivos**. Y acá la ética se juega en **qué tipo de datos** alimentan la agencia:

Datos históricos

Recolectados del mundo real.

Arrastran los sesgos y prejuicios

Datos sintéticos

Generados por la propia IA.

Ejemplo: AlphaZero aprendió

humanos (racismo, sexismo, etc.) y además tienen riesgos de privacidad, porque vienen de personas reales.

ajedrez sin partidas históricas, solo jugando contra sí mismo. Son más "limpios" y seguros: no vienen de individuos, reducen el riesgo de filtraciones y permiten entrenar más allá de la experiencia humana (millones de partidas sin explotar a jugadores humanos).

4. El ciclo de la responsabilidad ética (responsabilidad distribuida)

La ética no es un sello que se pone al final, como un control de calidad. Es un proceso cíclico y sistemático. Y como en una IA intervienen muchas personas, la responsabilidad está distribuida en tres niveles:

NIVEL	ACTORES	DECISIONES CLAVE	RIESGOS	CASO REAL
1. Diseño (pre-desarrollo) Se define el "ADN" del sistema	Desarrolladores, científicos de datos, Product Owners	¿Qué datos usamos? ¿Qué función objetivo optimizamos? ¿"Tiempo en pantalla" o "bienestar del usuario"?	Sesgos en el set de entrenamiento	Arte y creatividad: IA generativa que gana premios sin "entender" el arte. ¿Es ético entrenar con obras de artistas sin su permiso?
2. Implementación (uso y despliegue) Acá ocurre el enveloping	Empresas, usuarios profesionales (médicos, jueces), usuarios finales	¿Quién supervisa? (human-in-the-loop). ¿Se usa para asistir o para vigilar?	Vigilancia desmedida, pérdida de privacidad	Vigilancia laboral: algoritmos que miden cada micro-movimiento de los empleados
3. Impacto (post-desarrollo) Consecuencias de largo plazo	Sociedad civil, reguladores, comunidades afectadas	Cómo responde la sociedad a los efectos	Exclusión de minorías, impacto ambiental de "la nube"	Data centers que consumen agua y energía masiva (Querétaro, México); sistemas que

excluyen a
personas con
discapacidad
(Amnistía
Internacional)

Dos aclaraciones. La **función objetivo** es lo que el sistema intenta maximizar o minimizar; elegirla es una decisión ética disfrazada de técnica. Y **human-in-the-loop** significa "humano en el circuito": una persona que revisa o aprueba lo que la máquina propone. Por último, "la nube" suena etérea, pero **la IA no es etérea**: vive en edificios llenos de servidores que gastan agua y electricidad.

5. Metodología de análisis ético (basada en Floridi)

Para resolver los dilemas de la materia vamos a usar siempre este método de cuatro pasos. Apréndanlo bien, porque lo van a usar en todas las actividades:

1

Identificar el fallo

¿Es de datos (sesgo), de diseño (agencia mal dirigida) o de entorno (enveloping forzado)?

2

Rastrear la agencia

¿Quién diseñó y quién implementó? La IA no es responsable; los humanos sí.

3

Evaluar la entropía

¿La solución destruye información y bienestar, o los construye?

4

Proponer solución

¿Se arregla con mejor código, mejores datos o mejor regulación?

QUÉ ES "ENTROPÍA" ACÁ

En física, la entropía mide el desorden. Floridi usa la palabra para hablar de la **degradación de la infosfera**: una acción que empobrece la información o daña el bienestar aumenta la entropía; una que los mejora la reduce.

Glosario del Módulo 1

Agente moral artificial (AMA)	Sistema capaz de generar consecuencias éticas (aunque no sea responsable de ellas).
Agencia vs. inteligencia	Actuar con éxito (agencia) frente a comprender lo que se hace (inteligencia).
Datos sintéticos	Datos generados artificialmente para entrenar modelos, evitando los problemas de privacidad de los datos históricos.
Enveloping	Adaptar el entorno físico o digital a las limitaciones de la IA para que funcione.
Ética de la información	Teoría que estudia el valor moral de la información.
Ética por diseño	Integrar valores éticos en el desarrollo tecnológico.
Moralidad por diseño	Idea de que los sistemas deben construirse con criterios éticos incorporados desde el inicio.
Infosfera	Entorno informacional global de datos e interacciones, donde vivimos "onlife".
Responsabilidad distribuida	Asignación de responsabilidad ética a la red de actores humanos que diseñan, despliegan y usan la IA.

Actividades del Módulo 1

- **Actividad 1, del caso a la reflexión ética:** buscar una noticia verificable de IA en salud, justicia, empleo, educación, consumo o seguridad, y responder en 10 a 12 líneas: dónde está el divorcio agencia/inteligencia, qué enveloping hay, si el problema principal surge de los datos, el diseño o el entorno, y qué actor humano es responsable y qué podría hacer distinto. Indicar la fuente.
- **Actividad 2, interrogantes:** en el foro, una app de IA con dilemas éticos y qué valores deberían guiar su diseño; comentar al menos una publicación de un compañero.
- **Actividad 3, mapa ético cotidiano:** elegir una app (chatbot, recomendador, reconocimiento facial), describirla, identificar valores en juego, aplicar el método de Floridi y proponer una mejora. Informe de 1 a 2 páginas.

Para autoevaluarse

- ▶ ¿Por qué no se puede culpar a un algoritmo?
- ▶ Den un ejemplo propio de enveloping.
- ▶ ¿En qué nivel del ciclo se elige la función objetivo?

MÓDULO 2 · 25% DE LA MATERIA

Principios éticos y dilemas en la IA

En el Módulo 1 entendimos que la IA es agencia sin inteligencia. Ahora damos un paso más: **¿qué principios deben orientar a toda IA?** y **¿cómo se aplican en dilemas donde no hay una única respuesta correcta?**

Al terminar este módulo van a poder identificar los cinco principios, analizar dilemas reales, evaluar tensiones entre valores (eficiencia–equidad, autonomía–explicabilidad) y aplicar herramientas prácticas como auditorías y evaluaciones de impacto.

¿De dónde salen estos principios? De la **bioética clásica**, la ética de la medicina, que tiene cuatro: beneficencia, no maleficencia, justicia y autonomía. Floridi los reinterpreta desde la ética de la información y **suma un quinto principio** pensado para la ingeniería: la **explicabilidad**. La UNESCO (2021) y la OCDE (2019) los retoman y promueven transparencia, rendición de cuentas, equidad y derechos humanos en todo el ciclo de vida de la IA.

LA BRÚJULA MORAL DEL INGENIERO

Los principios **no son reglas rígidas**, son brújulas: orientan para equilibrar valores en conflicto. La ética aplicada no responde con "sí" o "no", sino con **razones**: analiza contextos, actores, consecuencias y valores para construir decisiones justificables.

Los 5 principios fundamentales (el marco unificado)

1. Beneficencia: "hacer el bien" (*Do Good*)

Toda IA debe buscar un **impacto positivo**. No alcanza con que sea eficiente: tiene que demostrar un **beneficio social** (*AI for Social Good*), promoviendo el bienestar humano y la sostenibilidad del planeta.

Ejemplo: una IA que optimiza el consumo de energía de un data center reduce la huella de carbono. El material cita un sistema que reduce casi un 50% las emisiones de centros de datos.

2. No maleficencia: "no dañar" (*Do no Harm*)

Obliga a **evitar daños previsibles**, intencionales o accidentales. Incluye gestión de riesgos, seguridad informática y prevención del **uso dual**: que una IA legítima se use para el mal (un modelo que diseña medicamentos podría usarse para diseñar venenos).

Dilema en salud: un sistema de diagnóstico es benéfico porque detecta enfermedades, pero maléfico si filtra datos de pacientes. El equilibrio está en **validar, auditar y proteger**.

DIFERENCIA SUTIL

Beneficencia y no maleficencia no son lo mismo. Uno puede no dañar a nadie y aun así no hacer ningún bien. Son dos exigencias distintas: sumar lo bueno y evitar lo malo.

3. Autonomía: la meta-autonomía

Es el derecho de las personas a **comprender y decidir** sobre lo que las afecta. En IA, el humano debe conservar la **meta-autonomía**: la capacidad de decidir **cuándo cederle el control a la máquina y cuándo recuperarlo** ("decidir delegar").

ANALOGÍA

Poner el piloto automático en un avión es un acto de autonomía, siempre que el piloto pueda retomar los mandos cuando quiera. El problema no es delegar, sino delegar sin poder volver atrás o sin saber qué se delegó.

Ejemplo educativo: una plataforma que recomienda cursos ayuda, pero si no

explica por qué te ofrece cierto nivel, vulnera tu autonomía. La ética exige transparencia sobre criterios y límites.

4. Justicia (*Fairness*)

Busca **distribuir beneficios y cargas de manera equitativa**. Una IA justa no discrimina ni amplía brechas; al contrario, corrige desigualdades eliminando sesgos en los datos de entrenamiento. La **equidad algorítmica** aplica **métricas matemáticas** que verifican si las decisiones afectan por igual a distintos grupos (género, edad, región).

5. Explicabilidad: el nuevo principio

Es la **clave de bóveda**: la piedra central de un arco que sostiene a todas las demás. Combina dos conceptos:

Inteligibilidad (epistémica)

Poder **comprender cómo funciona** el modelo. "Epistémico" quiere decir que se refiere al conocimiento. Sin inteligibilidad no podemos auditar ni corregir errores. Es la diferencia entre **caja blanca** (se ve por dentro) y **caja negra** (solo se ven entradas y salidas).

Accountability (ética)

Poder responder "**¿quién es responsable?**". Si hay un fallo, tiene que existir una cadena clara de responsabilidad humana que podamos rastrear. En castellano se traduce como "rendición de cuentas".

PARA RECORDAR

La explicabilidad une el **saber** (inteligibilidad) con el **deber** (accountability). Entender cómo funciona el sistema es lo que permite asignar responsabilidades.


Caso central: IA en selección de personal

Una empresa usa IA para analizar currículums. El modelo aprende de decisiones históricas y descubre un patrón: **prefiere varones jóvenes de ciertas universidades**, porque en el pasado eran los más contratados. Es eficiente, pero no equitativo.

Dilemas presentes:

- **Beneficencia vs. justicia:** maximizar productividad frente a asegurar igualdad de oportunidades.
- **Autonomía vs. explicabilidad:** los postulantes no entienden por qué fueron descartados, porque el modelo es una caja negra (modelos complejos cuyo razonamiento interno es opaco).

Análisis paso a paso:



De la teoría a la práctica: la operacionalización

Definir valores es la parte "fácil". El desafío real es **operacionalizarlos**: convertir un principio abstracto, como "justicia", en **métricas de código, protocolos de prueba y restricciones de diseño verificables**.

Floridi (2019) habla del paso de la "**Hard Ethics**", que el material asocia al cumplimiento legal básico, a la "**Soft Ethics**", la gobernanza proactiva: ir más allá de lo que la ley obliga. Para eso no alcanza la buena voluntad; se usan instrumentos técnicos a lo largo del **SDLC** (*Software Development Life Cycle*, el ciclo de vida del desarrollo de software).

Herramientas éticas prácticas

HERRAMIENTA	QUÉ ES
-------------	--------

Estudio / Evaluación de Impacto Ético (EIA)	Análisis sistemático y preventivo de riesgos y beneficios antes del despliegue, como un estudio de impacto ambiental antes de construir una represa.
Checklist de Eticas Foundation	Guías de verificación paso a paso para auditar sesgos, privacidad y rendición de cuentas durante el desarrollo.
Auditorías algorítmicas	Revisiones independientes del funcionamiento interno (caja blanca) o de los resultados (caja negra) para detectar discriminación.
Evaluación por Derechos Humanos (HRIA)	Marco de Naciones Unidas adaptado para medir si una IA vulnera derechos fundamentales.
Gobernanza por diseño	Incorporar los principios desde la arquitectura técnica inicial, no como un parche final .

OJO CON LA SIGLA

"EIA" en este contexto es Evaluación de Impacto Ético. No la confundan con la sigla de la materia (Ética en Inteligencia Artificial).

Del discurso a la evidencia: una IA ética es aquella cuyos principios se verifican con evidencia y métricas, no solo con promesas.

Más ejemplos de dilemas:

- **Salud:** IA que prioriza pacientes con datos más completos (eficiencia) y deja atrás a quienes viven en zonas rurales (injusticia).
- **Seguridad:** reconocimiento facial que aumenta la seguridad (beneficencia) pero vulnera la privacidad sin consentimiento (autonomía).
- **Consumo:** publicidad personalizada que optimiza ventas (beneficencia comercial) pero manipula decisiones económicas (vulnera la autonomía).

Cada decisión técnica encarna un valor; cada omisión, un riesgo.

Conclusión del Módulo 2

Los principios son el **punto de encuentro entre la filosofía y la ingeniería**. Diseñar IA ética no es aspirar a la perfección, sino a la **mejora continua** mediante auditorías, transparencia y métricas claras. Lecturas sugeridas: UNESCO (2021), OCDE (2019) y Eticas Foundation (2023).

Glosario del Módulo 2

Autonomía	Respeto por la capacidad de decisión de las personas.
Beneficencia	Obligación de promover el bien y maximizar el valor social.
Explicabilidad	Posibilidad de entender cómo decide un sistema.
Fairness	Conjunto de técnicas para medir la equidad algorítmica.
Gobernanza algorítmica	Mecanismos institucionales de control y supervisión.
Justicia	Trato equitativo y no discriminatorio.
No maleficencia	Evitar causar daño o injusticia.
Privacidad	Derecho a controlar los datos personales.
Responsabilidad	Trazabilidad y rendición de cuentas.

Actividades del Módulo 2

- **Actividad 1, claves para el debate (foro):** (a) cómo equilibrarían eficiencia, justicia y transparencia en una IA para contratar personal; (b) ¿elegirían una IA médica 99% precisa pero caja negra, o una 85% precisa y totalmente explicable? Argumentar con beneficencia vs. explicabilidad.
- **Actividad 2, auditoría de principios:** retomar el caso del Módulo 1, evaluarlo con los 5 principios (¿es útil?, ¿discrimina?, ¿sabemos cómo decide?) y proponer una herramienta (checklist, EIA o auditoría) para resolverlo. Informe de 1 a 2 páginas.

Para autoevaluarse

► ¿Qué principio agrega Floridi a la bioética clásica y por qué?

► ¿Qué es la meta-autonomía?

► ¿Qué significa "operacionalizar" un principio?

MÓDULO 3 · 20% DE LA MATERIA

Sesgos y desafíos prácticos en la IA

Llegamos a uno de los temas más críticos en la práctica. Una frase para empezar: **los sesgos no son simples errores de programación, son desigualdades humanas traducidas en código**. Cada vez que pedimos un crédito, buscamos trabajo o recibimos un diagnóstico mediado por IA, interactuamos con decisiones que reflejan los datos con los que se entrenó. Si esos datos son incompletos, discriminatorios o desbalanceados, el resultado también lo será.

Los algoritmos no tienen prejuicios, pero pueden amplificarlos.

Cecilia Danesi (2022), El imperio de los algoritmos

La UNESCO (2021) y la OCDE (2019) advierten que los sesgos son **uno de los principales riesgos éticos** de la IA actual: afectan la equidad, la privacidad y la confianza pública.

Al terminar este módulo van a poder explicar cómo se originan los sesgos, clasificarlos, evaluar los trade-offs entre precisión y equidad, y aplicar métricas, auditorías y supervisión humana para mitigarlos.

Bloque 1: qué son los sesgos y cómo se originan

DEFINICIÓN

El **sesgo algorítmico** es una **distorsión sistemática** en los resultados de un sistema de IA que produce tratamientos injustos o discriminatorios hacia ciertos grupos o individuos.

Fíjense en la palabra **sistemática**: no es un error aislado, es un error que se repite siempre en la misma dirección, contra los mismos grupos. Puede originarse en cualquiera de las tres etapas del ciclo de vida:

1. **Sesgos de datos**: la información de entrenamiento no es representativa o arrastra prejuicios históricos.
2. **Sesgos de diseño**: elegir qué variables incluir, cómo ponderarlas o qué

métricas optimizar introduce valores humanos.

3. **Sesgos de uso:** la forma de implementar y supervisar la IA puede reforzar desigualdades.

Fíjense que esto coincide con el Módulo 1: datos, diseño y entorno.

Una mirada ética sobre el origen

Para Floridi, los sesgos **deterioran la infosfera** porque reducen la calidad moral de la información. Cuando un algoritmo discrimina, no solo falla técnicamente: **daña la estructura moral de la sociedad informacional**.

DE LA ESTADÍSTICA AL VALOR

Un modelo estadístico busca **precisión**; la ética busca **justicia**. Un sistema puede acertar en el 95% de los casos y aun así ser injusto si el 5% de errores cae **siempre sobre el mismo grupo vulnerable**.

Tipos de sesgos más comunes

TIPO	QUÉ PASA	EJEMPLO PARA FIJARLO
Selección	Los datos vienen de una población limitada u homogénea.	Un sistema de voz entrenado solo con hombres que no entiende voces femeninas.
Confirmación	Se refuerzan los supuestos previos del diseñador.	El diseñador cree que cierta zona es "peligrosa" y elige variables que lo confirman.
Etiquetado	Las personas que anotan los datos transfieren sus prejuicios.	Anotadores que marcan como "agresivo" cierto dialecto o acento.
Medición	Las variables no reflejan bien el fenómeno real.	Medir "productividad" solo por horas frente a la pantalla.
Interpretación	Se atribuyen significados erróneos a correlaciones.	Concluir que el código postal "causa" el riesgo crediticio.
Interacción	El comportamiento de los usuarios modifica los resultados.	Un chatbot que aprende insultos de quienes lo usan.

La columna de ejemplos la agrego como docente para ayudar a fijar cada tipo; solo el primero viene del material.

El círculo de retroalimentación

Los sistemas de IA aprenden de sus usuarios. Si los datos iniciales ya estaban sesgados, la retroalimentación **amplifica** la distorsión: el sistema decide con sesgo, esas decisiones generan nuevos datos sesgados, y el sistema se reentrena con ellos. Por eso la UNESCO recomienda **supervisión humana continua**.

Bloque 2: desafíos prácticos

1. Opacidad algorítmica

Muchos modelos, sobre todo los de **deep learning** (redes neuronales de muchas capas), son cajas negras: producen resultados sin poder explicar cómo llegaron a ellos. Esto afecta la confianza y la responsabilidad. Según la UNESCO, los ciudadanos tienen **derecho a entender** cómo se toman las decisiones que los afectan.

2. Trade-offs entre precisión y equidad

Un **trade-off** es un intercambio: ganar algo cuesta perder otra cosa. A veces reducir el sesgo implica sacrificar un poco de exactitud técnica. ¿Preferimos un modelo más preciso o más justo? Depende de los valores y del contexto. Pero la OCDE da un criterio: **ante la duda, priorizar la equidad y los derechos humanos sobre la eficiencia estadística**.

3. Sesgos culturales

Los algoritmos reflejan el contexto donde se desarrollan. Un sistema entrenado en Europa puede fallar en América Latina porque no reconoce nuestras diversidades culturales y lingüísticas. La UNESCO reclama una **IA inclusiva y multilingüe**.

4. Falta de diversidad en los equipos

Si quienes diseñan vienen todos de entornos similares, es más probable que no vean ciertos sesgos. La ética aplicada promueve **equipos multidisciplinarios y diversos**.

Caso central: IA en justicia predictiva ("JustAI")

Un tribunal usa "JustAI" para recomendar penas y evaluar el **riesgo de reincidencia** (probabilidad de volver a delinquir), con el objetivo de agilizar procesos. Unos investigadores descubren que asigna más riesgo a **jóvenes de barrios vulnerables**.

Diagnóstico:

- Los datos venían de **registros policiales históricos**, ya sesgados (sesgo de datos).
- El algoritmo **no distinguía entre "arresto" y "condena"** (sesgo de medición y diseño). Ser detenido no significa ser culpable.
- **No había supervisión judicial efectiva** sobre las recomendaciones (sesgo de uso).

JUSTICIA ALGORÍTMICA

Los sesgos pueden **reproducir desigualdades estructurales**. Una IA ética debe ser explicable, auditada y corregida regularmente. La justicia predictiva sin transparencia puede violar la **presunción de inocencia** (el principio de que todos somos inocentes hasta que se pruebe lo contrario).

Herramientas de mitigación

1. **Auditorías algorítmicas:** revisiones internas y externas de los modelos.
2. **Evaluaciones de impacto ético (EIA):** identificar riesgos antes del despliegue.
3. **Fairness metrics:** indicadores estadísticos de equidad:
 - *Paridad demográfica:* que los distintos grupos reciban resultados positivos en proporciones similares (por ejemplo, misma tasa de aprobación de créditos para hombres y mujeres).
 - *Igualdad de oportunidades:* que, entre quienes realmente merecen el resultado positivo, todos los grupos tengan la misma probabilidad de recibirlo.
 - *Disparate impact (impacto dispar):* compara las tasas de resultado favorable entre grupos; una diferencia grande indica discriminación aunque nadie haya tenido intención de discriminar.

4. **Revisión humana significativa:** intervención obligatoria de una persona con **autoridad real** de decisión, no alguien que solo pone el sello.
5. **Diversidad en los equipos:** perspectiva de género, regional y disciplinaria.
6. **Transparencia activa:** documentación, *datasheets* (fichas que describen un conjunto de datos: origen, composición, limitaciones) y *model cards* (fichas que describen un modelo: para qué sirve, cómo rinde en distintos grupos, cuándo no usarlo).

GOBERNANZA PROACTIVA

La gobernanza algorítmica requiere instituciones con protocolos de control, auditorías periódicas y **sanciones** por incumplimiento. Como dice Corvalán (2023): "la regulación ética debe ser **dinámica, no decorativa**".

Conclusión: los sesgos no desaparecen con mejor tecnología, sino con **mejor comprensión ética**, porque toda IA refleja las decisiones humanas que la crearon. El material cierra con una frase atribuida a Floridi: "la verdadera inteligencia no es la que predice mejor, sino la que actúa con responsabilidad moral".

EVALUACIÓN

Al terminar este módulo están en condiciones de rendir la **Primera Parte de la Evaluación Integradora**. Lecturas recomendadas: Corvalán (2023), *Propuestas de regulación y recomendaciones de IA en el mundo* (IALAB-UBA) y Jobin, Ienca y Vayena (2019), *The Global Landscape of AI Ethics Guidelines*.

Glosario del Módulo 3

Evaluación de impacto ético (EIA)	Herramienta para anticipar consecuencias morales.
Gobernanza algorítmica	Conjunto de políticas y estructuras para regular el uso ético de la IA.
Fairness	Principio de equidad algorítmica.
Opacidad algorítmica	Falta de comprensión del funcionamiento interno de un modelo.

Revisión humana significativa	Supervisión efectiva de decisiones automatizadas.
Sesgo algorítmico	Distorsión sistemática en los resultados de un sistema de IA.

Actividades del Módulo 3

- **Actividad 1, análisis de un caso de sesgo:** elegir un caso (justicia, salud, empleo, educación), identificar los tipos de sesgo, analizar consecuencias y proponer mitigaciones. Informe de 1 a 2 páginas con citas.
- **Actividad 2, foro:** ¿qué es más urgente para reducir sesgos: mejorar los datos, diversificar los equipos o crear nuevas leyes? Fundamentar con la teoría.

Para autoevaluarse

► ¿Por qué un modelo con 95% de acierto puede ser injusto?

► En JustAI, ¿qué tipos de sesgo identifican?

MÓDULO 4 · 10% DE LA MATERIA

Impacto social y futuro de la IA

La IA no solo cambia procesos técnicos: **cambia estructuras sociales completas**.
Cómo trabajamos, aprendemos, nos informamos y nos relacionamos. La pregunta ética de fondo es:

¿Quién se beneficia y quién queda excluido del progreso tecnológico?

Luciano Floridi (2019)

La ética de la IA debe asegurar que la innovación **reduzca desigualdades en lugar de profundizarlas**, equilibrando eficiencia con justicia social, sostenibilidad ambiental y diversidad cultural.

Al terminar este módulo van a poder analizar el impacto social, laboral, cultural y democrático de la IA, evaluar riesgos para la equidad digital y la diversidad, comprender la huella ecológica y reflexionar sobre la soberanía digital de

América Latina.

LA ÉTICA DEL IMPACTO: DEL BENEFICIO INDIVIDUAL AL BIEN COMÚN

Floridi propone la **beneficencia informacional**: toda acción tecnológica debe mejorar la calidad moral de la infósfera. Medir el impacto no es preguntar solo "¿qué tan bien funciona?", sino "¿a quién sirve y qué efectos produce?".

Ejemplo: una IA que optimiza la recaudación fiscal hace más eficiente al Estado, pero si vulnera la privacidad o discrimina sectores, su impacto ético es negativo. **La eficacia no garantiza justicia.**

Bloque 1: impacto social, laboral y cultural

1. La economía digital y el trabajo digno

La automatización redefine el empleo. Algunos puestos desaparecen y surgen otros: análisis de datos, ciberseguridad, ética tecnológica, auditoría algorítmica. La UNESCO y la OCDE piden una **transición justa**: acompañar las políticas de IA con reconversión laboral y educación permanente.

Ejemplo argentino: el Plan Nacional de IA (2023) propone capacitar a agentes públicos y PyMEs, priorizando a trabajadores con baja alfabetización tecnológica. La justicia social se traduce en **formación y participación**.

2. Educación y equidad digital

La IA educativa puede personalizar la enseñanza, anticipar dificultades y promover la inclusión. Pero si se entrena con datos desbalanceados, **reproduce las mismas brechas que busca corregir**. Una IA educativa ética explica sus recomendaciones, respeta la autonomía del estudiante y garantiza igualdad de acceso: **no decide por el alumno, lo empodera para decidir mejor**.

Ejemplo regional: tutorías inteligentes en universidades argentinas y mexicanas (ProAI-UBA, Aprende con IA) muestran que la tecnología mejora la retención solo cuando hay acompañamiento docente humano.

3. Cultura, medios y burbujas informativas

Los algoritmos de recomendación determinan buena parte del consumo cultural. Personalizan, pero pueden encerrarnos en **burbujas informativas**: solo vemos lo que ya nos gusta o lo que confirma lo que pensamos.

La UNESCO promueve la **diversidad algorítmica**: una IA multilingüe y plural. Tener contenidos en español, portugués y lenguas originarias es también **justicia digital**. Iniciativas en México, Brasil y Argentina crean datasets locales; un ejemplo es **Latam-GPT**, un proyecto de universidades y centros de Argentina, México, Brasil y Colombia para construir un modelo de lenguaje soberano con corpus regionales que incluye lenguas indígenas.

4. IA, democracia y participación ciudadana

La IA puede servir a la transparencia pública o a la manipulación política. Campañas que segmentan mensajes o crean **deepfakes** (videos o audios falsos hiperrealistas) comprometen la integridad democrática. Floridi vincula la ética digital con la defensa de la verdad pública: "cuidar la infosfera es proteger el tejido moral de la democracia". En Argentina, en 2023, la Defensoría del Pueblo alertó sobre desinformación algorítmica en las elecciones. Hace falta regulación que preserve el derecho a una **información veraz** (integridad informacional).

Bloque 2: IA y sostenibilidad

1. La huella ecológica de la IA

Entrenar modelos grandes consume mucha energía. Cada innovación tiene un costo ambiental que debe evaluarse. Floridi plantea una **ecología de la información**: cuidar el entorno digital con los mismos criterios que el natural. La IA debe ir hacia la eficiencia energética, el hardware sostenible y el software optimizado.

Ejemplo regional: data centers de Uruguay y Chile alimentados con energías renovables (los llamados *Green Data Centers*).

2. IA para el desarrollo sostenible

La IA también puede proteger el ambiente. El proyecto **IA y Cambio Climático** (INTA-CONICET, 2024) usa aprendizaje automático con datos meteorológicos, satelitales y proyecciones climáticas para anticipar sequías en la Pampa

Húmeda y planificar siembra, cultivos resilientes y manejo del agua.

BENEFICENCIA ECOLÓGICA

Una IA ética debe generar un **beneficio neto ambiental**: lo que aporta a la sostenibilidad tiene que superar el costo energético de funcionar.

Bloque 3: escenarios futuros y debates emergentes

1. Autonomía y responsabilidad compartida

Los sistemas autónomos nos obligan a mantener la **supervisión humana significativa**. El objetivo no es crear máquinas morales, sino **sociedades que asuman colectivamente la responsabilidad**. Floridi propone cambiar el paradigma de "inteligencia artificial" por el de **inteligencia aumentada**: las máquinas deben amplificar la empatía y el juicio humano, no reemplazarlos.

2. Creatividad, arte y derechos de autor

Los modelos generativos crean imágenes, música y textos, y plantean dilemas de **autoría y originalidad**. La ética de la co-creación se basa en la **transparencia**: reconocer las fuentes de datos, respetar los derechos de autor y proteger la creación humana. Ejemplo: artistas digitales argentinos (IApuraArte, 2025) que promueven códigos abiertos y atribución compartida.

3. Concentración tecnológica y soberanía digital

La IA global está dominada por **pocas corporaciones**, lo que genera dependencia y desigualdad. Corvalán (2023) dice que América Latina debe fortalecer su infraestructura de datos, sus marcos regulatorios y la formación pública. Dos iniciativas argentinas:

- **IALAB (UBA)**: el primer laboratorio de IA en una Facultad de Derecho de Iberoamérica. Investiga y prototipa soluciones con impacto social y promueve organizaciones "humano-agénticas", que mantienen la centralidad humana en las decisiones. Lo dirige Corvalán.
- **AAIP (Agencia de Acceso a la Información Pública)**: organismo estatal que garantiza el acceso a la información pública y la protección de datos personales, con guías para el uso responsable de IA y la explicabilidad

algorítmica.

Caso central: IA y automatización en el empleo público

Un organismo estatal argentino usa IA para clasificar declaraciones y detectar anomalías fiscales. Gana eficiencia, pero los empleados temen perder su trabajo. Tras un diálogo, la institución crea un **Programa de transición digital ética** con capacitación, acompañamiento psicológico y participación sindical.

- **Principios implicados:** justicia, beneficencia y autonomía.
- **Riesgos:** exclusión laboral, pérdida de confianza institucional.
- **Medidas:** capacitación, revisión humana significativa, comunicación transparente.

Una digitalización ética es **inclusiva, gradual y participativa**: mejora el servicio sin sacrificar derechos laborales.

La ética del futuro no se predice, se diseña.

Floridi (2019), según el material

Desarrollar IA para el bien común es responsabilidad compartida entre gobiernos, empresas, universidades y ciudadanía.

Glosario del Módulo 4

Beneficencia informacional	Acción que mejora la calidad ética de la infosfera.
Diversidad algorítmica	Pluralidad cultural y lingüística en el diseño de IA.
Ecología de la información	Cuidado ético del entorno digital y su impacto ambiental.
Inteligencia aumentada	Cooperación ética entre humanos y máquinas.
Integridad informacional	Protección de la calidad y veracidad de la información pública.
Soberanía digital	Autonomía de los Estados en el control y uso de datos.
Transición justa	Políticas que acompañan los cambios laborales generados por la tecnología.

Actividades del Módulo 4

- **Actividad 1, ensayo ético (2 páginas):** elegir un ámbito (trabajo, educación, cultura, ambiente o política), describir el impacto, identificar valores comprometidos, aplicar Floridi, UNESCO y OCDE, y proponer mejoras.
- **Actividad 2, foro:** ¿cómo podría la IA contribuir al desarrollo sostenible y la equidad social en América Latina?

MÓDULO 5 · 20% DE LA MATERIA

Gobernanza y regulación de la IA

Último módulo. Ya vimos fundamentos, principios, sesgos e impacto. Ahora, la pregunta práctica: ¿cómo se garantiza todo eso en la realidad?

IDEA CENTRAL

La ética marca el rumbo; la gobernanza define el camino. Sin supervisión y normas claras, los principios quedan en buenas intenciones. El desafío es **institucionalizar la responsabilidad tecnológica**.

La gobernanza algorítmica no es un freno a la innovación, sino su condición de legitimidad.

Floridi (2019), según el material

Al terminar este módulo van a poder explicar los pilares de la gobernanza algorítmica, analizar los marcos globales (AI Act, UNESCO, OCDE, NIST AI RMF, ISO/IEC 42001), valorar las iniciativas argentinas y latinoamericanas, y aplicar criterios de *AI Security by Design*.

Bloque 1: qué es la gobernanza algorítmica

Es el conjunto de **políticas, estructuras, estándares y prácticas** que garantizan que la IA respete los valores democráticos, los derechos humanos y el interés público. La consigna: **gobernar algoritmos, no dominarlos**. Equilibra tres dimensiones:

Regulación jurídica

Leyes, normas y estándares internacionales.

Gestión organizacional

Procesos internos, auditorías y control institucional.

Cultura ética

Educación, transparencia y participación ciudadana.

Floridi define la gobernanza de la información como la **arquitectura del bien digital**: diseñar sistemas donde las decisiones automatizadas se integren en una ética institucional. *Ejemplo*: una IA que aprueba créditos no debe limitarse a predecir, sino hacerlo con justicia y **trazabilidad auditada**.

Bloque 2: marcos internacionales de regulación y ética

1. La Unión Europea y el AI Act (2024)

Es la **primera ley integral sobre IA del mundo**. Su idea central es regular según el **riesgo**: cuanto más daño puede causar un sistema, más obligaciones tiene. Lo resume la fórmula "prohibir, permitir o vigilar":

Riesgo inaceptable: prohibido
Manipulación subliminal, scoring social

Alto riesgo: evaluación previa
Salud, justicia, seguridad

Riesgo limitado: transparencia
Debe informar que es una IA, por ejemplo

Riesgo mínimo: libre uso
Sin control regulatorio específico

El **scoring social** es puntuar a los ciudadanos según su comportamiento para darles o quitarles derechos. El AI Act exige documentación, explicabilidad, supervisión humana y gestión de riesgos: marca el paso de la **ética voluntaria** a la **compliance obligatoria** (cumplimiento normativo exigible). Para América

Latina funciona como **referente** en los debates de Argentina, Brasil, Chile y México.

2. La Recomendación de la UNESCO (2021)

Aprobada por consenso global, es el **marco ético internacional más amplio**. Principios rectores: proporcionalidad y seguridad; equidad y no discriminación; supervisión y rendición de cuentas; privacidad y protección de datos; responsabilidad ambiental; gobernanza internacional. Su lema: **ética global, implementación local**. Cada país adapta la IA a su contexto, y se proponen Consejos Nacionales de Ética de la IA y evaluaciones de impacto ético en políticas públicas.

3. Los Principios de la OCDE (2019)

Adoptados por más de 40 países, promueven una IA centrada en el bienestar humano, transparente y responsable, robusta y segura, inclusiva y sostenible. Sirvieron de base para el AI Act y para el **Global Partnership on AI (GPAI)**, que busca armonizar estándares entre regiones (cooperación multilateral).

4. Marcos técnicos complementarios

NIST AI RMF (EE.UU., 2023) Marco de gestión de riesgos que orienta a empresas y gobiernos para identificar, evaluar y mitigar riesgos algorítmicos. Es una guía, no una ley.	ISO/IEC 42001 (2023) Primera norma internacional de gestión para IA: requisitos de políticas internas, auditorías, documentación y gobernanza de datos. Las organizaciones deben demostrar cumplimiento con evidencia; es la institucionalización de la ética.
--	---

MARCO	QUIÉN	NATURALEZA	EN UNA FRASE
AI Act	Unión Europea, 2024	Ley obligatoria	Regula por niveles de riesgo.
Recomendación	UNESCO, 2021	Marco ético global	Ética global, implementación local.

Principios	OCDE, 2019	Principios adoptados por +40 países	Base del AI Act y del GPAI.
AI RMF	NIST, EE.UU., 2023	Marco técnico voluntario	Gestión de riesgos.
ISO/IEC 42001	ISO, 2023	Norma certificable	Sistema de gestión con evidencia verificable.

Bloque 3: gobernanza y soberanía digital en América Latina

La región necesita **reducir su dependencia** de modelos desarrollados en el Norte Global. Corvalán (2023) propone tres pilares: **datos soberanos y públicos, marcos legales coordinados y cooperación académica regional**. Sin soberanía digital no hay ética sostenible: desarrollar capacidades locales es un acto de **justicia intergeneracional** (hacia las generaciones futuras).

Argentina como caso de estudio

ORGANISMO	ROL
AAIP	Res. 145/2025: Programa de Fortalecimiento de Protección de Datos Personales (cumplimiento, capacitación, redes de delegados).
IALAB – UBA	Impulsa marcos de <i>AI Security by Design</i> y evaluaciones de impacto ético.
ARSAT	Infraestructura pública de datos soberanos.
CSIRT-AR	Respuesta estatal a incidentes de ciberseguridad.
INTI e INAI	Desarrollo técnico y promoción de derechos digitales.

La gobernanza argentina combina infraestructura, regulación y ética aplicada. El Estado no solo debe controlar, sino **liderar con el ejemplo**: IA transparente, trazable y abierta.

América Latina y el multilateralismo digital

La CEPAL y la OEA impulsan un Marco Regional Ético para la IA articulado con UNESCO y OCDE. Brasil, Chile, Uruguay y México ya tienen estrategias nacionales. El reto: convertir valores en **políticas sostenibles y medibles**.

Bloque 4: desafíos de implementación

1. Auditoría y trazabilidad

La **ética se verifica con evidencia**. Hay que documentar datos, modelos y decisiones. La **trazabilidad** es poder reconstruir cada paso del proceso de decisión, como la "caja negra" de un avión que permite saber qué pasó después de un accidente. Es el principio operativo de la confianza (*accountability* algorítmico). Eticas Foundation (2023) propone auditorías **externas, independientes y periódicas**.

2. Responsabilidad algorítmica y legal

¿Quién responde si una IA causa daño? Hay tres enfoques en debate:

Del diseñador

Culpa técnica: quien lo construyó mal responde.

Del operador o usuario

Quien lo usó de forma indebida responde.

Objetiva del titular

El dueño del sistema responde por el daño aunque no haya culpa demostrada.

La responsabilidad se extiende a **todo el ciclo de vida**: diseño, entrenamiento, uso y actualización. "De la culpa a la gobernanza": la transparencia documental es la herramienta más eficaz contra la **impunidad tecnológica**. Fíjense cómo esto retoma la responsabilidad distribuida del Módulo 1.

3. Gobernanza adaptativa

La tecnología avanza más rápido que las leyes. Por eso se propone la **regulación en capas**:

1

Principios éticos estables

Cambian poco (justicia, explicabilidad...).

2

Normas técnicas dinámicas

Se actualizan con la tecnología.

3

Guías de buenas prácticas

Orientación concreta y flexible.

Ejemplo: el AI Act prevé comités de expertos que actualizan periódicamente los anexos técnicos. Argentina podría aplicar este modelo con la cooperación AAIP-INTI-IALAB.

Caso central: Marco Argentino de AI Security by Design (MAC-GenAI)

Impulsado por el UBA IALAB, propone integrar **seguridad y ética desde el diseño**. Sus cinco ejes:

- Evaluación de impacto ético y legal.
- Supervisión humana significativa.
- Protección de datos por diseño.
- Ciberseguridad algorítmica.
- Gobernanza institucional transversal.

Ética por diseño y seguridad por diseño se complementan: juntas producen sistemas confiables, auditables y socialmente aceptables.

EVALUACIÓN

Al terminar este módulo están en condiciones de rendir la **Segunda Parte de la Evaluación Integradora**.

Glosario del Módulo 5

Accountability	Responsabilidad y trazabilidad de las decisiones automatizadas.
AI Act	Reglamento Europeo sobre Inteligencia Artificial (2024).
AI Security by Design	Integración de seguridad y ética desde el diseño.
Evaluación de Impacto Ético	Análisis previo de los efectos morales y sociales de una IA.
Gobernanza algorítmica	Sistema de políticas, normas y controles que orientan el desarrollo ético de la IA.

ISO/IEC 42001	Estándar internacional de gestión para sistemas de IA.
NIST AI RMF	Marco estadounidense de gestión de riesgos de IA.
Soberanía digital	Capacidad de los Estados para controlar sus datos, infraestructuras y políticas tecnológicas.

Actividades del Módulo 5

- **Actividad 1, marco de gobernanza (integradora, 3 a 4 páginas):** elegir una organización pública, privada o académica, identificar los riesgos éticos y regulatorios de su IA y diseñar un marco basado en UNESCO–OCDE–ISO–AAIP, con roles, controles, documentación y auditorías. Se evalúa pertinencia técnica, coherencia ética y solidez normativa.
- **Actividad 2, pregunta de cierre (foro):** ¿qué tipo de gobernanza necesita Argentina para una IA ética, transparente y soberana?


Para autoevaluarse

- ▶ Un sistema de scoring social, ¿en qué nivel del AI Act cae?
- ▶ ¿Qué diferencia a la ISO/IEC 42001 de la Recomendación de la UNESCO?
- ▶ ¿Qué es la regulación en capas y para qué sirve?

CIERRE

Síntesis final: cómo se conecta todo

Repasemos el recorrido como una sola historia:



4

A quién afecta

Trabajo, educación, cultura, democracia y ambiente.

5

Cómo se controla

Gobernanza: leyes, gestión organizacional y cultura ética.

Una IA ética requiere tres condiciones: **principios sólidos, instituciones responsables** y una **ciudadanía informada y participativa**. La gobernanza es el puente entre el ideal ético y la realidad operativa.

Seremos medidos no por cuán inteligentes sean nuestras máquinas, sino por cuán sabias sean nuestras decisiones al usarlas.

Floridi (2019), según el material

Muchas gracias. Nos vemos en el foro.

Clase elaborada a partir del material de cátedra "Ética en Inteligencia Artificial" (Lic. en Inteligencia Artificial, Universidad Blas Pascal). Las analogías y los ejemplos marcados como del docente son agregados pedagógicos; las citas atribuidas a autores se reproducen tal como figuran en el material.