"Evaluación Integradora – Matemáticas - Primera parte".

Estudiante: Gentile, Agustín Raúl
DNI: 32,7097,735
Fecha entrega: 14/10/2026
Legajo: 199433

Gentile, Agustín Raúl (DNI: 32709735) (Legajo: 199433)

1. Integración entre Álgebra Lineal y la estructura de modelos de IA

- Explique cómo se articula la representación vectorial de datos con el funcionamiento de una capa densa.
- Fundamente usando los ejemplos trabajados en las actividades del Módulo 1 (independencia, rango, transformaciones).

Toda entidad del mundo real para ser procesada por un modelo de IA, es transformada y representada por un vector, que es un conjunto de valores numéricos, donde cada uno representa una característica del objeto que se está representando. Por ejemplo si queremos representar una casa para introducirlo a un modelo que predice precios en base a 5 características, la misma se representaría como un vector=(m², cant habitaciones, cant baños, m² patio, posee pileta).
En un modelo de red neuronal, cada capa densa toma como entrada un vector de entrada X y produce un vector de salida Y, mediante una fórmula del tipo Y = f(W.x + b). Donde Y es el vector de salida, "x" el vector de entrada, "f" es una función de activación no lineal; y lo importante a recalcar acá es W.x + b, intervienen dos operaciones, la multiplicación de matriz x vector y se le suma un vector de sesgo. Cada fila de W representa los pesos de una neurona, multiplicar cada fila de "W" por el vector de entrada "x", produce una combinación lineal, combina las características del vector de entrada el cual se convierte a un componente del vector de salida.

Mediante el análisis de la matriz de pesos podemos recabar mucha información útil: determinar si existe dependencia lineal entre sus filas y/o columnas, determinar el rango, el espacio de salida, entre otras.

Si tomamos como ejemplo una matriz de pesos (caso de las actividades): Tenemos la matriz W como una capa densa de un modelo:

$$W = \begin{bmatrix} 1 & -1 & 2 & 0 \\ 2 & -2 & 4 & 0 \end{bmatrix}$$

Analizando la matriz se observa que hay una dependencia lineal entre las filas de la matriz; la segunda fila se puede escribir como combinación lineal de la primera, la segunda fila es el doble de la primera (F2 = 2 * F1). Las dos neuronas de la capa son redundantes aprenden la misma combinación de características.
Además, existe una dependencia lineal entre las columnas de la matriz: tanto la segunda columnas, como la tercera y cuarta son combinaciones lineales de la primer columna (C2 = -1 * C1; C3= 2 * C1 ; C4 = 0 * C1). Existe solo una columna independiente.

Si obtenemos el rango; esta matriz tiene rango 1, no tiene rango máximo, rango es menor que el mínimo número de filas y columnas que sería 2.
Como la matriz W define una transformación lineal de un espacio de 4 dimensiones a un espacio menor de 2 dimensiones , pero su rango es 1, nos dice que aunque la transformación va de 4 dimensiones a 2, la imagen de salida vive en un espacio de una dimensión. Aunque la capa parece tener 2 neuronas, en términos efectivos sólo aprende una dirección del espacio de características → desperdicio de parámetros, pérdida de capacidad representativa.

Gentile, Agustín Raúl (DNI: 32709735) (Legajo: 199433)

2. Rol de las transformaciones lineales en el procesamiento de características

- Analice por qué las matrices guían la mezcla, proyección y reducción de características.
- Incluya referencias directas a los ejercicios realizados en clase.

Una matriz como transformación lineal puede pensar como una máquina (una función) toma vector de entrada y produce un vector de salida, toma vectores de un espacio de N características y las lleva a un espacio de M características, la idea de la linealidad se da porque toda transformación lineal debe respetar que la líneas siguen siendo líneas, y el origen no se mueve, gracias a esto una matriz como transformación lineal puede llegar a definir operaciones como la reducción de características (combinando características reducimos el espacio de entrada a un espacio de menor dimensión), proyección del espacio de entrada sobre otra dimensión; rotar el espacio, estirarlo y entre otras.

Por ejemplo tenemos a la matriz como transformación lineal (tomamos el ejemplo de las actividades)

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}$$

Si tenemos a A como matriz de transformación lineal y lo aplicamos a un conjunto de vectores de entrada x1=(2, 1) , x2=(1,3) , x3=(4,2), obtenemos como salida: X1=(5,3) , X2=(5, 4), X3=(10, 6)
Si analizamos el comportamiento de haber aplicado la matriz a dichos vectores de entrada, podemos observar como se transformó el espacio de entrada a un nuevo espacio; además observamos distintos comportamientos: deformación del espacio y estiramiento. Al contar con una matriz cuadrada podés obtener el determinante para analizar invertibilidad, det(A) = 2*1 – 1*1 = 1 distinto de 0; Como el determinante de A no es 0 (1 en esta matriz) nos determina que la matriz es invertible, no hay perdida de información, la matriz es inyectiva.

3. Funciones, continuidad y comportamiento analítico

- Explique la importancia de la continuidad en modelos de IA.
- Fundamente con ejemplos del Módulo 2: funciones definidas por tramos, límites y crecimiento.

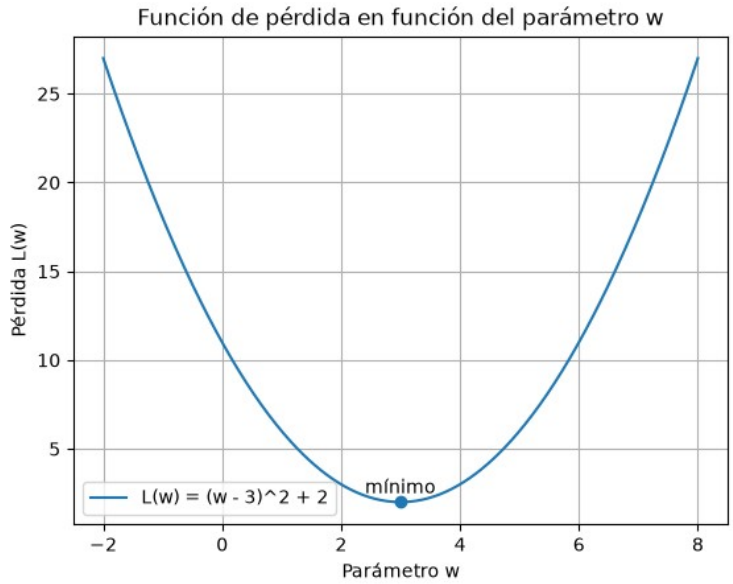
Una función es una relación o mapeo que a cada entrada la transforma y produce una salida. Toda función acepta un conjunto posible de valores donde la misma está bien definida y devuelve valores, este conjunto de valores es el “dominio” de la función, y el conjunto de todas las salidas que produce se lo conoce como la “imagen”. Una función es creciente en un intervalo si a medida que aumenta los valores de entrada, los valores de salida también aumentan; y es decreciente si a medida que aumentan los valores de entrada los valores de salida disminuyen.

Gráficamente, una función es continua en un rango, si podés seguir la traza con un lápiz, y el mismo nunca se levanta de la hoja, no hay saltos bruscos en la gráfica. Formalmente, podemos decir que es continua en un determinado punto A, cuando el límite de la función tiende a A es el mismo valor calculado de F(x) en ese punto “A”.

Existen funciones que están definidas por tramos, en estas funciones encontramos distintas definiciones según el tramo del dominio.
Las funciones de perdida que se utilizan en los modelos de IA, aplican cálculos de derivada; para poder derivar en un determinado punto es condición necesaria que la misma sea continúas en dicho punto, por eso es fundamental que las funciones de perdida sean continuas, esto le aporta estabilidad y predictibilidad. Los modelos de IA aprenden ajustando parámetros, aumentando o disminuyendo estos de forma muy pequeña, si no se usaran funciones continuas, cualquier cambio pequeño en los parámetros produciría un cambio brusco en la salida (en el valor de la perdida)

Si tomamos el ejemplo de la actividad:

$$L(w) = (w-3)^2 + 2$$



Esta función es continua es todo su dominio, por lo tanto, es derivable.

4. Derivadas, gradientes y función de pérdida

- Analice el vínculo entre la derivada y la dirección de ajuste del modelo.
- Conecte el cálculo de derivadas e integrales realizados con la interpretación del aprendizaje.

Sabemos que los modelo de IA usan una función de perdida para decidir si hay que ajustar los parámetros del modelo o si se llegó al punto de perdida mínimo, no hay que ajustar más. Para saber esto, si hay que ajustar los parámetros “w” se calcula la derivada de la función de perdida en “w” la cual determina según su valor si hay que ajustar los valores de los parámetros o no. Según el resultado de la derivada podemos estar en frente a tres escenarios:

- Si la derivada es mayor que cero: Nos dice que si aumentamos W aumenta el error y si disminuimos W el error disminuye.
- Si la derivada es menor a cero: Si disminuimos W la perdida crece, si aumentamos W la perdida disminuye.
- Si la derivada en cero: estamos en un minio, los valores de W serian candidatos (modelo ajustado)

5. Síntesis integradora (1 página)

Responda las tres preguntas de la imagen que compartió:

a) ¿Cómo se articula el álgebra lineal con el análisis de funciones en el interior de un modelo de IA?
b) ¿Por qué las transformaciones lineales, la continuidad y la convexidad resultan esenciales en aprendizaje automático?
c) Qué papel cumplen estas herramientas matemáticas en la generalización y estabilidad del modelo?

a) Los modelos de IA reciben una entrada y produce una salida, en su interior esta entrada (información) pasa por numerosos cálculos encadenados hasta producir la salida.
En una red neuronal, en cada capa primero se lleva a cabo operación perteneciente al álgebra lineal (multiplicación matriz x vector), con esto se pueden combinar, transformar, rotar, proyectar características (operaciones lineales); a continuación el resultado pasa por una función de activación no lineal, la cual introduce no linealidad y permite que el modelo aprenda relaciones complejas.
Para ajustar la matriz de pesos se emplean derivadas y gradientes que indican en que dirección debe moverse el modelo para ajustarse.

b) Las tres operaciones aunque diferentes en funcionalidad cumplen un papel fundamental en el aprendizaje automático.

- Las transformaciones lineales nos proveen de las operaciones para manipular información, a través de la multiplicación de "**matriz"** (como transformación lineal) x **"vector"** (entrada) podemos definir distintas operaciones como: combinación de características, proyección de un espacio de N dimensiones a uno de M, reducción de características, etc, cada capa aplica una transformación lineal, para aprender ciertas características y pasarla a la capa siguiente.
- La continuidad es fundamental, ya que garantiza estabilidad al modelo, nos garantiza que pequeños cambios en los parámetros de una red, produzcan salidas continuas sin saltos bruscos, la continuidad es condición necesaria para la derivabilidad, y sin esta última no hay descenso del gradiente; con lo cual no se puede entrenar el modelo
- A través de la convexidad garantizamos que cualquier mínimo local sea un mínimo global; esto es fundamental, en el descenso del gradiente una función de perdida convexa garantiza que el mínimo converga al mínimo global.

c) Tanto transformaciones lineales, la continuidad y la convexidad lineales, cumplen un papel fundamental tanto en la generalización como en la estabilidad. Las transformaciones lineales favorecen la generalización, reducir características o combinar las mismas nos permiten trabajar con información relevante, la continuidad favorecen a la estabilidad, ya que garantizan que pequeños cambios en los parámetros produzcan cambios pequeños en las salidas, sin producir saltos bruscos.
La convexidad en las funciones de perdida nos garantizas que el mínimo encontrado sea global.

Gentile, Agustín Raúl (DNI: 32709735) (Legajo: 199433)