

Matemáticas para Inteligencia Artificial

Módulo 1 - Álgebra lineal, explicado desde cero

Resumen de estudio pensado para retomar Matemáticas después de varios años

Objetivo de este apunte: que puedas leer el Módulo 1 sin sentir que cada fórmula supone conocimientos frescos. Primero entendemos la idea, después vemos la cuenta y recién al final la conectamos con IA.

Este resumen sigue los temas del Módulo 1 del material de la Licenciatura: vectores, espacios vectoriales, matrices, transformaciones lineales, rango, núcleo, imagen, matrices especiales y determinantes. Se simplifica el lenguaje, pero se conservan los conceptos que necesitás para las actividades y para los módulos siguientes.

0. Antes de empezar: el mapa mental

El álgebra lineal puede parecer una colección de símbolos, pero en IA tiene una idea central muy concreta: **convertimos información en números y después transformamos esos números**.

Concepto	Pensalo como...	En IA puede representar...
Vector	Una lista ordenada	Una persona, una palabra, un píxel, características
Matriz	Una tabla de números / una máquina	Dataset, pesos de una red, transformación
Transformación	Una regla que cambia datos	Mezclar, comprimir o proyectar características
Rango	Cuánta información útil queda	Redundancia o pérdida de dimensiones
Determinante	Si la transformación se puede deshacer	Invertibilidad y pérdida de información

Idea para programador: un vector se parece a un array numérico. Una matriz se parece a un array bidimensional. La diferencia es que en Matemáticas no solo almacenamos números: definimos operaciones con significado geométrico.

1. Vectores

1.1 ¿Qué es un vector?

Un vector es una **lista ordenada de números**. Si escribimos:

$$x = [2, 5, 1]$$

podemos decir que x tiene tres componentes. En un problema real esas componentes podrían significar, por ejemplo: edad = 2, cantidad de compras = 5 y reclamos = 1. Lo importante es que **cada posición tiene un significado**.

En IA, los datos suelen convertirse en vectores. Una imagen puede convertirse en miles de números; un audio en una secuencia de muestras; una palabra en un embedding, es decir, un vector numérico que la representa.

1.2 Suma y multiplicación por un número

$$[2, 3] + [4, 1] = [6, 4]$$

$$2 * [2, 3] = [4, 6]$$

La suma se hace componente a componente. Multiplicar por un número (un *escalar*) multiplica todas las componentes.

Escalar = un número común, como 2, -3 o 0,5. **Vector** = varios números ordenados.

1.3 Magnitud o norma

La norma mide el 'largo' del vector. Para un vector de dos componentes se usa Pitágoras:

$$||x|| = \sqrt{x_1^2 + x_2^2}$$

Ejemplo: para $x = [3, 4]$, $||x|| = \sqrt{9+16} = 5$. En IA, las normas aparecen en distancias, normalización y regularización.

1.4 Producto punto

El producto punto toma dos vectores del mismo tamaño, multiplica componente a componente y suma:

$$[1, 2, 3] \cdot [4, 5, 6] = 1*4 + 2*5 + 3*6 = 32$$

Sirve para medir cuánto 'apuntan en la misma dirección'. Por eso está relacionado con similitud, embeddings, redes neuronales y mecanismos de atención.

2. Espacios vectoriales, sin misterio

El material llama al espacio vectorial la 'geometría donde vive la IA'. Para empezar, alcanza con esta intuición: **es el conjunto de todos los vectores del tipo con el que estamos trabajando**, junto con reglas válidas para sumarlos y multiplicarlos por escalares.

R^2 significa vectores con 2 números, por ejemplo [3,5]. R^3 significa vectores con 3 números. R^n significa vectores con n números.

No hace falta imaginar R^{1000} . Geométricamente es difícil, pero computacionalmente es simplemente un vector de 1000 valores.

¿Por qué esto importa en IA? Porque permite calcular distancias, ángulos y similitudes entre datos. Eso se usa, por ejemplo, para encontrar vecinos cercanos (kNN), agrupar datos (clustering) o comparar embeddings.

3. Combinación e independencia lineal

3.1 Combinación lineal

Una combinación lineal es sumar vectores después de multiplicarlos por números.

$$2 * [1, 0] + 3 * [0, 1] = [2, 3]$$

Los números 2 y 3 son los coeficientes. La idea aparece constantemente cuando una red neuronal combina características.

3.2 Independencia lineal

Dos o más vectores son linealmente independientes cuando ninguno puede construirse usando los otros. Si uno es una copia escalada de otro, hay dependencia.

$$v1 = [1, 2] \text{ y } v2 = [2, 4] = 2 * v1 \rightarrow \text{dependientes}$$

Esto significa redundancia: $v2$ no agrega una dirección nueva. En un dataset o una capa de una red, demasiada redundancia puede significar que estamos usando variables o neuronas sin aportar información diferente.

Regla mental: independiente = aporta algo nuevo. Dependiente = se puede obtener a partir de lo que ya teníamos.

4. Matrices

4.1 ¿Qué es una matriz?

Una matriz es un arreglo rectangular de números. Por ejemplo, una matriz de 2 filas y 3 columnas:

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \rightarrow \text{tamaño } 2 \times 3$$

En IA una matriz puede ser un dataset, los pesos de una capa neuronal, una imagen, una matriz de covarianza o las conexiones de un grafo. El material remarca que gran parte del aprendizaje automático depende del álgebra matricial.

4.2 Matriz como una máquina que transforma

Pensá una matriz como una función: entra un vector y sale otro vector.

$$\mathbf{y} = \mathbf{A} \mathbf{x}$$

La matriz puede mezclar características, estirar, comprimir, rotar o proyectar datos. Una capa densa de una red neuronal usa justamente una operación del estilo $\mathbf{Wx} + \mathbf{b}$.

5. Multiplicación matriz-vector

Para multiplicar una matriz por un vector, cada fila de la matriz hace un producto punto con el vector.

$$A = \begin{bmatrix} 2 & 1 \\ 3 & 4 \end{bmatrix} \quad x = \begin{bmatrix} 5 \\ 2 \end{bmatrix}$$

$$Ax = \begin{bmatrix} 2 \cdot 5 + 1 \cdot 2 \\ 3 \cdot 5 + 4 \cdot 2 \end{bmatrix} = \begin{bmatrix} 12 \\ 23 \end{bmatrix}$$

La matriz tenía 2 filas, por eso el resultado tiene 2 componentes. En una red neuronal, cada fila puede pensarse como los pesos de una neurona. Cada neurona combina las entradas y produce un valor.

Chequeo de dimensiones: una matriz $m \times n$ puede multiplicar a un vector de n componentes y devuelve uno de m componentes.

6. Multiplicación matriz-matriz

La lógica es la misma, pero ahora procesamos varias columnas/entradas juntas. Para obtener cada posición del resultado, hacemos fila por columna.

$$\begin{bmatrix} 1 & 2 \\ 5 & 6 \end{bmatrix} \times \begin{bmatrix} 1 \cdot 5 + 2 \cdot 7 & 1 \cdot 6 + 2 \cdot 8 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 3 \cdot 5 + 4 \cdot 7 & 3 \cdot 6 + 4 \cdot 8 \end{bmatrix}$$

$$\text{Resultado} = \begin{bmatrix} 19 & 22 \\ 43 & 50 \end{bmatrix}$$

En IA esto permite procesar un lote completo de datos de manera eficiente. Si X contiene muchas entradas y W los pesos de una capa, una operación matricial puede calcular muchas salidas simultáneamente.

7. Rango: ¿cuánta información real hay?

El rango de una matriz indica cuántas filas o columnas **linealmente independientes** tiene. En lenguaje cotidiano: **cuántas direcciones de información diferentes conserva.**

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$$

La segunda fila es el doble de la primera. No aporta una dirección nueva, así que el rango es 1, no 2.

Si una capa tiene dos neuronas pero una aprende exactamente el doble de la otra, en cierto sentido estamos desaprovechando una neurona: las dos producen información redundante.

Rango máximo: conserva todas las dimensiones posibles. **Rango bajo:** comprime o pierde alguna dimensión.

8. Núcleo (kernel) e imagen

8.1 Núcleo

El núcleo es el conjunto de vectores que la matriz transforma en cero:

$$Ax = 0$$

Intuitivamente, son direcciones que la transformación 'borra'. Si existen vectores distintos de cero que terminan en cero, hay información de entrada que desaparece.

8.2 Imagen

La imagen es el conjunto de todas las salidas que la transformación puede producir. Su dimensión coincide con el rango.

Analogía: dominio = todo lo que puede entrar; núcleo = lo que la máquina borra; imagen = todo lo que la máquina puede producir.

9. Matrices especiales que aparecen en IA

9.1 Matriz simétrica

Una matriz cuadrada es simétrica cuando se ve igual al reflejarla sobre su diagonal principal:

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} \rightarrow A = A^T$$

Las matrices de covarianza son un ejemplo importante. El módulo las vincula con análisis estable, autovalores reales y autovectores ortogonales.

9.2 Matriz definida positiva

Es una matriz simétrica que cumple una propiedad que, en forma compacta, se escribe:

$$x^T A x > 0 \text{ para todo } x \neq 0$$

No necesitas memorizarla de entrada. La idea útil es que estas matrices aparecen cuando queremos representar funciones convexas, energía o distancias generalizadas. El material las relaciona con estabilidad, soluciones únicas y modelos gaussianos.

9.3 Matriz ortogonal

Sus columnas son unitarias y perpendiculares entre sí. Estas matrices preservan longitudes y ángulos, por lo que no deforman el espacio al rotarlo o reflejarlo.

$$Q^T Q = I$$

En IA son útiles cuando queremos transformaciones numéricamente estables o preservar geometría.

9.4 Matriz dispersa (sparse)

Es una matriz donde la mayoría de los valores son cero. Si hay millones de posibles conexiones pero solo unas pocas existen, guardar todos los ceros sería un desperdicio.

Son comunes en grafos, NLP y sistemas de recomendación. Su ventaja práctica es ahorrar memoria y cálculo.

10. Autovalores y autovectores: intuición

Aunque el desarrollo formal es más avanzado, el glosario del módulo los usa como conceptos importantes.

Un **autovector** es una dirección especial que, al aplicar una matriz, no cambia de dirección. Solo se estira, se comprime o eventualmente cambia de sentido. El **autovalor** indica cuánto.

$$A v = \lambda v$$

v es el autovector y λ el autovalor. En PCA, estas ideas permiten encontrar direcciones donde los datos varían más.

Imagen mental: la matriz deforma una hoja de goma. Casi todas las flechas cambian de dirección; algunas direcciones especiales permanecen alineadas. Esas son las direcciones de los autovectores.

11. Determinantes

11.1 ¿Qué significa el determinante?

El determinante es un número asociado a una matriz cuadrada. Para este módulo conviene recordar tres interpretaciones:

- Si $\det(A) \neq 0$, la matriz es invertible.
- Si $\det(A) = 0$, la transformación pierde al menos una dimensión y no puede deshacerse de forma única.
- Su valor absoluto indica cómo cambia área o volumen la transformación.

11.2 Determinante de 2 x 2

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \quad \det(A) = a*d - b*c$$

Ejemplo:

$$A = \begin{bmatrix} 2 & 3 \\ 1 & 4 \end{bmatrix} \quad \det(A) = 2*4 - 3*1 = 5$$

Como $5 \neq 0$, A es invertible.

11.3 Ejemplo con pérdida de información

$$B = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \quad \det(B) = 1*4 - 2*2 = 0$$

B no es invertible. Esto coincide con lo que ya vimos: la segunda fila es el doble de la primera, por lo que hay dependencia lineal y rango bajo.

Conexión clave: en una matriz cuadrada, rango máximo, determinante distinto de cero e invertibilidad son distintas formas de describir una misma situación favorable: no se colapsó ninguna dimensión.

11.4 ¿Y para 3 x 3 o matrices grandes?

El material presenta tres caminos: Regla de Sarrus para 3 x 3, expansión por cofactores para n x n y reducción por filas. Sarrus es rápida pero solo sirve para 3 x 3. Cofactores es general pero se vuelve costoso. La reducción por filas es más práctica para matrices grandes y se relaciona con los métodos usados por software numérico.

Para retomar la materia, primero asegurate de dominar bien 2 x 2 y la interpretación del resultado. Después practica Sarrus y reducción por filas.

12. Reducción por filas: qué tenés que recordar

La idea es transformar una matriz hasta hacerla triangular. En una matriz triangular, el determinante es el producto de la diagonal.

- Intercambiar dos filas cambia el signo del determinante.
- Multiplicar una fila por k multiplica el determinante por k.
- Sumar a una fila un múltiplo de otra no cambia el determinante.

13. Cómo se conecta todo

Este es el recorrido conceptual más importante del módulo:

DATOS -> VECTORES -> MATRICES -> TRANSFORMACIONES -> ¿SE CONSERVA INFORMACIÓN?

Los vectores representan datos. Las matrices transforman esos vectores. La independencia lineal nos dice si hay redundancia. El rango mide cuántas direcciones independientes sobreviven. El núcleo muestra qué información se destruye. La imagen describe qué salidas son posibles. El determinante, en matrices cuadradas, ayuda a saber si la transformación puede invertirse.

Las matrices especiales agregan propiedades útiles: simetría, estabilidad, preservación de geometría o eficiencia de almacenamiento.

14. Ejemplo completo, bien bajado a tierra

Supongamos un modelo que usa dos características de una persona:

$$x = [\text{edad_normalizada}, \text{compras_mensuales}]$$

Tenemos una transformación:

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}$$

Para $x = [3, 2]$:

$$Ax = [2 \cdot 3 + 1 \cdot 2, 1 \cdot 3 + 1 \cdot 2] = [8, 5]$$

La matriz mezcló las dos características y produjo dos características nuevas. Ahora calculamos:

$$\det(A) = 2 \cdot 1 - 1 \cdot 1 = 1$$

Como el determinante no es cero, la transformación es invertible: en principio, no colapsó las dos dimensiones en una sola.

Si en cambio usáramos:

$$B = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$$

$\det(B)=0$. Las filas son dependientes, el rango es menor que 2 y parte de la información se pierde. Diferentes entradas pueden terminar generando la misma salida.

15. Lo que deberías saber para las actividades

Según las actividades del módulo, conviene que puedas hacer y explicar estas cosas:

- Reconocer un vector y explicar qué pueden representar sus componentes.
- Detectar dependencia lineal sencilla, especialmente cuando un vector/fila es múltiplo de otro.
- Multiplicar una matriz por un vector y entender qué representa el resultado.
- Interpretar una matriz como transformación lineal.
- Determinar conceptualmente si una matriz tiene rango máximo o bajo.
- Explicar qué significa perder información.

- Reconocer una matriz simétrica.
- Entender qué representan autovalores y autovectores a nivel conceptual.
- Reconocer una matriz dispersa y explicar por qué ahorra recursos.
- Calcular determinantes, decidir si una matriz es invertible y relacionarlo con pérdida de dimensionalidad.

16. Ejercicios de recuperación

Ejercicio 1 - Vectores

Dados $u=[1,2]$ y $v=[3,4]$, calculá $u+v$ y $2u$.

Respuesta: $u+v=[4,6]$. $2u=[2,4]$.

Ejercicio 2 - Dependencia

¿Son independientes $[1,3]$ y $[2,6]$?

Respuesta: no. El segundo vector es 2 veces el primero. Hay redundancia.

Ejercicio 3 - Matriz por vector

$A=[[1,2],[3,1]]$ y $x=[2,4]$. Calculá Ax .

Respuesta: primera componente = $1*2+2*4=10$. Segunda = $3*2+1*4=10$. Resultado $[10,10]$.

Ejercicio 4 - Determinante

$A=[[3,1],[2,4]]$. ¿Es invertible?

Respuesta: $\det(A)=3*4-1*2=10$. Como $10 \neq 0$, sí es invertible.

Ejercicio 5 - Pérdida de información

$B=[[2,4],[1,2]]$. ¿Qué observás?

Respuesta: una fila es múltiplo de la otra. $\det(B)=0$, el rango no es máximo y la transformación pierde una dimensión.

Ejercicio 6 - Matriz simétrica

¿ $[[4,2],[2,7]]$ es simétrica?

Respuesta: sí. Los valores fuera de la diagonal se reflejan: $a_{12}=a_{21}=2$.

17. Chuleta de fórmulas

Tema	Fórmula / regla
Norma 2D	$\ x\ = \sqrt{x_1^2 + x_2^2}$
Producto punto	$x \cdot y = x_1 \cdot y_1 + x_2 \cdot y_2 + \dots$
Transformación	$y = Ax$
Capa densa	$z = Wx + b$
Núcleo	$Ax = 0$
Imagen	Todas las salidas posibles Ax
Determinante 2x2	$ad - bc$
Invertible	$\det(A) \neq 0$ (matriz cuadrada)
Ortogonal	$Q^T Q = I$

Tema	Fórmula / regla
Autovector	$Av = \lambda v$

18. Qué memorizar y qué entender

Entender sí o sí	Memorizar/practicar
Vector = representación numérica de datos	Suma y producto por escalar
Matriz = transformación / colección de datos	Multiplicación matriz-vector
Independencia = ausencia de redundancia	Determinante 2x2
Rango = información/dimensiones preservadas	Reglas básicas de operaciones por filas
Núcleo = direcciones que se pierden	Reconocer simétrica, ortogonal y sparse
$\det=0$ implica problema de invertibilidad	Sarrus si la cátedra lo exige
Autovector = dirección especial; autovalor = escala	Notación básica A^T , I , R^n

Orden recomendado para estudiar: 1) vectores, 2) combinación e independencia lineal, 3) matrices y multiplicación, 4) rango/núcleo/imagen, 5) determinante e invertibilidad, 6) matrices especiales, 7) autovalores/autovectores. No intentes memorizar todo de una sola pasada.

Este apunte fue elaborado exclusivamente a partir del contenido y las actividades del Módulo 1 (págs. 17-54) del material aportado por el estudiante, reorganizado con lenguaje introductorio y ejemplos de repaso.