

Caja de Herramientas Humanísticas

GIFT (Grupo de investigación de Inteligencia Artificial, Filosofía y Tecnología)

Dra. Karina Pedace

Dr. Tomás Balmaceda

Dra. Diana Pérez

Dr. Diego Lawler

Prof. Maximiliano Zeller Echenique

GuIA.ai

En colaboración con:

fAir LAC

BID
Banco Interamericano
de Desarrollo

CeTys
Universidad Tecnológica de
Yucatán

PARTE 1

- Apuntes para la reflexión filosófica sobre la inteligencia artificial
- Algunas reflexiones filosóficas sobre el diseño de artefactos y de sistemas tecnológicos

En este trabajo presentamos un marco general para pensar la inteligencia artificial y sus aplicaciones desde una perspectiva humanística. El propósito del trabajo es analizar estos desarrollos, llamando la atención sobre el medio social y humano en el que surgen y se aplican estas nuevas tecnologías de la información, así como las implicaciones éticas que plantean estos novedosos desarrollos. El trabajo está dividido en dos partes.

En la primera parte, presentamos una serie de reflexiones filosóficas tendientes a aclarar la naturaleza de la inteligencia artificial, su relación con la inteligencia humana, así como los diversos tipos de desarrollos que se han producido en este ámbito y las preguntas y desafíos que plantean. Para entender más cabalmente las implicancias éticas que el desarrollo de estas tecnologías supone, presentamos también un marco filosófico general acerca del diseño de artefactos y de sistemas tecnológicos en el que se ponen de manifiesto las diversas acciones y prácticas humanas allí empleadas, así como los diferentes niveles de implicaciones éticas anidadas en estos desarrollos.


En la segunda parte, nos detenemos en algunos de los problemas éticos más discutidos en la literatura reciente, y que mayor impacto tienen en el desarrollo de tecnologías con IA: el problema de los sesgos, la cuestión de la privacidad de los datos, la transparencia de los sistemas, la asignación de responsabilidad en el diseño y en el uso de estos sistemas, la seguridad, y, finalmente, su relación con el bienestar, con los derechos humanos y con la sociedad humana en su conjunto.

PARTE 2

- Sesgos
- Privacidad
- Transparencia
- Responsabilidad
- Seguridad
- Bienestar, derechos humanos, política y tecnología

PARTE 1

■ Apuntes para la reflexión filosófica sobre la inteligencia artificial.



Desde la Antigua Grecia, se ha sostenido la idea de que los seres humanos nos caracterizamos por ser animales con *logos*, es decir, con razón, con palabra. Nos consideramos a nosotros mismos como “animales racionales” y entendemos que lo que nos distingue como especie biológica del resto de los animales y de las máquinas (autómatas, robots) es nuestra inteligencia, nuestra racionalidad y nuestra palabra. Parece haber problemas que solo los humanos podemos resolver (teoremas matemáticos, juegos como el ajedrez, o el Go), y conductas que solo los seres humanos podemos realizar (escribir un poema, establecer un diálogo con otro ser humano, sufrir por amor). Tanto nuestra inteligencia teórica (nuestra capacidad para entender el mundo y acumular conocimiento) como nuestras acciones (nuestra capacidad para resolver los desafíos prácticos que el mundo y la sociedad humana nos plantean) se entienden como el resultado de nuestra capacidad de resolver problemas racionalmente.


A mediados del siglo XX nuestra autoimagen humana fue puesta en duda por el matemático y criptógrafo británico Alan Turing (1950) en el provocativo artículo “¿Pueden pensar las máquinas?”. En este trabajo, Turing, haciéndose eco de los desarrollos en lógica y en ciencias de la computación de la época, a los que él mismo contribuyó de manera notable, desafió la idea cartesiana que desterraba a las máquinas de la posibilidad de entablar un diálogo como si fueran un humano. El “juego de la imitación” –tal como Turing lo concibió– permitiría a una máquina (un autómata programado para entablar un diálogo con un humano) “engañar” al humano, confundiéndolo con otro humano. Así, la inteligencia artificial surge bajo la premisa de construir un artefacto capaz de ejecutar conductas inteligentes indistinguibles de los patrones de conducta humana.

Este proyecto puede leerse de una manera menos ambiciosa o estrecha (*narrow AI*) si se trata de buscar sistemas que realicen una tarea particular de forma inteligente. Alternativamente, puede ser visto de una manera más ambiciosa o general (*general AI*), si se busca crear un artefacto que en todos los aspectos actúe (y piense) de una manera humana (como los replicantes de la película *Blade Runner*). Claramente este segundo proyecto sigue estando relegado a la ciencia ficción, así que en lo que sigue en este trabajo nos centraremos en el proyecto más acotado, consistente en replicar artificialmente ciertas específicas capacidades humanas.

Si nos detenemos a reflexionar sobre qué es lo que está involucrado en la noción de “conducta inteligente”, rápidamente notaremos que encierra una idea normativa. En efecto, qué cuenta como conducta inteligente o racional depende no solo de la conducta efectivamente realizada por las personas, sino de que esas conductas estén respaldadas por principios que indiquen que se trata de la mejor conducta, o de la más apropiada para la ocasión (Aristóteles, 1973; 2010; Raz, 1979; Pedace, 2017). La conducta que un individuo despliega es inteligente a la luz de ciertas razones que lo llevaron a actuar como lo hizo: comer un plato de raviolos a los cuatro quesos puede ser racional si lo hacemos porque hace mucho que no comemos, porque tenemos hambre, porque queremos seguir vivos, y porque nos gustan la pasta y el queso, pero también puede ser irracional, o poco acertado, si ya comimos un asado, si tenemos sobrepeso, presión elevada, alta glucosa, etc. Paralelamente, las creencias de una persona pueden ser racionales si están fundadas en evidencias comprobables, si se siguen lógicamente de otras creencias anteriores bien fundadas, o irracionales si simplemente nos hacemos eco de los chismes de un vecino, o de las *fake news* que aparecieron en nuestras redes sociales.

Las reflexiones relativas a qué considerar una conducta inteligente y qué no suponen establecer parámetros de racionalidad que rápidamente nos llevan a contemplar una posibilidad novedosa de la que la idea de una inteligencia artificial se nutre. Parece que no solo se podría construir un artefacto capaz de imitar la conducta humana inteligente efectiva, sino que también se podría construir una máquina más perfecta que cualquier humano de carne y hueso, una máquina que podría resolver los problemas humanos mejor que los propios humanos, sin equivocarse (esto es, sin desviarse jamás de las normas de racionalidad). Crear máquinas que realicen alguna tarea humana de una manera que supere al mejor humano conocido ha sido un motor de la inteligencia artificial, proyecto que coronó a Deep Blue como campeón mundial de ajedrez al vencer a Kasparov, o a AlphaGo al ganarle al campeón mundial de Go, Lee Sedol.





Finalmente, podemos encontrar en la literatura reciente una idea adicional y aún más provocativa. Hay buenas razones para pensar que la cognición/inteligencia humana no solo depende de nuestra dotación biológica sino también de los nichos culturales que el ser humano ha sabido construir, creando artefactos como el alfabeto y los teléfonos móviles para potenciar nuestras capacidades cognitivas (Clark y Chalmers 1998; Clark 1997; 2008). La creación del alfabeto, la notación arábiga de los números naturales y la creación de lenguajes artificiales en general para la lógica, la aritmética y la computación, son herramientas que, acopladas a nuestra dotación biológica, han permitido a los seres humanos realizar proezas inimaginables hace 40.000 años (¡o incluso hace 150!). Podemos entonces preguntarnos si no será posible generar con el desarrollo de la IA un nuevo nicho cultural que permita que los seres humanos cambien de una manera drástica (aún no imaginada) sus capacidades cognitivas. ¿No estaremos ahora en una situación similar a la que estábamos antes de la existencia del alfabeto? El desafío de combinar estos desarrollos de IA con las capacidades humanas existentes, potenciando las capacidades humanas (*human enhancement*), nos permite pensar que tal vez estemos ante la posibilidad de generar seres "súperhumanos" o "transhumanos", es decir, seres que rompan las barreras de lo que la dotación biológica junto con el moldeado cultural actualmente existente nos permiten hacer.

Ejercicio de reflexión



¿Existe algo peculiarmente humano?

No son pocos los que se sienten intimidados y perturbados por la posibilidad de aumentar nuestras habilidades humanas o de crear nuevas a partir de la tecnología. La raíz de esta incomodidad parece ser la idea de que existe algo así como una "naturaleza humana" que no puede ser alterada o contaminada... ¿qué piensa usted? ¿qué es lo que nos vuelve hombres y mujeres y nos diferencia de los demás animales y objetos del mundo? Como mencionamos al comienzo de esta sección, por siglos se creyó que nuestra capacidad de razonamiento y nuestro lenguaje nos volvían únicos. Ahora que las máquinas pueden disputarnos ese logro y que existen definiciones de inteligencia que abren el camino a que consideremos a varios animales como inteligentes... ¿existe algo propiamente humano y que ningún otro ser comparta?

Podemos ver en esta breve presentación que hay varios proyectos diferentes coexistiendo en el ámbito de la IA, y no todos confluyen en el mismo lugar. En efecto, hay al menos tres propósitos diferentes alrededor de la construcción de sistemas de IA.

Proyectos en IA



- 1** Generar sistemas que actúen y piensen como efectivamente piensan hoy los seres humanos (con sus defectos y virtudes).
- 2** Generar sistemas que realicen actividades como un humano ideal lo haría, esto es, como lo haría un humano perfecto, que jamás cometiera errores, que fuera máximamente racional, etc.
- 3** Generar sistemas que mejoren las capacidades existentes, creando sistemas compuestos por humanos + máquinas que fueran capaces de hacer cosas más allá de la perfección ideal que concebimos hoy.

Todos estos proyectos suponen una serie de principios normativos ocultos. Por un lado, el proyecto de generación de artefactos, que actúan y resuelven problemas tal como lo hacen los seres humanos efectivamente existentes, heredan los tics, los sesgos (biases) y los defectos de los humanos. Un sistema que quisiera actuar como un humano debería equivocarse de vez en cuando, debería tardar más en responder una pregunta compleja que una simple, tendría sesgos al juzgar a los seres humanos, prejuicios, etc. En caso contrario, sería muy fácil darnos cuenta de que nos contesta una máquina y no un ser humano.

Parece, sin embargo, que la promesa interesante de la IA consiste en generar sistemas que permitan mejorar las sociedades humanas, esto es que actúen como un ser humano perfecto, y no exactamente como nosotros. Si queremos mejorar la justicia, por ejemplo, deberíamos crear un sistema de IA que sea una jueza perfecta, que solo falle administrando justicia de la manera correcta; o una médica perfecta, que jamás se equivoque en sus diagnósticos, si queremos mejorar la práctica médica actual. Obviamente, estos sistemas ideales heredan

los cánones normativos de su idealidad. Si un sistema es lógicamente racional, debe responder apelando a razonamientos lógicamente válidos, debe actuar de manera de maximizar la utilidad de sus acciones, etc. Si queremos construir una jueza perfecta, deberíamos tener en claro cuál es exactamente el fallo más justo en cada caso... pero esto parece algo bastante alejado de nuestras posibilidades humanas: en última instancia cuál es la mejor manera de administrar justicia es una cuestión en la que los seres humanos probablemente nunca lleguemos a ponernos de acuerdo (tampoco, por desgracia, hay diagnósticos perfectos: nos falta todavía demasiado conocimiento del cuerpo humano y de su entorno psicosocial).

Finalmente, si queremos “mejorar” a los seres humanos de manera tal que superen las posibilidades cognitivas de los humanos actuales, debemos tener en claro qué es mejor que qué y en qué respecto. Volvernos súperhumanos supone valorar como mejor o peor una cosa que otra o una situación antes que otra y no siempre es evidente qué es una mejor vida humana: vivir muchos años sin ciertos placeres o menos años con más placeres; combatir por nuestra patria en el frente de batalla o desertar y escondernos de la guerra, etc. (y probablemente, otra vez, no todos los seres humanos tengamos la misma respuesta a esta pregunta).

Ejercicio de reflexión

¿Qué es una “buena vida”?

La pregunta por “qué es una buena vida” es casi tan antigua como la filosofía: aparece ya en los primeros autores que conocemos y se mantiene abierta hasta el día de hoy, pues no parece existir una única respuesta ni una opinión que deje satisfechos a todos. A pesar de su longevidad, no deja de ser una temática de candente actualidad: qué vamos a considerar una buena vida será central a la hora de repensar nuestras decisiones éticas en materia de inteligencia artificial.

Como vemos, los desarrollos de sistemas de IA plantean una infinidad de preguntas éticas y, más generalmente, preguntas filosóficas, tanto atinentes a las consecuencias prácticas que podrían tener en las vidas humanas estos desarrollos, como a preguntas teóricas acerca de en qué medida alteran la autoimagen que tenemos los humanos de nosotros mismos. Nuestro lugar privilegiado en el mundo ha quedado puesto en cuestión.

Veamos dónde estamos parados hoy (2019) con los desarrollos de IA y enumeremos **algunos de los logros alcanzados que constituyen nuestro nicho humano actual:**


- 
- Podemos dialogar (chatear) con máquinas –y lo hacemos habitualmente en los sitios de Internet donde los chatbots nos ofrecen servicios, incluyendo “servicios” médicos, consultorías legales, etc.–.
 - Podemos contar con traducciones automáticas (bastante razonables) de porciones de un lenguaje natural a otro lenguaje natural.
 - Hay máquinas que reconocen rostros y huellas digitales (en las fronteras de los países, en las cámaras de seguridad en la calle y en medios de transporte público, en ciertos edificios, a la hora de desbloquear la pantalla de nuestro teléfono...).
 - Hay máquinas que reconocen y etiquetan objetos del entorno.
 - Hay vehículos autónomos (i.e. que permiten trasladar a un humano de un lugar a otro sin que el humano “maneje”).
 - También hay armas que funcionan autónomamente (i.e. que “deciden” sin intervención humana qué objetivo alcanzar con sus misiles).
 - Hay consultoras que ofrecen servicios de identificación de individuos que sean blancos accesibles para la manipulación política o comercial.
 - Casi todas las redes sociales y plataformas de streaming nos ofrecen publicidad, noticias, nos brindan oportunidades de trabajo y servicios personalizados, de acuerdo a nuestros intereses y preferencias.
 - Existen máquinas que juegan complejos juegos humanos mejor que el campeón mundial de cada especialidad: Deep Blue derrotó a Garry Kasparov y AlphaGo derrotó a Lee Sedol.
 - Podemos navegar en las ciudades sin más ayuda que la de nuestro móvil, conectado a Internet.
 - Hay sistemas que prueban teoremas de la lógica proposicional (y sabemos que no es posible hacer lo mismo con la aritmética).
 - Hay infinidad de máquinas automáticas que reemplazan humanos en las fábricas y en las empresas de servicios.
 - Existen semáforos que gracias a la IA regulan el flujo del tránsito de manera eficiente.
 - Contamos con apps que prometen ayudarnos a encontrar a nuestra pareja ideal.

- Tenemos correctores automáticos de nuestros mensajes, respuestas automáticas de nuestros mails, etc.
- Hay máquinas (Siri, Alexa) que reconocen nuestras voces, entienden nuestros pedidos y nos “obedecen” prendiendo luces, buscando datos en nuestra agenda, redactando mails por nosotros, etc.


No todos estos desarrollos de IA tienen los mismos algoritmos detrás, es decir, no todos ellos responden a un único modelo matemático. No vamos a detenernos en detalles, pero necesitamos mencionar algunas cuestiones generales para hacer explícitas algunas de las herramientas que proponemos utilizar para pensar humanísticamente la IA.

Los primeros “programas” de IA estaban basados en la idea de “máquina de Turing”. Como sabemos, se trata de un algoritmo (una máquina ideal/lógica, no una máquina efectiva material) muy sencillo que incluye una serie de órdenes, codificadas en una tabla donde se especifican todas las funciones del sistema, o las reglas de transición. Así, una máquina de Turing es capaz de ejecutar una multiplicidad de tareas en la medida en que puedan aplicarse serialmente estas transiciones de un estado de la máquina a otro. En estos modelos podemos apreciar que las reglas que sigue el sistema reproducen cánones normativos acerca de qué se debe hacer ante cada información o situación dada, aplicando serial y recursivamente las reglas para llegar a una respuesta del problema planteado. Estas máquinas seriales muy potentes para realizar ciertas tareas tienen serias limitaciones para otras (ya desde sus inicios los famosos problemas del marco y de la explosión computacional señalaron restricciones a este modelo).

Pero el desarrollo de la IA se ha alejado rápidamente de estas máquinas seriales. La mayor parte de los desarrollos de IA involucrados en los ejemplos ya mencionados están basados en otro tipo de algoritmos que permiten extraer patrones a partir de grandes cantidades de datos (denominados usualmente “*machine learning*” o “aprendizaje automatizado”). Estos mecanismos parten de una serie más o menos grande y más o menos estructurada de datos (“experiencias pasadas”), a partir de los cuales descubren patrones preexistentes en ellos, lo que les permite predecir qué va a ocurrir ante la aparición de un nuevo dato, o realizar tareas varias en función de la “experiencia” pasada acumulada, del “aprendizaje” realizado. El proceso de aprendizaje varía, puede ser guiado o automático (es decir, puede haber humanos que corrijan el avance en el aprendizaje –maestros– o puede aprender la máquina interactuando consigo



misma), activo o pasivo (esto es, puede darse en medio de una constante interacción con el entorno que retroalimenta el proceso de aprendizaje, o puede ser puramente observacional, i.e. la máquina adquiere información antes de empezar a actuar), puede ser orientado a un fin (que la máquina aprenda a realizar una tarea específica) o simplemente que encuentre patrones inesperados entre los datos preexistentes (minería de datos –*data mining*–). Los algoritmos pueden ser variados (Shalev-Shwartz y Ben-David, 2014) pero, en todos los casos, se trata de “educar” un programa para generar un modelo de un cierto dominio de la realidad, que le permitirá al sistema realizar las acciones apropiadas.



Sin entrar en excesivos tecnicismos, siguiendo a Mittelstadt et al. (2016), cabe advertir que hay al menos dos acepciones de “algoritmo”:

- Desde su caracterización formal es considerado un constructo matemático a los efectos de lograr un propósito dado bajo ciertos suministros.
- Desde su empleo concreto alude a qué debe ser implementado y ejecutado para llevar a cabo una acción y obtener ciertos efectos.


Un algoritmo completamente configurado incorpora, pues, la estructura abstracta matemática que se ha implementado en un sistema para el análisis de tareas en un dominio particular. En lo que sigue, cuando hablemos de “algoritmos”, estaremos haciendo referencia a este segundo sentido, esto es, a un algoritmo realizado en un artefacto concreto, que forma parte de nuestro mundo material. La reflexión ética en torno a los algoritmos parece requerir crucialmente que atendamos a cómo son implementados y ejecutados en programas de computación, en software y en sistemas de información. En particular, la escena actual está dominada por una clase particular de algoritmos que toman decisiones determinando, por ejemplo, la mejor acción a llevar a cabo en una situación dada, la mejor interpretación de los datos, etc. Tales algoritmos aumentan o reemplazan los análisis y las tomas de decisiones por parte de seres humanos, a menudo debido al alcance o a la escala de los datos y de las reglas involucradas. No obstante, los algoritmos nos interpelan éticamente no solo en virtud de la escala de análisis y de la complejidad en la toma de decisión; sino que la opacidad del trabajo que efectúan y su impacto en nuestras vidas es también motivo de especial reflexión.

Tal como dijimos, los sistemas de aprendizaje automatizado se caracterizan por la capacidad de definir o de modificar reglas de toma de decisión de manera autónoma. Un algoritmo de machine learning aplicado a tareas de clasificación, por ejemplo, consiste típicamente en un aprendiz que produce un clasificador con la intención de desarrollar clases que se puedan generalizar más allá de los datos de entrenamiento

(Domingos, 2012). Como señalamos, el aprendizaje puede ser supervisado (vía inputs etiquetados a mano) o no supervisado (el algoritmo mismo define los modelos que mejor encajan para dotar de sentido al conjunto de inputs). En ambos casos, el algoritmo define las reglas de toma de decisión para manejar nuevos inputs. En consecuencia, el operador humano no necesita comprender la razón subyacente a las reglas de toma de decisión producidas por el algoritmo (Matthias, 2004). Sin embargo, es un desideratum de los diseñadores de IA que la transparencia no desaparezca completamente en este proceso, dado que los algoritmos que son poco predecibles o poco explicables son difíciles de controlar, de monitorear o de corregir (Tutt, 2016). Como señalan Mittelstadt et al. (2016), la transparencia es tratada a menudo ingenuamente como una panacea para las cuestiones éticas que emergen a partir de las nuevas tecnologías.

De esta manera, vemos que los datos de los que parte el sistema son clave para que el sistema aprenda, y que lo aprendido está en una relación directa con los datos que le proporcionamos de partida y con las correcciones que se van haciendo a lo largo del proceso de aprendizaje. Así, si el sistema parte de un conjunto pasado de fallos judiciales injustos, generará nuevos fallos injustos; si parte de datos sesgados (por ejemplo de datos acerca de cuáles de hecho son las preferencias de varones y mujeres en nuestra actual sociedad patriarcal) generará ofertas publicitarias sesgadas reforzando el sesgo original: ofrecerá escobas a las mujeres y autos a los varones. También nos mostrará más frecuentemente las opiniones y las fotos de los amigos a los cuales les pusimos un “like”, que las de amigos a los que nunca les comentamos nada.... Y reforzará nuestras antiguas opiniones mostrándonos las opiniones de quienes concuerdan con nosotros (sesgo de confirmación).

Los desarrollos –como los ya ejemplificados– están muy extendidos en nuestras sociedades actuales y tanto su desarrollo como su uso plantean una infinidad de cuestiones éticas, muchas de ellas novedosas y urgentes. Es notable la velocidad con la que ciertos sistemas y aplicaciones que involucran IA se suceden y transforman nuestra vida cotidiana. En este trabajo ofrecemos una serie de herramientas provenientes de la filosofía (y de las humanidades en general) con vistas a generar un pensamiento crítico, éticamente informado, en aquellos que de alguna u otra manera tengan que tomar decisiones que conciernen al desarrollo y/o al uso de IA: diseñadores, desarrolladores, empresas, gestores de políticas públicas, incluso padres y madres que tienen que decidir qué permiten y qué evitan que hagan sus hijos y, por qué no, usuarios en general, ciudadanos que vivimos en este nuevo nicho cultural atravesado de IA. Pero antes tenemos que comprender cabalmente el proceso de generación de nuevos sistemas tecnológicos y su inserción en las sociedades humanas.



■ Algunas reflexiones filosóficas sobre el diseño de artefactos y de sistemas tecnológicos

Hay tres preguntas fundamentales para abordar el diseño tecnológico:


La **primera** es la pregunta por la agencia: ¿quién o qué diseña?

Una **segunda** pregunta corresponde al método de diseño: ¿cómo se diseña?

Una **tercera** pregunta es de carácter básico y hace al producto del diseño: ¿qué es un objeto o un sistema diseñado?

La respuesta a la primera pregunta es, aparentemente, simple: el agente de diseño es un diseñador humano, racional, deliberativo y previsor. En cuanto a la segunda pregunta hay que señalar que el método de diseño se basa en procedimientos de toma de decisiones que incluyen la previsión de los usos prácticos de la entidad diseñada y sus consecuencias. Por último, el resultado del proceso de diseño es un artefacto o un sistema artificial que cumple la función de mediación entre el ser humano y su entorno. Una vez que se decide qué diseño será realizado, se produce el artefacto o sistema tecnológico y estos pasan a formar parte de nuestro entorno, modelando nuestra vida cotidiana.

Ahora bien, en la práctica humana de diseñar y de producir un artefacto conviven distintas dimensiones que involucran cuestiones éticas relevantes. Veamos cada una de ellas.



¿Qué es diseñar un artefacto o un sistema tecnológico? Diseñar es una actividad humana que consiste en realizar una operación cognitivo-conceptual por medio de la cual se crean modelos de estructuras materiales y mecanismos que realicen funciones propuestas por los diseñadores para resolver una situación que está planteada como un problema.

Esta operación cognitivo-conceptual comprende representaciones de opciones de estructuras materiales y de mecanismos, así como de cursos de acción, deliberación sobre esos cursos de acción, sobre las estructuras materiales y sobre los mecanismos, establecimiento de ponderaciones y elección de unos en desmedro de otros de acuerdo con un conjunto de valores y de objetivos previamente formulados.

En el proceso de diseño, frente a la representación de cualquier artefacto o sistema tecnológico, hay un diseño alternativo posible. Por eso, el diseño es básicamente un ámbito deliberativo que se cierra con una decisión sobre qué diseño habrá de adoptarse y realizarse efectiva y materialmente. Por consiguiente, cuando voluntariamente se elije realizar un diseño y no otro, los diseñadores son responsables de esa elección. Hay una capacidad, la de crear diseños de artefactos y sistemas tecnológicos, y una obligación asociada a esa capacidad, la de hacerse cargo de la elección del diseño y de las consecuencias de su introducción en el entorno humano.

La elección del diseño de un artefacto o de un proceso tecnológico para su producción e introducción en el mundo real es una respuesta a la pregunta por cuál es la solución adecuada al problema determinado.

Ejercicio de reflexión



¿Qué significa una “solución adecuada”?

¿Cómo se establece que una solución es una “solución adecuada”? Esta pregunta es importante porque conduce a interrogarse acerca de cómo se toman las decisiones tecnológicas, en función de qué dimensiones intervienen en la creación de un artefacto o sistema tecnológico, y cómo se las valora en la decisión tomada en relación con los problemas que resuelven y con las modificaciones que introducen en el mundo.

En el contexto deliberativo del diseño intervienen valoraciones intrínsecas y extrínsecas. Las valoraciones intrínsecas son propiamente tecnológicas y las valoraciones extrínsecas conciernen a los propósitos humanos incorporados en los artefactos y en los sistemas tecnológicos.





Figura 1. Diseño, decisiones y contextos valorativos (adaptación de Broncano, 2000)

- Las valoraciones intrínsecas están vinculadas a la eficacia y a la eficiencia de los artefactos y de los sistemas tecnológicos; a que funcionen y a que lo hagan con el menor coste posible de recursos (materiales, económicos, etc.) y de consecuencias no queridas (matar moscas a cañonazos es efectivo, pero tiene una multitud de consecuencias no queridas).
- Las valoraciones extrínsecas están relacionadas con lo que significa que el artefacto o el sistema tecnológico sea una solución adecuada a un problema planteado. Esto no depende solamente de que el artefacto o sistema sea eficaz y eficiente; por el contrario, depende de cómo se inserta en el entorno de las personas y de una sociedad determinada, y de la valoración que hacen los distintos actores sociales (diseñadores, productores, usuarios, etc.); una valoración que es contextualizada, donde cuentan más los valores relacionados con cómo se quiere vivir que los aspectos estrictamente tecnológicos. Esta valoración está fuertemente asociada a las particularidades de los grupos sociales así como a sus identidades prácticas y, por tanto, a sus fines, intereses y puntos de vista sobre el mundo. Por ejemplo, un grupo social impulsado por una fuerte conciencia y compromiso ecológico puede rechazar la instalación de una central nuclear en su región, a pesar de que esta sea la opción tecnológicamente más adecuada para resolver el suministro de energía en esas condiciones socioeconómicas y ambientales.

Al deslindar estos dos tipos de valoraciones en juego, se torna evidente que la solución técnica, relativa a las valoraciones intrínsecas, no es todo lo que se requiere explicar. Ese es el viejo sueño positivista de la neutralidad, que supone que es posible deslindar tajantemente valores epistémicos, como la eficacia, la verdad, etc., de valores éticos profundos, tales como los relacionados con qué vamos a entender, por ejemplo, por el ideal de un “florecimiento humano”. En efecto, lo meramente intrínseco no resuelve las cuestiones extrínsecas vinculadas con cómo queremos vivir. Así, resulta evidente que la tecnología requiere de la reflexión ética. En este trabajo nos centramos en las cuestiones éticas que plantea, en particular, el desarrollo de sistemas tecnológicos que involucran desarrollos de IA. Presentaremos a continuación las cuestiones éticas más debatidas ahora explicitadas dentro del marco humanístico propuesto hasta aquí. Nuestra intención es proveer al lector de una “caja herramientas humanísticas” para re-pensar la IA y los múltiples desafíos ante los que nos ubica.



PARTE 2

■ Sesgos

Tal como hemos visto, los algoritmos están cargados de valores. Los parámetros operacionales son especificados por los desarrolladores y son configurados por los usuarios que tienen en mente ciertos resultados deseados, que privilegian algunos valores e intereses por sobre otros. Sin embargo, la operación dentro de los parámetros aceptados no garantiza que la conducta resultante sea éticamente aceptable. Esto se advierte, por ejemplo, en algoritmos que arman perfiles que discriminan a distintos individuos y/o a grupos sociales, aun cuando no sea esta la intención de los diseñadores.

Cuando los algoritmos extraen conclusiones a partir de datos, los procesan mediante inferencias estadísticas o técnicas de aprendizaje automatizado que conllevan la producción de conocimiento probable (e inevitablemente incierto; de hecho, hay teorías específicas que se ocupan de caracterizar y de cuantificar esta incerteza). Esto nos ubica ante el reconocimiento de ciertas limitaciones epistémicas. En este sentido, se imponen algunas reflexiones en torno a la evidencia que utilizamos a la hora de realizar estos desarrollos y aplicaciones (cf. Mittelstadt et al., 2016).

Los algoritmos procesan datos y están, por tanto, sujetos a la restricción de que el output nunca puede exceder al input. Mientras que la teoría matemática de la comunicación de Shannon ofrece una explicación formalmente precisa de este hecho, el slogan informal “garbage in, garbage out” permite captar de una manera bastante más intuitiva qué es lo que está en juego acá: las conclusiones solo pueden ser fiables en función de los datos en los cuales están basadas. De esta suerte, si la base de datos está viciada, conducirá a resultados sesgados y, en ocasiones, injustos e inequitativos. Aquí convergen, por tanto, cuestiones epistémicas y valorativas.

Más aún, si asumimos que hay una carga inevitablemente normativa en las tecnologías de la información en general y en el desarrollo de algoritmos en particular (e.g. Newell y Marabelli, 2015), parece que los algoritmos inexorablemente conducen a decisiones sesgadas. El diseño y la funcionalidad de un algoritmo reflejan los valores de su diseñador y de sus usos pretendidos. Como adelantamos ya, el desarrollo no es neutral: no hay una elección objetivamente correcta en ninguna instancia del desarrollo, sino muchas posibles elecciones (Johnson, 2006). En consecuencia, es difícil detectar los sesgos latentes en los algoritmos y los modelos que producen.

Friedman y Nissenbaum (1996) sostienen que los sesgos pueden surgir a partir de, al menos, tres instancias:

- 1** Valores sociales pre-existentes de las instituciones sociales, prácticas y actitudes de las que surge la tecnología.
- 2** Restricciones técnicas.
- 3** Aspectos emergentes de un contexto de uso.

Los sesgos sociales pueden estar enquistados a propósito en el diseño de un sistema por parte de los diseñadores, por ejemplo, en ajustes manuales de índices de motores de búsqueda y de criterios para armar *rankings*. No obstante, también pueden ser no intencionales como, por ejemplo, en algoritmos de aprendizaje automático entrenados a partir de datos etiquetados por humanos, que aprenden de modo inadvertido a reflejar esos sesgos.

Los sesgos técnicos surgen de restricciones tecnológicas, de errores o de decisiones de diseño, que favorecen a grupos particulares sin valores directrices subyacentes (Friedman y Nissenbaum, 1996). Por ejemplo, cuando un listado alfabético de cadenas hoteleras conduce a incrementar las ventas de las que están antes en el alfabeto.


Por su parte, los sesgos emergentes están ligados a avances en el conocimiento o a cambios deliberados en los usos del sistema.



Por ejemplo, los sistemas de apoyo a decisiones clínicas (CDSS) están inevitablemente sesgados hacia tratamientos incluidos en su arquitectura de decisión.

El punto que nos interesa señalar aquí es que a partir de evidencia y de tomas de decisión sesgadas pueden surgir resultados fuertemente discriminatorios. En efecto, los algoritmos que arman perfiles (definidos ampliamente como la construcción o la inferencia de patrones por medio de *data mining* y la aplicación de perfiles de gente cuyos datos cuadren con ellos) son frecuentemente citados como fuentes de discriminación. Estos algoritmos identifican correlaciones y hacen predicciones acerca de la conducta de un determinado grupo.

El sesgo puede concebirse, así, como una dimensión de la toma de decisión misma, en tanto que la discriminación sería un efecto de la decisión en términos de un impacto desproporcionadamente adverso resultante de la toma de decisión algorítmica.



Se supone que es posible dirigir los algoritmos de modo tal que no consideren atributos sensibles que contribuyan a la discriminación, tales como género o grupo étnico, basados en la emergencia de discriminación en un contexto particular. Sin embargo, los perfiles contruidos a partir de características presuntamente neutrales tales como un simple código postal pueden yuxtaponerse, de manera inadvertida, con otros perfiles vinculados con género, preferencia sexual, etc.

Romei y Ruggieri (2014) dan cuenta de cuatro estrategias para prevenir la discriminación en el análisis:

- 1** La distorsión controlada de los datos de entrenamiento.
- 2** La integración de criterios de anti-discriminación en el algoritmo de clasificación.
- 3** Los modelos de clasificación post-procesamiento.
- 4** La modificación de las predicciones y de las decisiones para mantener

Por su parte, otra práctica, la relacionada con la personalización, es también frecuentemente discutida como fuente de discriminación.

En efecto, la personalización puede segmentar a una población de modo tal que solo algunos grupos reciban ciertas oportunidades o información, reforzando así desventajas sociales preexistentes. La personalización a través de perfiles no distributivos del tipo que se ve, por ejemplo, en la tasación personalizada de seguros, puede ser discriminatoria al violar tanto principios éticos como legales acerca del tratamiento igualitario de los individuos.

Desde una mirada filosófica, John Rawls (1971) propuso que el criterio con el cual se deberían dividir los bienes y los servicios entre hombres y mujeres es la justicia. Rawls identifica la justicia con la equidad, término que utilizaba con dimensión política, ya que creía que cuidar a los más desfavorecidos era una de las obligaciones del Estado. En efecto, para el enfoque de la *Teoría de la Justicia*, el título de la obra más famosa de Rawls, el foco del análisis ético de nuestras acciones debe estar puesto en la justicia como equidad. La meta es lograr un sistema de gobierno que pueda tener los efectos políticos, sociales y económicos adecuados sobre la sociedad para garantizar esta equidad.



La manera más sencilla de comprender su propuesta es mediante el experimento mental que propone Rawls, una ficción que es útil para hacer más inteligible su concepción de la justicia. Pensemos en una situación originaria en la que la totalidad de hombres y mujeres de una sociedad nos ponemos de acuerdo en cómo se repartirán los recursos de una forma que deje a todos satisfechos. Sería un orden ideal, que quizá nunca se consiga pero al que apuntamos como un norte. El punto es que debemos realizar esta deliberación con un velo de ignorancia, esto es, tomando decisiones sin conocer cuál es nuestra identidad en términos de sexo, género, edad, educación, ingresos, talentos o color de piel. Al no saber cómo soy ni en qué condiciones viviré en el mundo, determinaré lo que me parece sería una distribución justa y equitativa de la riqueza sin sesgos personales ni intereses. Deliberando con nuestros pares llegaremos a un equilibrio reflexivo cuando, mediante juicios compartidos por toda la comunidad, se logre un consenso alrededor de lo que es justo. De este modo, para Rawls, la justicia como equidad garantizará la aceptación y la tolerancia de derechos y de libertades para todos, porque nadie sabría, hasta que se levantara el velo de la ignorancia luego de acordar un orden justo, cuál es efectivamente su condición: si son hombres, mujeres, personas trans o no binarias, ricos o pobres, si viven con alguna discapacidad, etc.

Una vez establecidos estos principios, se deben dar cinco pasos para alcanzar una sociedad justa, a saber: celebrar el contrato, aceptarlo unánimemente, incluir condiciones básicas e irrenunciables (como los derechos humanos), maximizar el bienestar de las personas más desfavorecidas y asegurar la estabilidad del contrato.

Para los defensores de la *Teoría de la Justicia*, esta ficción sirve para que quede claro que la libertad y la igualdad son la manifestación de una sociedad democrática, sustentada en la cooperación libre y justa entre los ciudadanos, incluyendo el respeto por la libertad, y el interés en la reciprocidad. Rawls creía que,

de este modo, su marco teórico tomaba lo mejor del utilitarismo, pues se buscaba maximizar la felicidad, pero sin sus riesgos, ya que se garantizaban las libertades y los derechos básicos, a la vez que se ponía en el primer lugar a la equidad como la característica central de toda organización social humana.

A la vera de esta reflexión filosófica, creemos que podría agregarse una nueva opción a la lista propuesta por Romei y Ruggieri (2014) como estrategia para prevenir la discriminación: la extrapolación del experimento mental del “velo de la ignorancia” a la hora de diseñar IA.

En efecto, sería enriquecedor que al momento de desarrollar un cierto algoritmo, los diseñadores lo hicieran pensando en desconocer cuál es su identidad en términos de sexo, género, edad, educación, ingresos, talentos o color de piel. Al no saber cómo son ni en qué condiciones vivirán en el mundo, podría favorecerse (al menos en principio) una distribución más justa y equitativa de las oportunidades sin el abierto impacto de sesgos personales.

Como hemos señalado, el desarrollo de sistemas de inteligencia artificial (IA) y su aplicación social da lugar a dilemas éticos y a preguntas complejas. Al ubicar las reflexiones en un escenario hipotético, creemos que se facilita la indagación de cuestiones filosóficas arduas.

Un escenario hipotético:

Atentas a una coyuntura de crisis económica y social, las autoridades de una provincia argentina deciden lanzar una línea de créditos blandos para que personas de bajos recursos accedan a fondos para paliar su situación. Como la demanda es abrumadora, no es posible que sus empleados analicen y evalúen la situación particular de cada solicitante, así que el banco provincial licita y adquiere un modelo basado en un algoritmo de aprendizaje automatizado que permite realizar el *scoring* financiero y el análisis crediticio de todos los interesados y arrojar un resultado que asiste a quien tomará la decisión final.

Así, quienes deseen acceder a estos créditos deben completar en una plataforma digital varios de sus datos sobre competencias financieras y no financieras, incluyendo el perfil socioeconómico. Con esto se crea un informe del solicitante destacando sus debilidades y sus virtudes a partir del análisis del comportamiento financiero, del tipo de consumidor y del perfil de consumo. El sistema en cuestión ofrece luego recomendaciones sobre cómo proceder con la solicitud de crédito, mide el nivel de riesgo crediticio y lo coteja con informes comerciales.

Ahora bien, hemos visto que sobre la base del ciclo de vida del aprendizaje automático, a saber: datos de entrenamiento, entrenamiento del algoritmo, implementación en situaciones reales, evaluación de resultados y ajuste de parámetros, hay una serie de riesgos asociados. En este apartado señalaremos un riesgo crucial: la aparición de sesgos en las decisiones. Veamos las posibles fuentes de sesgos que hemos considerado:

1. Valores sociales pre-existentes, de las instituciones sociales,
2. prácticas y actitudes de las que surge la tecnología.
Restricciones técnicas.
3. Aspectos emergentes de un contexto de uso.

En nuestro escenario hipotético claramente podrían impactar, por ejemplo, factores del primer tipo: valores sociales preexistentes, pensando en el contexto social del conurbano bonaerense (de Argentina). Allí podría profundizarse la feminización de la vulnerabilidad: dado el hecho de que muchas mujeres son jefas de hogar y, a la vez, trabajadoras no registradas, la asociación de estas dos condiciones en los datos de entrenamiento del sistema podría llevarlas a quedar excluidas como sujetos recomendados para la toma de crédito. De este modo, se estaría exacerbando la desigualdad, en lugar de favorecer la pretendida inclusión.

Asimismo, a la luz de los otros dos tipos de factores (restricciones técnicas y aspectos emergentes del uso), podrían tener lugar decisiones erróneas a partir de correlaciones espurias en los datos de entrenamiento y en la consecuente creación del perfil de la solicitante. La posibilidad de discriminación a partir de los sesgos considerados desde este escenario hipotético da lugar, entonces, a algunas preguntas sobre las que nos gustaría reflexionar a continuación.

Discusión

¿Cómo podemos evitar la discriminación? Por ejemplo, en el nivel de los *input data*, ¿un mero código postal podría excluir a priori a una solicitante?

¿La categorización podría considerarse una forma de discriminación indirecta? ¿Solicitantes/usuarios diferentes podrían requerir un tratamiento diferente, sensible a su contexto socioeconómico?

Como es sabido, el sistema requiere de una vasta recolección de datos de los usuarios. ¿Qué información sensible va a emplearse y cómo podría usarse a futuro son cuestiones que los desarrolladores deberían hacer explícitas ante quienes apliquen a la solicitud de crédito?

¿Estas son cuestiones frente a las que el Estado debiera garantizar protección? ¿Qué tipo de control debe ejercerse sobre el uso de los datos para evitar escenarios discriminatorios?

■ Privacidad



La línea divisoria entre lo privado y lo público es difícil de trazar. Qué datos y qué experiencias nuestras queremos compartir y cuáles no y con quiénes queremos compartirlas es una pregunta fundamental que moldea nuestra vida humana. Es una cuestión relacionada con derechos humanos básicos: el derecho a la intimidad, el derecho a la propiedad privada, el derecho humano básico y elemental de trazar una línea entre lo que es mío y lo que es de otros. Y también hay variaciones culturales respecto de qué cuenta como privado y qué es de dominio público. Recordemos la subversión en el orden de qué acciones son públicas y cuáles son privadas en la película *El discreto encanto de la burguesía* de Buñuel (1972).

En la era de la información, además de preocuparnos por cuidar los objetos físicos que son nuestra propiedad privada (nuestra tierra, nuestra casa, nuestra familia), tenemos que cuidar de la información que generamos, nuestros datos digitales. Intangibles, difíciles de asir, difíciles de cuidar. En parte porque no tomamos conciencia de que existen, en parte porque no sabemos cómo cuidarlos.


Así tenemos en claro que nuestra casa es posesión nuestra, pero no tomamos clara conciencia de que nuestros datos de filiación (número de identidad, sexo, edad, nombre y apellido, etc.) son nuestros y privados, y que tenemos derecho a compartirlos con quienes voluntariamente deseemos, y que podemos negarle el acceso a nuestros datos a quienes queramos. Así como nadie puede obligarme a dejarlo entrar en mi casa, nadie puede obligarme a decirle cómo me llamo.

Sin embargo, los desarrollos en IA basados en aprendizaje automatizado solo son posibles gracias a que procesan una enorme

cantidad de datos y “aprenden” de ellos, en gran medida datos personales de miles o de millones de individuos. Y más allá de que esos datos estén anonimizados, siguen siendo datos personales. Este hecho ha generado una de las mayores controversias en la ética de la IA.

Si bien hay diversas legislaciones vigentes respecto de los datos digitales de las personas, la complejidad de este asunto motiva –al menos– dos preguntas filosóficamente relevantes, que podrían dar lugar a diferentes problemas en torno a los datos.

En primer lugar, está pendiente de resolución la cuestión de determinar legalmente (en cada país) cuáles datos se consideran propiedad privada de las personas, y cuáles son públicos. Los datos que se consideren privados deberían estar en poder de cada ser humano, de tal manera de que cada uno de nosotros sea la única persona que esté en posesión de esos datos, y no se vea obligado a compartirlos. Notemos que la información sobre nuestra identificación suele ser información que nos vemos obligados a compartir constantemente: los formularios de migraciones, formularios bancarios, impositivos, escolares, médicos, etc., ineludiblemente incluyen datos personales. A pesar de que suele ser un tema poco discutido, recientemente han surgido algunas dudas acerca de la necesidad de compartir ciertos datos. Así, movimientos feministas y a favor de la diversidad sexual cuestionan la necesidad de incluir en muchos de estos formularios la opción binaria femenino/masculino. Nótese que esto no se soluciona simplemente añadiendo más opciones. El problema es más profundo aún. ¿Por qué habríamos de hacer público nuestro sexo cuando tramitamos un crédito bancario, por ejemplo? Si uno piensa el asunto en estos términos, sin duda la respuesta debería ser que es absolutamente irrelevante qué sexo tengamos en este caso. Por el contrario, es sumamente relevante en contextos médicos, donde el par femenino/masculino queda corto: identificar a una mujer trans como mujer o a un hombre trans como hombre podría oscurecer datos médicos relevantes en ciertos contextos. Los datos personales son los que constituyen nuestra identidad, nuestra identidad sexual, nuestra identidad racial, de clase, profesional, etc. Sin duda debería estar en manos de cada uno de nosotros decidir con quiénes y hasta qué punto queremos compartir nuestra identidad personal.



En segundo lugar, está el problema del uso de los datos. Cada vez que llenamos un formulario (sea en los casos mencionados, sea para acceder a algún sitio en Internet, *app*, etc.) estamos haciendo públicos nuestros datos personales. Ahora bien, ¿cuán públicos estamos haciendo esos datos? Hay contextos en los que cedemos datos sabiendo que hay confidencialidad, por ejemplo en el contexto médico-paciente, o abogado-cliente. Pero en la mayoría de los demás


casos no queda claro cuán públicos se pueden volver los datos que entregamos al llenar los formularios. Tampoco está claro si se los “prestamos” a quienes nos los piden, y podemos recuperarlos y que nos los “devuelvan” cuando lo deseamos. Porque en el medio están siendo usados para muchas cosas sin nuestro consentimiento. O tal vez con nuestro consentimiento, dado que hemos cliqueado en el “sí, acepto” después de (no) haber leído las “bases y condiciones” que, en general, están redactadas de una manera difícil de comprender y resultan extensas como para leerlas en detalle.

Por otra parte, el mero hecho de nuestra existencia en el mundo genera hoy “datos” accesibles a sistemas informáticos a través de cámaras de seguridad, micrófonos, fotos nuestras que otras personas nos sacan y suben sin nuestra autorización a sitios de Internet (ningún sitio de Internet solicita autorización a todos los que aparecen en fotos y videos para que se haga pública su imagen, o su voz).

Así el documento “Para una IA confiable” de la Unión Europea (“Building trust in human-centric artificial intelligence”) recomienda proteger los datos personales en todas las instancias del desarrollo y del uso de sistemas de IA. Para lograr esto, el primer paso en cualquier diseño debería ser anonimizar los datos personales, de tal manera de que no sean identificables con la persona de carne y hueso que los introdujo en el sistema a los efectos de usar esos datos para generar con ellos sistemas de aprendizaje automatizado. De esta manera los mismos datos serían útiles para generar sistemas de IA, pero no correría ningún peligro ni estaría en desventaja la persona que cedió sus datos. Por ejemplo, se podría generar un sistema que ayude a las personas diabéticas a regular sus dosis diarias de insulina, sin que sea identificable qué personas particulares diabéticas o no cedieron sus datos para crear la *app* en cuestión, i.e. sobre la base de los datos de quiénes se hizo correr el algoritmo de aprendizaje para generar el modelo.

Sin embargo, esta propuesta tiene limitaciones, porque muchos de los sistemas que se generan continúan alimentándose de datos personales para llegar con sus sugerencias a la gente concreta de carne y hueso. ¿De qué nos serviría un sistema general que ayude a la gente a cuidar su nivel de insulina, si no le damos datos concretos de un paciente determinado para ver en qué momento ese paciente tiene que inyectarse? Los datos personales no anónimos son indispensables para que los sistemas lleguen a la gente concreta (con sugerencias de películas, de tratamientos médicos, etc.).

Queda pendiente entonces el planteo original. ¿Qué datos personales pueden ser usados por quiénes y para qué? La discusión permanece abierta. ¿Puede una empresa privada tomar datos personales para



hacer publicidad específica a cada usuario? ¿Puede un gobierno (democrático o no) tomar datos personales de la gente en las cámaras de vigilancia? ¿Para qué fines estaría autorizado a hacerlo: para aprehender delincuentes con pedido de captura, o también para detener sospechosos (¿qué cuenta como sospechoso, alguien por sus acciones, sus rasgos faciales, su color de piel?, ¿con qué datos se entrenó este sistema para evaluar “sospechosos” –y volvemos a la cuestión de los sesgos–?), o aun para identificar cabecillas de marchas de protesta contra un gobierno? ¿Puede un futuro empleador acceder a los datos de la historia clínica de alguien para tomar decisiones acerca de si emplearlo o no? ¿Puede un científico tomar datos de historias clínicas para realizar tareas de investigación y publicar un artículo sobre un tema particular? ¿Y qué pasa con los miles de datos generados en los estudios por imágenes surgidas en contextos médicos? Y, en particular, en el caso de los datos cerebrales, ¿quién puede usarlos y para qué?



Recientemente, en la revista *Nature* (Yuste et al., 2017), los miembros de proyecto BRAIN (una iniciativa médico-científica y tecnológica que tiene como objetivo reproducir tecnológicamente las características del cerebro humano) han llamado la atención sobre la necesidad de legislar sobre los datos cerebrales, proponiendo que se los considere como un derecho humano básico: cada sujeto humano es dueño de sus datos cerebrales, porque nuestros datos cerebrales son nuestra alma, nuestra identidad como sujetos humanos. Esto supondría dejar en manos de los médicos las decisiones acerca de la utilización de estos datos. Nadie podría utilizar los datos personales para propósitos comerciales, ni venderlos o comprarlos, de la misma manera que no se pueden comerciar ni vender ni comprar otros órganos humanos, como los riñones, por ejemplo.

Hoy en día los datos cerebrales son usados por investigadores en ciencias médicas, por ejemplo, a través de algoritmos de aprendizaje automatizado sobre miles de datos de imágenes cerebrales de pacientes que luego desarrollaron alguna enfermedad neurodegenerativa como el Alzheimer, para ver indicios cerebrales del desarrollo de la enfermedad antes de que se detecte sintomáticamente. Sin duda, resulta provechoso para la población tener un sistema de detección temprana de pacientes con Alzheimer para promover tratamientos preventivos, pero el costo es la utilización de datos personalísimos de miles de personas, que no necesariamente han dado su consentimiento para eso. Y estos desarrollos y estos datos también pueden ser utilizados con otros fines, por ejemplo para generar interfaces cerebro-artefactos de diseño con fines variados, como manos ortopédicas, pero también súper-soldados, i.e. armas de destrucción masiva.

En suma, los datos digitales de las personas deben ser resguardados para evitar situaciones de injusticia, o sesgos, o desventaja, por parte de quienes manejan nuestros datos y sus acciones hacia nosotros. Pero también es cierto que los datos

personales que no son voluntariamente cedidos están generando sistemas diseñados para el beneficio de la humanidad, como el caso del Alzheimer, o de los sistemas que permiten a la policía ubicar prófugos a partir del reconocimiento de rostros en cámaras de vigilancia en la vía pública. La compleja línea divisoria entre lo privado y lo público y los potenciales malos usos de los datos personales deben ser objeto de constante preocupación para los diseñadores y usuarios de IA.

Veamos un caso imaginario



El flamante asistente de voz A.L.F.R.E.D. permite controlar varios dispositivos hogareños –como la música, las luces y el lavarropas–, además de hacer listas para el supermercado, enviar mensajes de texto y responder preguntas sobre el clima y el tráfico. Para activarlo, cada usuario debe decirle “A.L.F.R.E.D.” y la acción requerida. Para estar alerta, A.L.F.R.E.D. está todo el tiempo detectando los sonidos de la casa, pero sus programadores se aseguraron de mantener un rígido principio de privacidad: es imposible acceder a las grabaciones de lo que escucha o que reaccione si no es explícitamente convocado. Ahora bien, ¿qué sucede en el caso de una casa en donde se ejerce violencia doméstica? ¿qué pasaría si al escuchar ciertas frases típicas de situaciones peligrosas se active pidiendo asistencia policial o disuadiendo al atacante? ¿Vale más la privacidad o la integridad de una persona?

Como diseñadores de IA deberíamos preguntarnos con qué derecho podríamos incorporar en un dispositivo como A.L.F.R.E.D. un sistema de detección de situaciones peligrosas como las descriptas. ¿Quién nos autoriza a incorporar esta función? Una opción es dejar en manos del usuario al configurar a A.L.F.R.E.D. la posibilidad de dejar activa o no esta función. Claro que probablemente quien configure el dispositivo sea aquel que ejerce la violencia... y, o bien se autoengaña y no cree estar ejerciéndola, o bien no quiere que se reconozca esta situación y probablemente decida configurarlo de tal manera que quede desactivado. ¿Puede el fabricante incluir esta función sin el consentimiento de los usuarios? Pensemos ahora la situación del lado de quien recibe el llamado de urgencia, el 911. ¿Está preparado el sistema para recibir llamadas automáticas de este tipo? ¿Tiene que responder de manera diferenciada en estos casos? ¿Por qué?



■ Transparencia

La transparencia de un sistema tecnológico no es independiente de la cultura técnica existente en una sociedad. Una cultura técnica sólida, sofisticada y extendida en una sociedad permite que sus miembros participen de una manera informada y consciente del debate público respecto de qué tecnología desarrollar, para qué propósitos, en qué entornos y con qué punto de vista sobre la vida humana. La cultura técnica incorporada en una sociedad genera un trasfondo de comprensión de los desarrollos tecnológicos que elimina los prejuicios y permite balancear prudencialmente los pros y los contras en función de cómo esa sociedad desea vivir o de cómo entiende lo que es una vida digna de ser vivida. La valoración ética adecuada de los sistemas de inteligencia artificial demanda una comunicación pública eficaz de las características de la inteligencia artificial y de sus impactos en la vida de las sociedades.

Por cultura técnica se entiende el conjunto de conocimientos y de representaciones sobre los objetos artificiales, sus componentes, sus estructuras y funciones; además de componentes prácticos como reglas, habilidades y conocimientos operacionales referidos a los artefactos y a sus funciones. Finalmente, la cultura técnica también comprende componentes valorativos que involucran los objetivos y los resultados de las funciones de los artefactos y de nuestras acciones con ellos.

La comprensión de los diseños de los artefactos o de sistemas tecnológicos depende de la cultura técnica existente en los diferentes grupos sociales. La presencia de contenidos culturales técnicos adecuados es el gozne que relaciona al usuario con el diseñador y que sitúa al artefacto en el contexto de su historia cognitiva, técnica y cultural. De esta manera, los potenciales usuarios logran aprehender el

para qué de los artefactos, emplear los modelos conceptuales adecuados para entender sus posibilidades y sus restricciones, evaluar adecuadamente los resultados de sus funciones y desarrollar y modular relaciones de confianza/desconfianza con los sistemas artificiales, emocionales, etc.

Es una exigencia ética de la tecnología de la inteligencia artificial comunicar y difundir sus características y aplicaciones para que los ciudadanos puedan tomar decisiones informadas. La transparencia o la explicabilidad de los sistemas de IA está directamente asociada a la autonomía de la vida humana. Si no hay una comprensión mínima de los sistemas tecnológicos que incorporan IA, no se podrá garantizar el ejercicio de la autonomía, puesto que los ciudadanos deberán ceder siempre su autoridad a los expertos y no podrán juzgar lúcidamente por sí mismos respecto de la adopción o no de esa clase de tecnologías. Sin comprensión de la tecnología no hay evaluación juiciosa y adecuada a su realidad.

Los componentes primarios de la transparencia son: **(1)** la accesibilidad y **(2)** la comprensibilidad de la información (Glenn y Monteith, 2014; Kitchin, 2016).



(1) Muchas veces la información acerca del funcionamiento de los algoritmos es mantenida en secreto por razones de ventaja competitiva, de propiedad o de seguridad nacional. En estos casos se alega que la transparencia podría contrariar la autonomía de las organizaciones y la privacidad de los datos. Esto genera una asimetría en la información y un desequilibrio en el conocimiento y en el poder de toma de decisión en favor de los procesadores de datos (Tene y Polonetsky 2013).

(2) Más allá del conocimiento de los datos y de los algoritmos en los que se basa un sistema, la información que el sistema proporciona al usuario como *output* del procesamiento debe ser comprensible por el usuario para ser considerada transparente (Turilli y Floridi, 2009). Los esfuerzos por hacer que los algoritmos sean transparentes afrontan un desafío arduo. El problema persistente de la interpretabilidad en los algoritmos de aprendizaje automático apunta al reto de la opacidad. En efecto, el algoritmo modifica su estructura de comportamiento durante la operación (Markowetz et al., 2014). Esta alteración acerca de cómo el algoritmo clasifica nuevos inputs es precisamente lo que le permite aprender (Burrell, 2016). La razón subyacente (*rationale*) al algoritmo es oscura, dando lugar al así llamado problema de la “caja negra”. Los algoritmos son opacos en el sentido de que el receptor del *output* del algoritmo no tiene idea de cómo o por qué se llegó a una clasificación particular a partir de los *inputs*. Tanto los inputs (datos) como los


outputs (clasificaciones) pueden ser desconocidos e incluso incognoscibles. La opacidad en los algoritmos de aprendizaje automático es un producto de la alta dimensionalidad de los datos, del código complejo, y de la cambiante lógica de toma de decisión (Burrell, 2016). Asimismo, el consentimiento significativo al procesamiento de los datos no es viable cuando la opacidad imposibilita la evaluación de riesgos (Schermer, 2011).

Los pedidos de transparencia a menudo apuntan a la posesión de códigos de acceso abierto o a la aceptación por parte del usuario de los términos y condiciones de un servicio. Sin embargo, podría considerarse que hay una noción más rica de transparencia que implica compartir los fines, los medios y los procesos de pensamiento detrás de las decisiones de ingeniería con quienes son afectados por ellas.

En esta línea, es importante remarcar que la transparencia podría ser una demanda acerca del **(I) algoritmo** o acerca del **(II) uso** del sistema en cuestión.

En relación con **(I)**, considerando las limitaciones de la “caja negra” recién explicada, los desarrolladores podrían cuestionar la plausibilidad de ser transparentes con los algoritmos de aprendizaje automático. En ocasiones sostienen que ellos mismos no podrían descifrar o hacer ingeniería reversa acerca de cómo operan algoritmos específicos después de haberlos entrenado con vastos conjuntos de datos. El pretendido valor de estos algoritmos reposa en su habilidad para resolver la toma de decisión de un modo que sería superior a –en tanto optimizaría– las posibilidades de procesamiento humano. La transparencia algorítmica no contribuiría genuinamente, por tanto, a la comprensión de los usuarios.

Consideremos entonces qué sucede respecto de **(II)** la transparencia acerca del uso. En este caso se trata de hacer comprensibles para el usuario –de manera suficiente (aunque no del todo)– las decisiones tomadas en el momento del diseño del sistema, de tal manera de que el usuario pueda desarrollar una confianza en su fiabilidad y en su justicia subyacente. En general, esto supone dar una cierta información acerca de cómo se desarrolló el sistema, sin tecnicismos, y acorde a la cultura técnica (ver lo dicho anteriormente) del usuario. Dado que el grado y el tipo de información que los distintos usuarios pueden asimilar es variable en diversos grupos humanos, la transparencia es relativa, varía de un grupo de usuarios a otro y constantemente se requiere de expertos tanto en diseño informático como científicos sociales que permitan realizar la tarea de “traducción” de la especificación técnica del sistema para los usuarios efectivos.



Veamos algunas de las cuestiones que esto suscita desde la consideración de un escenario hipotético.



Uno de los principales obstáculos en la lucha para erradicar mal de Chagas, una enfermedad provocada por el parásito *Tripanosoma cruzi* y que representa uno de los mayores problemas de salud en regiones rurales de América Latina, es que la población en peligro de contagio se encuentra en regiones con poco acceso al sistema de salud pública o en sitios remotos y alejados. Frente a esto, la compañía HealthCare desarrolló un sistema que asegura que puede detectar con un 85% de certeza la presencia de triatominos, el responsable de la enfermedad, en el entorno de la persona solo con analizar imágenes de la saliva de una persona. Así que desarrolló una costosa aplicación para teléfonos celulares que usa la cámara del dispositivo en alta definición para tomar imágenes y enviarlas a un servidor en la nube, en donde es cotejada por algoritmos de aprendizaje automatizado con otras imágenes similares hasta determinar si detecta o no elementos compatibles con triatominos. Un país latinoamericano compra diez mil licencias de esta solución informática y las distribuye mediante folletos en mercados y bares entre la población rural que podría estar enferma. Si bien la aplicación requiere aceptar sus términos y condiciones para ser usada, además de advertir que su precisión llega solo al 85% de los casos, muchos de sus usuarios no saben leer o no tienen teléfono celular propio, y usan uno prestado. Además, el objetivo de la *app* es que los resultados obtenidos sean interpretados por un médico para dar un diagnóstico, pero no hay profesionales disponibles, y muchas personas reemplazan sus análisis simplemente por lo que indica la *app*.

Hay muchas cuestiones que serán tenidas en cuenta durante el desarrollo de un sistema como este, por ejemplo, los recursos materiales disponibles, la viabilidad económica, jurídica, ambiental, la programación de los algoritmos y la determinación de las bases de datos de casos que alimentará al sistema y partir de la cual aprenderá (toda vez que una tecnología se desarrolle con datos acotados de una

población y los resultados se extrapolen a otra poblaciones debería chequearse la posibilidad de extrapolar sin cambio el desarrollo a un nuevo grupo humano). Pero demos por sentado que el sistema desarrollado es robusto y fiable.

En este ejemplo interesa especialmente qué sucede con la transparencia del sistema tecnológico frente al hecho de que el usuario no sabe cómo opera el algoritmo, a pesar de que provee resultados correctos en un alto porcentaje. La adopción de este tipo de desarrollos tecnológicos por parte de una población cuya cultura tecnológica es limitada genera situaciones complejas. Si la población no está habitualmente familiarizada con el uso de teléfonos móviles, ¿cómo podrá comprender la posibilidad diagnóstica del aparato? ¿Qué hará el usuario con la información recibida? Un diagnóstico sin un consecuente tratamiento es inútil, y solo produce angustia en quien lo recibe. ¿Tiene sentido distribuir este desarrollo directamente en la población o tiene más sentido que esté disponible en centros de salud para que haya un profesional de la salud a cargo de su uso?

En este último caso se vuelve central la relación médico-paciente, nicho valorativo en que el que se inserta el sistema tecnológico. Y más allá de que las enfermedades orgánicas de los seres humanos sean las mismas en todo el planeta (aunque tengan diferente incidencia en diversas poblaciones) las formas de recibir y de lidiar con la información en cuestión pueden variar de cultura en cultura. Por lo tanto, si el sistema está siendo diseñado para ser directamente usado por médicos frente a pacientes, debería acoplarse a interfaces que tengan en cuenta las particularidades de la población y el modo en que se da la atención médica y la transmisión de información en la relación médico-paciente en esa cultura. La adaptación del sistema tecnológico al nicho sociocultural en que se inserta es una demanda ética básica sobre el desarrollo de tecnología. En este caso la transparencia del desarrollo supone hacer accesible al profesional de la salud la información relevante acerca del funcionamiento del sistema como para que pueda confiar en él a la hora de hacer los diagnósticos en la población que trata.

Como puede verse, la cuestión de la transparencia es relativa a la cultura tecnológica del usuario al que está destinado el desarrollo, por lo que “hacer transparente” el funcionamiento del sistema requiere de especialistas en ciencias humanas y sociales que conozcan el público al que está destinada la explicación provista del funcionamiento del sistema.



■ Responsabilidad

Tal como se desprende de lo señalado en las secciones anteriores, la implementación de nueva tecnología implica, además de promesas de cambio y transformaciones, riesgos tanto para los individuos como para la sociedad en general. En el caso del escenario actual de los modelos de IA, vemos cómo estos desarrollos ocupan cada vez mayor espacio en contextos críticos de decisión como el mundo de la salud, el ámbito judicial, las dependencias gubernamentales, los organismos financieros y los territorios de conflicto bélico, entre otros. Frente a esto, es imperioso comenzar la discusión sobre quiénes serían los responsables de las consecuencias y de los impactos de estos avances.



Algunos escenarios de conflicto posible son:


- Los dispositivos de alta tecnología como vehículos autónomos de transporte de pasajero o de vigilancia cuentan, por ejemplo, con múltiples componentes que rara vez son provistos por el mismo fabricante y que trabajan en conjunto, como sensores, cámaras, procesadores, diferentes tipos de códigos de software interno, múltiples algoritmos de aprendizaje automatizado. ¿En qué medida cada uno de los responsables de un equipo complejo es responsable por la conducta del aparato, si para su correcto funcionamiento estos elementos deben estar completamente interconectados?
- En muchas ocasiones los desarrollos de inteligencia artificial son ideados y desarrollados en un país pero utilizados en varias partes del globo, en comunidades que no siempre comparten los mismos valores culturales y comunitarios. ¿Sus desarrolladores son responsables si se violan principios de otras comunidades? ¿Es lícito prohibir el uso de ciertos desarrollos en determinados territorios?

- ¿Quién es responsable si un algoritmo está sesgado? ¿Aquellos que lo programaron, los que le brindaron la base de datos, la compañía que lo utiliza en su provecho?
- Aquellos que trabajan en tecnología que reemplazará puestos de trabajo que hoy realizan hombres y mujeres, ¿en qué sentido son responsables de los cambios en el mundo del trabajo y en la desaparición de esos puestos?
- Si es cierto que muchos sistemas de aprendizaje profundo funcionan como cajas negras y que los mecanismos que dan lugar a sus conclusiones no son transparentes ni pueden ser auditados por personas humanas, ¿quiénes son responsables por ellos?

Nos encontramos, entonces, frente a dilemas y problemáticas sobre la responsabilidad que parecen ser particulares de esta área. Por ejemplo, mientras que los agentes humanos pueden ser convocados para rendir cuentas de las decisiones y de las acciones que tomaron en el caso de que estas hayan afectado a otros, los modelos de IA y sus algoritmos no parecen ser responsables en un mismo sentido moralmente relevante, a pesar de que toman decisiones y realizan acciones que pueden afectar a los demás. Por otro lado, los actores involucrados en la creación, en el diseño, en el desarrollo y en la implementación de estos modelos son tan numerosos que crean una red compleja en donde establecer la responsabilidad no es una cuestión simple.

No es menor, tampoco, el hecho de que la actitud de hombres y mujeres frente a los dispositivos de inteligencia artificial suele ser diferente a la que tenemos hacia otros artefactos. En ocasiones, son percibidos como superiores y más avanzados en sus habilidades, lo que genera una falsa sensación de confianza. Pero también hay casos en donde temores y prejuicios infundados despiertan sospechas sobre los resultados de esta clase de avances y nos priva potencialmente de los beneficios que podría producir. Uno de los pasos necesarios para alcanzar una verdadera confianza en la inteligencia artificial es determinar con claridad los roles y las responsabilidades de cada jugador involucrado en su desarrollo y aplicación, lo que incluye no solo a las compañías y a los Estados, sino también a los desarrolladores y usuarios, entre otros.

La fundación World Wide Web, por su parte, distingue la responsabilidad algorítmica – esto es, la obligación de los diseñadores de algoritmos de dejar en claro cuáles son los daños potenciales de



sus desarrollos– de la justicia algorítmica, vinculada con la capacidad para reparar daños ocasionados (Webfoundation.org). Esta diferenciación ayuda a echar luz sobre la necesidad de pensar acerca de la responsabilidad antes de que ocurra cualquier daño y cómo aquellos que piensan, diseñan y desarrollan los algoritmos deben prever también las consecuencias indeseables de sus trabajos.


La pregunta por la responsabilidad, entonces, no aparece cuando el sistema se pone en marcha, sino que comienza en su misma génesis. En el momento en el que los diseñadores deciden que un diseño determinado es la mejor solución al problema que están intentando resolver se convierten en actores responsables de las modificaciones que se introducen en el entorno, puesto que la realización efectiva de un diseño cambia la realidad existente y la vida de las personas y esto con independencia de si se perciben o no anticipadamente las consecuencias que habrán de traer esos cambios. Así, no hay diseño sin responsabilidad por lo diseñado, la cual atañe a quienes imaginaron el artefacto o el sistema tecnológico y lo transformaron en un hecho real en el entorno humano.

Otro punto importante, más allá de la robustez del sistema tecnológico, es la responsabilidad por los fallos del sistema. Esto plantea una pregunta previa: ¿debe el experto suspender su juicio y diferirlo al sistema? ¿Quién tiene el control de la situación, el experto médico o el sistema? La responsabilidad no es independiente del lugar en el que ubiquemos a la fuente de autoridad última. Los requisitos éticos básicos exigen que la responsabilidad por los falsos positivos descansa siempre en una autoridad humana. Es más, el sistema tiene que estar siempre bajo acción y supervisión humana. Los resultados no pueden sustituir nunca el mejor juicio del experto humano; finalmente, es el juicio del experto quien debe calibrar el diagnóstico arrojado de la máquina; de lo contrario, nadie podría hacerse responsable por los resultados.

En la literatura actual se pueden distinguir tres sentidos en los que se habla de responsabilidad relacionados con la inteligencia artificial:

1. La responsabilidad como una característica o rasgo del sistema mismo de inteligencia artificial.
2. La responsabilidad en sentido estrecho de quiénes son las personas o grupos que deben rendir cuentas de los efectos de la tecnología.
3. La responsabilidad en sentido amplio que compete al ecosistema socio-político-económico que desarrolla, adquiere, implementa y utiliza los avances de la inteligencia artificial.

El primero de los sentidos está vinculado con la necesidad de incorporar la explicabilidad en los sistemas y algoritmos de inteligencia artificial, mientras




que el segundo y el tercero se centran en poder determinar quién o quiénes, en el amplio ecosistema de actores involucrados, es/son responsable/s o el/los más responsable/s de los efectos producidos en un hecho puntual o en la sociedad en general.

Y si bien la transparencia parece ser una de las condiciones necesarias a la hora de pensar la responsabilidad de la inteligencia artificial –en tanto un algoritmo transparente permite por ejemplo un mejor escrutinio de sus mecanismos internos–, este rasgo no parece ser suficiente, ya que la sola transparencia no basta para determinar mejor la responsabilidad de las partes. Existen otros principios que deben estar presentes, como la explicabilidad, la capacidad de respuesta y la auditabilidad.

Un proyecto de IA responsable debería tener capacidad de respuesta en tanto debe poder justificar las decisiones surgidas algorítmicamente con un respaldo humano. Esto significa que debe quedar establecida una cadena de responsabilidades de extremo a extremo con personas que asuman la responsabilidad de cada paso tomado, desde el diseño hasta su implementación, para poder comprender los resultados que brinde el algoritmo. Se trata de poder ofrecer explicaciones de los procesos de producción a cualquier individuo que lo solicite en un lenguaje claro, comprensible, coherente y accesible para personas no técnicas.

En cuanto a la auditabilidad, es condición necesaria para poder determinar tanto la responsabilidad de las prácticas de diseño y de uso como la justificación de los resultados. Para esto, desarrolladores e implementadores de sistemas algorítmicos deben llevar registro en todas las etapas, desde los primeros desarrollos, del modelado de las versiones de prueba, de la recopilación de datos, etc. Estos registros deben ser accesibles a pares y a supervisores como condición necesaria, aunque no suficiente, para que los procedimientos y las operaciones del modelo de IA sean seguros, éticos y justos.

La economía global de las aplicaciones y de los desarrollos tecnológicos también plantean desafíos a la hora de evaluar responsabilidades, ya que cada vez parece ser más difícil pensar estos avances dentro de determinadas fronteras. Cada algoritmo tiene en su concepción el conjunto de supuestos culturales de las personas que los llevaron adelante pero, en muchas ocasiones, se utilizan o se implementan en contextos foráneos, en donde hay otras normas o principios. Esto también genera choques no solo culturales o idiosincráticos sino también judiciales y de aplicación de reglamentos. Las discusiones acerca de la privacidad, por ejemplo, dejan en claro que estos problemas se dan en el choque de jurisdicciones y que su solución requiere la participación de múltiples partes interesadas y que requieren coordinación multilateral.



Algunos escenarios de conflicto posible son:

El complejo entramado de actores involucrados en el diseño, en el desarrollo, en la creación y en la implementación de algoritmos impone el diálogo de sus numerosos actores involucrados, ya que se trata de un terreno marcado por la complejidad y por la interseccionalidad.

Una lista no exhaustiva de partes interesadas debería incluir:


- Representantes del Estado, legisladores y hacedores de políticas públicas, quienes deben promover conductas responsables e inclusivas.
- Organizaciones intergubernamentales, que deben ofrecer el marco para las discusiones de todas las partes interesadas más allá de las fronteras.
- Compañías privadas vinculadas al mundo de la tecnología, que tienen que respetar códigos de ética en el manejo de materiales sensibles como los datos y cuyos productos deben poder ser auditables, además de ajustarse a la legislación local.
- Miembros del mundo académico, que por un lado deben garantizar que la ética de la inteligencia artificial esté presente en los planes de estudio de las carreras involucradas a la vez que investigan y ofrecen herramientas para la reflexión de estas prácticas, facilitando la investigación interdisciplinaria.
- Organizaciones no gubernamentales interesadas en pensar mecanismos para la participación ciudadana inclusiva, siendo puentes de intercambio de conocimientos y de diálogo entre el sector público y el privado.

Imaginemos el siguiente caso:

Luego de años de paciente desarrollo y pruebas, la compañía Hefestus tiene listo a "HER-CULES", un exoesqueleto de última generación que permite que cualquiera que lo use pueda mover sin esfuerzo objetos grandes y pesados. Se trata de una suerte de súper-traje neumático que incluye sensores que, al detectar que un movimiento puede herir a alguien, automáticamente cancela cualquier acción.

La empresa portuaria Container S.A. adquiere seis unidades de "HERCULES" y capacita a una docena de empleados en su uso, aumentando su capacidad de transporte y logística. Dos años más tarde, Hefestus detecta una falla en su sistema de sensores y envía una actualización de su firmware para solucionar este problema. Sin embargo, debido a la crisis económica que atraviesa su país, Container ha dejado de actualizar los exoesqueletos ya que cada actualización tiene un costo en moneda extranjera.

Semanas más tarde, un operario lastima gravemente a un compañero mientras trabajaba: ¿quién es el responsable? ¿los diseñadores de "HERCULES", que no previeron la falla? ¿La compañía Hefestus, cuyo modelo de negocios implica la capacitación y la actualización paga para usar sus productos? ¿Las autoridades de Container, que dejaron de adquirir las mejoras? ¿El empleado que estaba usando el equipo?



■ Seguridad

Hemos señalado en este trabajo que el impacto de la implementación de modelos de IA es vasto y complejo. Tiene consecuencias en los individuos y en la sociedad debido a su poder de cambiar o de consolidar inequidades, porque puede repetir sesgos y prejuicios ya instalados, porque tiene el potencial de poner en riesgo nuestra privacidad y porque, si no hay preocupación por la responsabilidad y por la transparencia, sus consecuencias pueden ser sorprendentes sin que nadie se haga cargo de ello. Pero existe otra dimensión que también debe ser tomada en cuenta y es la de la seguridad. Un buen modelo de IA debe ser confiable, preciso, robusto y seguro.

Una gestión irresponsable de los datos, un diseño negligente o procesos poco confiables de producción y de implementación pueden, cada uno a su manera, conducir a resultados peligrosos o inseguros que dañen directa o indirectamente el bienestar de las personas y el bienestar público. También pueden socavar la confianza de la sociedad en el uso responsable de las tecnologías de IA.

Se trata de un gran desafío porque estos sistemas se implementan en una realidad llena de eventos inesperados, con gran incertidumbre y volatilidad y en donde es posible que se cometan delitos o que se los utilice con un fin diferente de aquel para el que fueron pensados, por ejemplo para generar daño. Para que puedan ser verdaderamente útiles, los modelos de IA deben ser lo suficientemente flexibles como para poder ser utilizados en escenarios reales. Sin embargo, es allí donde reside uno de los principales problemas para su seguridad: sin suficientes controles, un modelo puede determinar un curso de acción que optimice recursos y consiga el mejor resultado pero por medios perjudiciales para las personas. Estos modelos no siempre tienen capacidad de leer distintos contextos y carecen de algunas de las

herramientas con las que contamos hombres y mujeres para afrontar lo inesperado, como el sentido común o la empatía, por lo que pueden tener consecuencias perjudiciales que sus programadores no anticiparon ni limitaron. Este es un problema arduo, ya que la complejidad ilimitada del mundo hace que la anticipación de todas sus circunstancias y variables parezca imposible.

Esto refuerza la necesidad de preocuparse por producir tecnologías de IA seguras, con mecanismos que puedan mitigar los riesgos de que falle cuando se enfrente al escenario del mundo real y sus imprevistos, además de minimizar la posibilidad de que sean vandalizados o convertidos en herramientas dañinas que produzcan resultados perjudiciales que socaven la confianza pública. La construcción de un sistema de IA que cumpla con estos objetivos requiere pruebas rigurosas, validación y reevaluación, así como la integración de mecanismos adecuados de supervisión y de control en su operación en el mundo real. A su vez, las consecuencias de la falta de seguridad varían de manera notable de acuerdo a cada modelo, ya que no es lo mismo un algoritmo que distingue entre correos electrónicos válidos y aquellos que conforman el *spam* a uno que reconoce potenciales blancos en un sistema de defensa militar.

La confiabilidad de un modelo de IA se da cuando se comporta exactamente como lo pretendieron y anticiparon sus creadores y diseñadores, cumpliendo las especificaciones para las que fue programado. La confiabilidad es, en este sentido, una suerte de medida de consistencia. Sin embargo, los usuarios de los modelos no siempre los utilizan con su funcionalidad prevista y este objetivo original se ve traicionado. Es por eso que más allá de las advertencias que se pueden hacer –con los términos y condiciones de uso, en manuales o en capacitaciones, por ejemplo– es necesario que se tenga en cuenta de qué modo los sistemas pueden ser utilizados de forma errada, ya sea intencionalmente o no, y minimizar cualquier capacidad de daño.

Poder afirmar la seguridad de un sistema depende, también, de la precisión de su comportamiento. Si bien esta medida cambia de acuerdo a las características propias de cada modelo de IA, podemos definir la precisión de un modelo como la proporción de ejemplos para los que genera un resultado correcto. La elección de un determinado nivel de precisión o de una tasa de error aceptable es la medida de evaluación de su *performance* y será lo que determine si funciona bien o mal. Un mal funcionamiento es la primera señal de que la seguridad del sistema está comprometida o de que hay intentos externos por dañarla, además de que el nivel de confianza que se depositará en él depende de cuántos errores comete. En una realidad que es volátil y cambiante, en un escenario lleno de incertidumbres, no siempre es sencillo asegurar precisión.



En estas condiciones imprevisibles se impone la necesidad de que los sistemas de IA sean robustos, es decir que funcionen de manera confiable y precisa en condiciones adversas. Estas condiciones pueden incluir intervenciones externas dañinas con intenciones vandálicas o cambios radicales e inesperados de alguno de los factores que normalmente no cambian o que están en los estándares esperados. La medida de robustez es la fortaleza de un sistema y la solidez de su funcionamiento en respuesta a condiciones difíciles o a ataques.

Así, además de tener un funcionamiento correcto, el objetivo de la seguridad de un sistema de IA es poder brindar protección frente a posibles ataques o acciones maliciosas, manteniendo siempre la integridad de la información que lo constituye. La confidencialidad y la privacidad de los datos propios y de los usuarios debe estar salvaguardada en todo momento. Esto implica, por un lado, garantizar que solo las personas autorizadas tendrán acceso a su uso y que existen mecanismos que protegen su arquitectura interna de cualquier modificación no autorizada. También se debe prever su funcionamiento a pesar del daño de alguno de sus componentes o en condiciones hostiles o adversas, como en medio de un ataque externo.



Los escenarios adversos o maliciosos son numerosos y no es posible dar una lista exhaustiva, pero podemos señalar ciertas condiciones que deben ser previstas a la hora del diseño de los modelos de IA. Por un lado, la mayoría de los sistemas de aprendizaje automático son contruidos con una imagen estática de la realidad en la que operarán, que surge de los datos históricos con los que han sido alimentados y que definieron sus parámetros internos. Frente a esta fotografía fija, cuando son aplicados “al mundo real”, su precisión y confiabilidad son especialmente vulnerables a cambios en la distribución o en la composición de esos datos. Cuando los datos históricos que se han cristalizado en la arquitectura del modelo entrenado dejan de reflejar a la población relevante a la que el modelo se aplica, lo vuelven rápidamente propenso a errores de manera inesperada y potencialmente perjudicial. Mantenerse al tanto de estas transformaciones en los datos es crucial para una IA segura y cada equipo debe asegurarse un plan de acción para anticipar y reducir su eventual impacto.

La incorporación de información nueva o inesperada puede minar la robustez de cualquier sistema que, como los de aprendizaje profundo, basan su funcionamiento en el procesamiento de cantidades masivas de datos de donde sacar resultando a partir de miles o incluso millones de parámetros. Estos modelos pueden tener dificultades para procesar

eventos y escenarios desconocidos cometiendo errores graves e inesperados porque no cuentan con la capacidad de contextualizar los problemas para los que no están programados para resolver. Como vimos en la sección de transparencia, estos errores pueden permanecer inexplicables dada la alta complejidad computacional de sus estructuras matemáticas. Esta fragilidad puede tener consecuencias muy adversas cuando los sistemas se aplican en vehículos autónomos como autos o drones militares.



También deben tenerse en cuenta los comportamientos maliciosos destinados específicamente a hacer fallar un modelo de IA. Existen varias estrategias conocidas, pero a medida que estos modelos se vuelven cada más populares en ámbitos estatales, empresariales y personales, aumenta el atractivo para quienes buscan beneficiarse de manera ilegal y por eso estos ataques son cada vez más frecuentes y distintos. Una de las formas más comunes de daño es la modificación intencional de los datos de entrada, a menudo de manera imperceptible, para inducir al sistema a una clasificación errónea o a una predicción incorrecta. Es lo que sucede, por ejemplo, cuando se alteran de forma indetectable los píxeles de una imagen para que no se pueda reconocer un rostro o la fachada de un edificio. La utilización de datos incorrectos o dañados puede darse incluso antes de que el sistema sea puesto en funcionamiento. El “envenenamiento de datos” es un tipo de ataque en el que se modifican o manipulan parte del conjunto de datos sobre el cual un modelo será entrenado, validado y probado. Al alterar un subconjunto seleccionado de entradas de entrenamiento, el sistema de IA generará una clasificación errónea, tendrá bajo rendimiento o un “talón de Aquiles” para que una vez instalado y en supuesto correcto funcionamiento se pueda atacar al aprovecharse de esa vulnerabilidad.

Algunos escenarios de conflicto posible son:

Algunas estrategias posibles para mitigar los riesgos de un modelo de IA incluyen:

- Ejecutar simulaciones extensas y en variedad de situaciones y de contextos durante la etapa de prueba, de modo que se puedan programar medidas apropiadas de restricción en el sistema.
- Crear sistemas transparentes y auditables que permitan la inspección y el monitoreo continuo.
- Incluir siempre mecanismos que permitan que personas autorizadas puedan anular o apagar funciones y sistemas en cualquier momento y de forma remota.

Imaginemos este caso:

Con el fin de lograr anuncios de publicidad que sean realmente atractivos para los usuarios de redes sociales, que en ocasiones aseguran sentir hastío del volumen de avisos que ven en sus muros y timelines, la empresa RelevANT diseñó un modelo de algoritmo de machine learning que toma toda la información pública asociada con un usuario y crea avisos que le resultan increíblemente atractivos. Se trata de un desarrollo tan exitoso que varias compañías lo compraron y vieron aumentar sus ventas.




Enterados de su eficacia, un grupo de delincuentes informáticos compró el algoritmo y lo utilizó para una campaña de phishing, con la que inundaron las redes sociales con avisos engañosos que llevaban a los usuarios a entregar los datos de sus tarjetas de crédito o contraseñas de sus cuentas de banco online, en el que terminó siendo uno de los crímenes informáticos más redituables de la historia.

¿Qué responsabilidad diría que tiene RelevANT en el delito que cometieron sus clientes? ¿Es posible que se limite el uso de tecnologías tan precisas como las de un algoritmo que crea un aviso publicitario perfectamente personalizado para cada individuo? ¿Es deseable eso?

Si el algoritmo de los avisos personalizados fuera contratado por una marca de una gaseosa altamente azucarada, ¿sería razonable exigirle que no los use con menores de edad o poblaciones con problemas de salud?



■ Bienestar, derechos humanos, política y tecnología



Bienestar

Los seres humanos perseguimos el bienestar, a saber, no solo nos interesa vivir sino especialmente vivir bien (Ortega y Gasset, 1998). Las tecnologías, que transforman el mundo según nuestros valores y propósitos son unas de las principales fuerzas forjadoras del bienestar. Ellas incorporan el modo en que los seres humanos se piensan a sí mismos y al mundo, retratan sus miedos y deseos y, en tanto que soluciones reales a problemas relacionados con la gestión de la vida individual y social cotidiana, contienen de hecho diferentes respuestas a la pregunta de qué se trata la buena vida –por ejemplo, las prácticas técnicas y creencias de los pueblos Quom del Gran Chaco configuran un modo de responder la pregunta de qué es el bienestar completamente diferente a las prácticas tecnológicas y creencias que organizan la vida de las tribus del Silicon Valley (Sadin, 2018)–.

El bienestar o buen vivir es un término siempre móvil, ilimitadamente variable a lo largo de la historia humana, puesto que las mujeres y los hombres no hemos querido, ni queremos, ni queremos siempre lo mismo; el perfil de nuestra idea de la buena vida está en permanente transformación y se configura a partir de nuestras experiencias, conocimientos, deseos, valores, miedos, imaginaciones, preocupaciones, etc.

Bienestar es aumentar cada vez más –¿ilimitadamente?– nuestras capacidades.


Con el fin de lograr anuncios de publicidad que sean realmente atractivos para los usuarios de redes sociales, que en ocasiones aseguran sentir hastío del volumen de avisos que ven en sus muros y timelines, la empresa RelevANT diseñó un modelo de algoritmo de machine learning que toma toda la información pública asociada con un usuario y crea avisos que le resultan increíblemente atractivos. Se trata de un desarrollo tan exitoso que varias compañías lo compraron y vieron aumentar sus ventas.

Enterados de su eficacia, un grupo de delincuentes informáticos compró el algoritmo y lo utilizó para una campaña de phishing, con la que inundaron las redes sociales con avisos engañosos que llevaban a los usuarios a entregar los datos de sus tarjetas de crédito o contraseñas de sus cuentas de banco online, en el que terminó siendo uno de los crímenes informáticos más redituables de la historia.

Las personas deliberamos para resolver las cuestiones relativas a cómo vivir, a nuestra idea de bienestar. Y lo hacemos con el propósito de obtener la íntima comodidad de sentirnos en casa con nosotros mismos y con los otros. Lo que orienta nuestras deliberaciones es lo que consideramos importante para nosotros (Frankfurt, 2004), motivo de nuestros cuidados y de nuestra atención. Sin embargo, los ingredientes del bienestar no resultan tan evidentes. Qué es el bienestar es un asunto bastante contextualizado espacial y temporalmente. Diferentes personas, grupos humanos y culturas alientan contenidos distintos para la noción de bienestar.

La noción de bienestar tiene una dimensión individual y otra colectiva. En su dimensión individual, el bienestar se relaciona directamente con el uso de las tecnologías y con el modo en que estas contribuyen o no a mejorar la vida cotidiana de las personas y a la realización de sus planes de vida. En su dimensión colectiva, el bienestar está relacionado con los derechos humanos en tanto que son un contenido transversal a las culturas y sociedades contemporáneas. En esta dimensión, la satisfacción de los derechos humanos constituye una preocupación fundamental en todas las áreas de las prácticas humanas, incluyendo el diseño y la realización de sistemas de inteligencia artificial.

Bienestar individual y social



Las tecnologías actuales tienen un impacto psicológico directo en la vida de las personas. Lo pone en evidencia una rápida mirada a nuestros hábitos cotidianos. El 80% de los usuarios de teléfonos inteligentes mira la pantalla de su celular al despertarse, incluso antes de lavarse los dientes. Se estima que el usuario promedio pasa al menos 4 horas por día frente a su celular o la *tablet*. La mayor parte de ese tiempo está dentro de alguna red social. De hecho, se habla de “adicción” al celular, habiendo muchos consejos y tratamientos *online* para tratarla, aunque no está aún tipificada dentro del marco de trastornos mentales. Si bien los resultados que arrojan dichos estudios son diversos, en su mayoría coinciden en que existe un impacto negativo en la calidad de la vida de los usuarios que pasan una cantidad importante de su tiempo dentro de este mundo digital.


Con la nueva tecnología surgen también nuevos problemas vinculados a la manipulación y al control de nuestros instintos evolutivos humanos. Las plataformas tecnológicas explotan la experiencia humana, permitiendo adicciones, socavando las relaciones sociales, difundiendo propaganda, manipulando a los niños, etc. Se trata de un problema global masivo creciente que afecta a más de dos mil millones de personas.

Hay, al menos, cuatro categorías de problemas que afectan directamente el bienestar individual e interpersonal.

1. **Atención.** Las interrupciones constantes de nuestros aparatos tecnológicos minan nuestra capacidad de hacer foco tanto en una tarea que lo requiera como en nuestras relaciones interpersonales de la vida cotidiana –incluso cuando tenemos el dispositivo apagado, este reduce nuestra capacidad cognitiva (Ward et al., 2017)–.
2. **Salud mental.** La cantidad de amigos promedio que tienen las personas ha caído en los últimos años. Si bien las redes sociales se han ideado justamente para conectar a más personas, parece que su efecto ha sido más bien el opuesto. Se ha encontrado una correlación fuerte entre el sentimiento de soledad, la depresión, el estrés y el uso de las redes sociales (Zoller, 2019).
3. **Relaciones interpersonales.** Tener una conversación y un contacto persona a persona es muy diferente a tenerlo mediante una plataforma. Estas últimas crean una menor conexión emocional y corren con el riesgo de ser malinterpretadas de forma constante. Sabemos que hay muchísimas señales (tanto conscientes como inconscientes) que se pierden en un contacto meramente digital (Turkle, 2015).

4. **Grupos sociales vulnerables.** Los niños son un grupo especialmente vulnerable a las políticas de interacción de las plataformas, particularmente en lo que atañe al *bullying* y al uso de su imagen. Si bien las distintas plataformas ponen un límite de edad para que no ingresen menores de 13 años, no existe actualmente ninguna barrera efectiva para que ello se cumpla. También en los contextos escolares el uso del celular perjudica de manera significativa la capacidad de atención necesaria para las tareas que se requieren en su educación.

Las tecnologías actuales de redes sociales intentan maximizar sus beneficios al tratar de incrementar la cantidad de tiempo que el usuario pasa en ellas (y así poder mostrarle más publicidad y monetizar más). Si este es el interés dominante, entonces el objetivo de su diseño se encuentra en la vereda opuesta a un aumento en la calidad de vida de los usuarios. ¿Deben las redes sociales tener advertencias sobre el daño que puede ocasionar su uso excesivo tal como las tienen los cigarrillos, las bebidas alcohólicas o las azucaradas? ¿Sería efectivo un simple aviso como tal? Quizás lo que sea más efectivo sería pensar desde el diseño mismo de las plataformas, ajustadas a un marco regulatorio que priorice la salud de la población en general. Pero, ¿qué forma deberían tener tal diseño y tal marco regulatorio? En principio dos aspectos deben ser tenidos en cuenta:



- (a) Se deben visibilizar los problemas, recalcar que el uso (y abuso) de las plataformas no es para nada inocuo. Tanto desde el Estado como desde las compañías mismas pueden idearse (en conjunto y en paralelo) campañas para limitar el uso y ayudar a aquellas personas que tengan una relación problemática con las plataformas. Por ejemplo, el diseño mismo de la plataforma debe advertir el abuso que realiza el usuario de estas, informando el tiempo que pasa con ellas y mostrando efectivamente cómo esto lo perjudica.
- (b) Debe hacerse foco especialmente en los usuarios vulnerables como los niños. Podrían implementarse sanciones a las compañías que no traten activamente tanto de dar de baja a los usuarios activos que reconozcan como menores como no dejar dar de alta a quienes lo intenten.

¿Se podría exigir a las compañías que pongan un límite a la posible adicción a sus productos, tal como ha pasado con el caso de las tabacaleras y el cigarrillo?
¿Dañan nuestra salud psicológica y nuestras habilidades sociales para llevar una buena vida la manera en que las redes sociales están diseñadas?



Otro aspecto importante de las nuevas tecnologías, relacionado con el bienestar de la persona, es que sean reversibles, a saber, cualquier usuario tiene que estar en condiciones de volver a un estado anterior durante el uso de la tecnología, si considera que esta le está produciendo un daño de cualquier tipo. Los diseños tecnológicos tienen que promover una relación no alienante con la tecnología. Esto garantiza que la persona pueda tener el control de los artefactos y que su autonomía predomine frente a las diferentes formas de dependencia que malogren el ejercicio de su libertad.

El bienestar, los derechos humanos y la democracia.

La creación y la evaluación de la inteligencia artificial no debería ser indiferente al respeto y a la promoción de los derechos humanos –derechos inherentes a todos los seres humanos, sin distinción alguna de raza, sexo, nacionalidad, origen étnico, lengua, religión o cualquier otra condición–.

La Declaración Universal de los Derechos Humanos comprende los derechos civiles y políticos (por ejemplo, derecho a libertad de pensamiento, de conciencia y religión; la participación en asuntos públicos y elecciones; la protección de los derechos de las minorías, entre otros) y los derechos económicos, sociales y culturales (por ejemplo, el derecho a trabajar en condiciones justas y favorables; el derecho a la educación y a gozar de los beneficios derivados de la libertad cultural y el progreso científico; entre otros).

La inteligencia artificial puede promover una pérdida de derechos civiles, económicos, sociales y culturales o ampliar su disfrute. La clave residirá en el modo en que se diseñen e instrumenten esos sistemas tecnológicos; en definitiva, en la idea de bienestar que promuevan las empresas y los Estados que están detrás del desarrollo de los sistemas de inteligencia artificial, así

como también del papel que adopte la ciudadanía frente a los desafíos que supone esta tecnología.

El impacto de la inteligencia artificial sobre los derechos humanos tiene una dimensión individual y otra colectiva. La dimensión individual involucra el respeto de la dignidad humana con independencia de las características particulares que puede tomar una existencia humana, i.e., etnia, edad, nivel socio-económico, lugar de residencia, etc. La dimensión colectiva se refiere a la clase de sociedad que la inteligencia artificial contribuye a crear, i.e., sociedades más democráticas o más autoritarias, sociedades económicamente más justas o injustas; sociedades respetuosas del medio ambiente o sociedades indiferentes a la ecología del planeta, etc.



La promoción y la protección de los DDHH en los nuevos nichos artificiales

Las libertades individuales. Los riesgos debidos a la capacidad de la IA para rastrear y analizar nuestras vidas digitales se agravan por la gran cantidad de datos que producimos al emplear Internet. Con el creciente uso de dispositivos de Internet de las cosas y los intentos de cambiar hacia “ciudades inteligentes”, la gente creará un rastro de datos para casi todos los aspectos de sus vidas. Estos datos agregados revelan detalles sobre nuestras vidas. La IA los utilizará para procesarlos y analizarlos con diferentes propósitos, a saber, publicidad microdirigida, optimización del transporte público, vigilancia gubernamental de los ciudadanos, entre otros. En un mundo así, no solo existen enormes riesgos para las libertades individuales, sino que, además, se plantea si es posible o no resguardar esos datos.

El derecho a trabajar en condiciones justas y favorables. Si la automatización revoluciona el mercado laboral, puede ocurrir que un gran número de personas pierdan sus trabajos; sin embargo, tendrán que seguir luchando para mantenerse a sí mismas y a sus familias. ¿Cómo asegurar un trabajo y un nivel de vida digno con esta volatilidad en el mercado laboral?

El acoso en línea por parte de robots puede amenazar la libertad de expresión. Las cuentas de bots que se disfrazan de usuarios reales y envían respuestas automatizadas desproporcionadas a cuentas que comparten una determinada opinión pueden cercenar la libertad de expresión.

Pero también la organización política de los estados democráticos puede ser puesta en jaque por el desarrollo de la IA. Consideremos los siguientes factores.

Las diversas plataformas emergen como las nuevas plazas públicas. Pero ni son públicas, ni la información fluye de forma tan libre como en los lugares públicos (Eslami et al., 2016). Se crean en ellas “burbujas sociales” donde solo se encuentra la información que refuerza nuestra propia opinión. Por otro lado, las plataformas no parecen responsabilizarse completamente por las informaciones falsas que circulan y que perjudican tanto a los usuarios como a naciones enteras; tampoco protegen a los usuarios de los llamados trolls y del comportamiento anónimo malicioso, aun pudiendo hacerlo, ya que es un proceso económicamente muy costoso.

En un contexto donde la riqueza y el poder se están concentrando en un número cada vez más reducido de personas, el sueño transhumanista podría alterar completamente la vida social y política que hoy conocemos. Si las mejoras humanas que promueven las nuevas tecnologías se volviesen asequibles solo para unos pocos, cambiarían radicalmente las relaciones sociales actuales. Emergería una casta de humanos más longeva, más sana y con más capacidades que las del resto de la humanidad. Así, el transhumanismo podría encaminarnos hacia un nuevo orden mundial gobernado por élites que se han elegido y diseñado a sí mismas. En una sociedad en la que existan estas enormes diferencias, la desaparición de la democracia parece inevitable.

Veamos, finalmente, un ejemplo en el que podemos encontrar conjugadas varias de las dificultades éticas que hemos reseñado a lo largo del trabajo.

Consideremos el caso de un vehículo aéreo no tripulado (dron) equipado con sistemas de IA diseñado por una dependencia estatal, encargada de los programas de seguridad pública de un país en vías de desarrollo con un sistema democrático en consolidación. Este artefacto tiene la capacidad de recolectar, de procesar y de transmitir información en tiempo real en espacios abiertos y urbanos sin que sea detectado. Está diseñado para reconocer escenarios geográficos urbanos, identificar personas a través de reconocimiento de rostros y reconocer distintas clases de desplazamientos humanos para distinguir entre desplazamientos humanos “habituales” y desplazamientos humanos que puedan sugerir la comisión de un delito o similar.



Para valorar la manera en que se enlazan la tecnología con la sociedad, la noción de bienestar que se promueve, cómo aparecen los derechos humanos y cómo se modelan las prácticas sociales y la convivencia ciudadana, hay que tener en cuenta un conjunto de consideraciones que van desde las decisiones que se toman durante su diseño hasta la naturaleza y las características de los actores involucrados en su desarrollo y uso. Para qué se diseña y desarrolla y quiénes lo usan conlleva compromisos valorativos que pueden o no estar en tensión con las experiencias y con los sentimientos morales de un grupo social determinado.



Las tecnologías, como el dron de este ejemplo imaginario, no son soluciones valorativamente neutras. Para identificar esos compromisos valorativos y calibrarlos éticamente hay que responder, al menos, las siguientes 4 preguntas:

- Identificación de las funciones: ¿qué tareas realiza el artefacto?
- Identificación de recursos: ¿qué recursos materiales y cognitivos se necesitan para realizar este artefacto? La identificación de los recursos expertos necesarios contribuye a mapear los intereses y las estructuras de poder involucradas en el desarrollo de los artefactos.
- Identificación de los actores: ¿qué actores están involucrados en su desarrollo y uso? ¿Por qué razones los actores involucrados desarrollan el sistema tecnológico en cuestión? ¿Con quiénes se asocian para su desarrollo?
- Identificación de consecuencias: ¿qué consecuencias tiene para la vida humana, tanto a nivel social como individual, la introducción de este artefacto en su entorno? ¿Las prácticas sociales que esta tecnología introduce colisionan con los derechos humanos? ¿Con cuál o cuáles?

La resolución de estas preguntas explicita el punto de vista valorativo sobre el mundo que subyace a las tecnologías, así como las tensiones de naturaleza ética que podrían estar involucradas en los artefactos. La tecnología no es meramente instrumental, la mejor solución a un problema práctico planteado no es inocua ni está moralmente vacía. Veamos cómo se resuelven estas preguntas en el caso del ejemplo imaginado.

El dron –diseñado por una dependencia estatal encargada de la seguridad pública– tiene funciones particulares: reconocer escenarios geográficos urbanos, identificar personas a través de reconocimiento de rostros e identificar y reconocer distintos patrones de desplazamientos humanos. El propósito detrás de estas funciones es facilitar y precipitar la toma de decisiones de la policía de la ciudad para el control de manifestaciones o marchas masivas de ciudadanos.

Se trata de un artefacto que fusiona el control, la comunicación, la computación, la identificación y el reconocimiento. Esto le permite localizar liderazgos en los grupos

humanos movilizados, calcular la fuerza de la manifestación, identificar desplazamientos y rotular conductas humanas (por ejemplo, para identificar conductas violentas), para desarrollar estrategias de control en sentido amplio, esto es, de contención y de intervención.

La identificación de los recursos materiales y cognitivos necesarios plantea sus propios problemas, por ejemplo, ¿qué bases de datos habrán de alimentar los algoritmos del reconocimiento de rostros? ¿Los datos de registro de identidad de los ciudadanos? ¿Los registros de los ciudadanos con antecedentes policiales? ¿Qué patrones de conductas se suministran al algoritmo para que reconozca desplazamientos humanos peligrosos? ¿Qué significa “peligroso” aplicado a los movimientos humanos?



La identificación de actores involucrados en el desarrollo y en el uso del artefacto conlleva la explicitación de un conjunto de intereses y de valores particulares. En este caso, el artefacto está diseñado por la dependencia encargada de la seguridad pública, lo que implica que se desarrolla un punto de vista relacionado con el control de los ciudadanos a través del monitoreo de las concentraciones populares para definir sus contornos y desplazamientos en tiempo real, a través de la vigilancia, grabación y procesamiento de lo que sucede con la protesta. Puesto que se trata de una dependencia estatal encargada de la seguridad pública, la información recogida podría emplearse para abrir posibles expedientes de actuación a quienes participan en las movilizaciones –no solo sus líderes más visibles–, y transformarlos en evidencias judiciales, si la dependencia estatal lo considera conveniente.

El punto de vista que transmiten los drones de nuestro ejemplo, equipados con IA y desarrollados por la dependencia estatal de seguridad pública, está en tensión con la promoción y con el respeto de los derechos humanos. Una vez que se han introducido estos artefactos con estos propósitos en la vida social, ¿se garantiza el derecho a la libertad de expresión y movimiento, a reunirse y expresar las propias creencias sin temores de ninguna clase?

El ejemplo nos sugiere que la introducción de artefactos como estos en el entorno de una ciudad podría trastocar el modo en que los ciudadanos se conciben a sí mismos y perciben su papel en la esfera pública, donde se elaboran las cuestiones referidas al bien común de un grupo humano y a sus respectivas identidades prácticas.

Cuando los desarrolladores y las autoridades estatales justifican frente a la opinión pública las ventajas tecnológicas de los drones en materia de seguridad y de control social, los posicionan como instrumentos del poder estatal –por su capacidad de mantener el orden social–, y dejan de lado la manera en que esto disminuye el ejercicio de los derechos ciudadanos (la capacidad de manifestar demandas políticas y sociales en la calle).


Las prácticas que habilitan estas tecnologías (de monitoreo y control de las movilizaciones sociales) entran en tensión con los contenidos éticos básicos, asentados en la autonomía de la vida humana, consagrados en la Declaración Universal de los Derechos Humanos.

Los drones militares pueden convertirse en armas automáticas sin control humano. Imaginemos que están equipadas con un software que distingue objetos de personas humanas y luego disparan. Pero, ¿qué sucedería si en vez de un grupo de soldados terroristas se está frente a tres jóvenes cazando conejos? ¿Deben prohibirse los drones automáticos –sin control humano– como se encuentran actualmente prohibidas las armas químicas? La reflexión ética puede informar el debate en los organismos internacionales.



¿Quién es responsable de esta tecnología? ¿Quién debe rendir cuentas de su introducción en la vida social? El Estado es el actor principal en este caso y quien debería rendir cuentas puesto que ha diseñado e introducido la tecnología con un propósito determinado: el control social. En el caso de nuestro ejemplo esto tiene un impacto especial puesto que se trata de una sociedad cuya vida democrática está en un proceso de consolidación. Este componente cultural vuelve al Estado sospechoso en función de prácticas históricas previas vinculadas a la interrupción de procesos políticos democráticos. Esta identidad práctica social, asociada a la lucha por los derechos humanos, condiciona la percepción de este sistema tecnológico por parte de la población civil, así como también los motivos que impulsaron su creación y las decisiones que se tomaron durante su desarrollo para que tuviese unas funciones y no otras. De allí que toda valoración esté fuertemente asociada a un contexto con una historia.

Las decisiones que llevan a la producción de un sistema tecnológico están permeadas de valores que actúan como filtros, catalizadores y motivadores de elecciones en una u otra dirección. En el caso hipotético que nos ocupa, la tradición autoritaria de la vida política orienta la producción de un sistema tecnológico relacionado con el monitoreo especial del modo en que los movimientos políticos se comportan en la calle de sus ciudades. En definitiva, el sistema tecnológico que se introduce en la realidad no solo está permeado de valores, sino que no vive (o funciona) en ningún caso en un vacío tecno-socio-cultural-político. La comprensión acabada de estos contextos constituye una condición básica para comprender cuáles son las identidades prácticas en juego y sus respectivas narrativas históricas, que habrán de condicionar y dar forma a una tecnología determinada. Por consiguiente, no hay que analizar la tecnología aisladamente, sino en sus nichos sociales particulares, donde ella habrá de desarrollarse y vivir.



CONCLUSIÓN

A lo largo de este trabajo hemos señalado las complejidades inherentes a la evaluación ética de los desarrollos de sistemas que involucran IA. Estas complejidades están atadas a cuestiones fundamentales para la vida y las sociedades humanas que la filosofía busca desentrañar desde sus orígenes. ¿Qué cuenta como una vida buena? ¿Qué acciones son correctas moralmente y cuáles no lo son? ¿Qué responsabilidad tenemos cada uno de nosotros, desde nuestro particular lugar en el espacio público, en lo relativo a los cambios sociales y culturales en los que estamos inmersos? ¿A quién hay que responsabilizar de los problemas y situaciones conflictivas que vivimos? ¿Qué tipo de organización política hay que favorecer y qué acciones atentan contra esta forma de vida? ¿Qué cuenta como una sociedad justa? ¿Cuáles son los límites de la propiedad privada? ¿Qué derechos humanos reconoceremos como básicos e inalienables?

Como hemos argumentado a lo largo de este trabajo, todos estos problemas están presentes en el desarrollo y en el uso de los sistemas de IA. Las preguntas surgen y se complejizan con cada paso de las innovaciones tecnológicas que introducen en la vida humana estos sistemas. Hemos explicitado los diferentes problemas y preguntas que surgen a cada paso, e intentamos mostrar que la responsabilidad para que los desarrollos en IA resulten beneficiosos para la humanidad está repartida entre todos los actores involucrados: diseñadores, desarrolladores, empresarios, entidades gubernamentales y ciudadanos de a pie. La información compartida, la reflexión crítica y la educación son fundamentales para que todos estos actores ejerzan sus derechos y obligaciones en el desarrollo de una IA ética.

Referencias bibliográficas

Aristóteles, *Ética Nicomaquea* (5a ed., trad., de Antonio Gómez Robledo), Porrúa, México, 1973.

Aristóteles, *Obra biológica (De Partibus Animalium, De Motu Animalium, De Incessu Animalium)*. Edición al cuidado de Bartolomé, S. y Marcos, A., Luarna, Madrid, 2010.

Broncano, F., *Mundos artificiales. Filosofía del cambio técnico*, Paidós, México, 2000.

Burrell, J., *How the machine 'thinks': Understanding opacity in machine learning algorithms*. Big Data & Society. Disponible en: <https://doi.org/10.1177/2053951715622512>, 2016.

Clark, A. (ed.), *Supersizing the Mind: Embodiment, Action, and Cognitive Extension*, Oxford University Press, Oxford, 2008.

Clark, A., *Being There: Putting Brain, Body and World Together Again*, MIT Press, Cambridge, 1997.

Clark, A. y Chalmers, D. J., The extended mind, en *Analysis* 58 (1), 1998, pp. 7-19.

Domingos, P., A few useful things to know about machine learning, en *Communications of the ACM*, v.55 n.10, octubre de 2012. [doi>10.1145/2347736.2347755]

Eslami, E., Karahalios, K., Sandvig, C., Vaccaro, K., Rickman, A., Hamilton, K., Kirlik, A. y First, I. "like" it, then I hide it: Folk Theories of Social Feeds, Proceedings of the 2016 CHI Conference on Human Factors in Computing Systems, 2016, San Jose, California. [doi>10.1145/2858036.2858494]

Frankfurt, H. G., *The Reasons of Love*, Princeton University Press, Princeton, NJ, 2004.

Friedman, B. y Nissenbaum, H. Bias in computer systems, *ACM Transactions on Information Systems (TOIS)*, v.14 n.3, p.330-347, Julio 1996. [doi>10.1145/230538.230561]

Glenn, T. y Monteith, S., Privacy in the Digital World: Medical and Health Data Outside of HIPAA Protections, en *Current psychiatry reports*, 16, 494, 10.1007/s11920-014-0494-4, 2014.

Hill, R. K., What an algorithm is, en *Philosophy & Technology*, 29 (1), 2015, pp. 35-59.

Johnson, J. A., Technology and pragmatism: From value neutrality to value criticality, SSRN Scholarly Paper, Social Science Research Network, Rochester, NY, 2006. Disponible en: <http://papers.ssrn.com/abstract=2154654>

Kitchin, R., The ethics of smart cities and urban science, en *374 Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, 2016. <http://doi.org/10.1098/rsta.2016.0115>

Markowetz, A., Błaszczewicz, K., Montag, C., Switala, C. y Schlaepfer, T., Psycho-Informatics: Big Data shaping modern psychometrics, en *Medical hypotheses*, 82. 10.1016/j.mehy.2013.11.030, 2014.

Matthias A (2004) The responsibility gap: Ascribing responsibility for the actions of learning automata. *Ethics and Information Technology* 6(3): 175–183

Matthias A (2004) The responsibility gap: Ascribing responsibility for the actions of learning automata. *Ethics and Information Technology* 6(3): 175–183

Matthias A (2004) The responsibility gap: Ascribing responsibility for the actions of learning automata. *Ethics and Information Technology* 6(3): 175–183

Matthias, A., The responsibility gap: Ascribing responsibility for the actions of learning automata. *Ethics and Information Technology* 6 (3), 2004, pp. 175-183.

Mittelstadt, B. D., Allo, P., Taddeo, M., Wachter, S. y Floridi, L., The ethics of algorithms: Mapping the debate, en *Big Data & Society*, 2016. <https://doi.org/10.1177/2053951716679679>

Newell, S. y Marabelli, M., Strategic opportunities (and challenges) of algorithmic decision-making: A call for action on the long-term societal effects of 'datification', en *The Journal of Strategic Information Systems*, 24, 2015, pp. 3-14.

Ortega y Gasset, J., *Meditación de la técnica y otros ensayos sobre ciencia y filosofía*, Alianza Editorial, Madrid, 1998.

Pedace, K., *Mente y lenguaje. La filosofía de Donald Davidson, modelo para armar*, SADAFA, Buenos Aires, 2017.

Rawls, J., *A Theory of Justice*, Harvard University Press, Cambridge, MA, 1971 (edición revisada, 1999).

Raz, J., *The Authority of Law. Essays on Law and Morality*, Clarendon Press, Oxford, 1979.

Romei, A. y Ruggieri, S., A multidisciplinary survey on discrimination analysis, en *Knowledge Eng. Review*, 2014, 29, pp. 582-638.

Sadin, E., *La silicolonización del mundo*, Caja negra, Buenos Aires, 2018.

Schermer, B., The limits of privacy in automated profiling and data mining, en *Computer Law and Security Review*, 27, 2011, pp. 45-52. 10.1016/j.clsr.2010.11.009.

Shalev-Shwartz, S. y Ben-David, S., *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press, Nueva York, 2014.

Tene, O. y Polonetsky, J., Judged by the Tin Man: Individual Rights in the Age of Big Data, en *Journal of Telecommunications and High Technology Law*, agosto de 2013.

Turilli, M. y Floridi, L. The ethics of information transparency, en *Ethics Inf Technol*, 2009, 11: 105. <https://doi.org/10.1007/s10676-009-9187-9>

Turing, A. M., Computing Machinery and Intelligence, en *Mind*, 1950, 49, pp. 433-460.

Turkle, S., *Reclaiming conversation: The power of talk in a digital age*, Penguin Press, Nueva York, 2015.

Tutt, A., *An FDA for Algorithms*, en 69 Admin. L. Rev. 83, 2017. Disponible en SSRN: <https://ssrn.com/abstract=2747994> o en <http://dx.doi.org/10.2139/ssrn.2747994>

Ward, A. Duke, K. Gneezy, A. y Bos, M. A., Brain Drain: The Mere Presence of One's Own Smartphone Reduces Available Cognitive Capacity, en *Journal of the Association for Consumer Research* 2, n° 2, abril de 2017, pp. 140-154. <https://doi.org/10.1086/691462>

Yuste, R., Goering, S., Arcas, B., Bi, G., Carmena, J., Carter, A., Fins, J., Friesen, P., Gallant, J., Huggins, J., Illes, J., Kellmeyer, P., Klein, E., Marblestone, A., Mitchell, C., Parens, E., Pham, M., Ramos, K., Rommelfanger, K. y Wolpaw, J., Four ethical priorities for neurotechnologies and AI, en *Nature*, 551, 2017, pp. 159-163. 10.1038/551159a.

Zoller, Y., The costs of overprotecting the young - iGen: Why today's super-connected kids are growing up less rebellious, more tolerant, less happy -and completely unprepared for adulthood- and what that means for the rest of us by Jean M. Twenge, en *The American Journal of Psychology*, 2019,132, pp. 115-119.

Descargo de responsabilidad. Las opiniones expresadas en la publicación incumben únicamente a los/as autores/as. No tienen intención de reflejar las opiniones o perspectivas de ninguna otra organización involucrada en el proyecto.