

Álgebra Lineal Aplicada a la Inteligencia Artificial

Matemáticas para la IA — Licenciatura en Inteligencia Artificial

Material de clase — Nivel introductorio

Introducción

En IA, prácticamente todo se representa con vectores y matrices: una imagen es una matriz de píxeles, un texto se convierte en vectores (*embeddings*), una red neuronal es una composición de multiplicaciones de matrices. Sin álgebra lineal, no hay IA moderna.

Este documento cubre los conceptos fundamentales con ejemplos resueltos y su conexión con la práctica de la Inteligencia Artificial.

1. Vectores

Un **vector** es una lista ordenada de números. Geométricamente, es una flecha desde el origen hasta un punto en el espacio.

$$\vec{v} = \begin{pmatrix} 3 \\ 2 \end{pmatrix} \in \mathbb{R}^2$$

En IA los vectores están en todos lados:

- Un píxel en color = vector de 3 números (R, G, B).
- Una palabra en un modelo de lenguaje = vector de cientos o miles de números (*embedding*).
- Las características de una casa (m², cuartos, precio...) = un vector.

Operaciones básicas

Suma (componente a componente):

$$\begin{pmatrix} 1 \\ 2 \end{pmatrix} + \begin{pmatrix} 3 \\ 1 \end{pmatrix} = \begin{pmatrix} 4 \\ 3 \end{pmatrix}$$

Multiplicación por escalar:

$$3 \cdot \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 6 \\ 3 \end{pmatrix}$$

Producto punto (dot product) — central en IA:

$$\vec{u} \cdot \vec{v} = u_1 v_1 + u_2 v_2 + \cdots + u_n v_n$$




Figura 1: Vector en el plano

Ejemplo:

$$\begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} \cdot \begin{pmatrix} 4 \\ 5 \\ 6 \end{pmatrix} = 1 \cdot 4 + 2 \cdot 5 + 3 \cdot 6 = 32$$

El producto punto mide **cuánto se parecen** dos vectores. Es la base de la **similitud coseno**, que usan buscadores, sistemas de recomendación y motores de búsqueda semántica.

2. Espacio Vectorial

Un **espacio vectorial** V es un conjunto de vectores donde:

1. Sumar dos vectores da otro vector del mismo conjunto.
2. Multiplicar por un escalar da otro vector del conjunto.
3. Cumplen propiedades como asociatividad, existencia del vector cero y del inverso.

Ejemplos:

- $\mathbb{R}^2$: todos los pares (x, y) .
- $\mathbb{R}^n$: todas las n -tuplas de reales. **Este es el espacio donde vive la IA.**
- El conjunto de todas las imágenes de 28×28 píxeles (como en MNIST) es un espacio vectorial de dimensión 784.

Span (combinación lineal generada)

El **span** de un conjunto de vectores es *todo lo que se puede construir* combinándolos linealmente:

$$\text{span}\{\vec{v}_1, \vec{v}_2\} = \{a\vec{v}_1 + b\vec{v}_2 : a, b \in \mathbb{R}\}$$

Ejemplo: el span de $\vec{v}_1 = (1, 0)$ y $\vec{v}_2 = (0, 1)$ es todo $\mathbb{R}^2$, porque cualquier vector (x, y) se escribe como $x(1, 0) + y(0, 1)$.

3. Dependencia e Independencia Lineal

Un conjunto de vectores es **linealmente independiente** si ninguno se puede escribir como combinación de los otros. Formalmente:

$$a_1\vec{v}_1 + a_2\vec{v}_2 + \dots + a_n\vec{v}_n = \vec{0} \implies a_1 = a_2 = \dots = a_n = 0$$

Si existen escalares no todos cero que dan $\vec{0}$, son **linealmente dependientes**.

Ejemplo 1 (independientes):

$$\vec{v}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad \vec{v}_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

No se puede escribir uno como múltiplo del otro.

Ejemplo 2 (dependientes):

$$\vec{v}_1 = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad \vec{v}_2 = \begin{pmatrix} 2 \\ 4 \end{pmatrix}$$

Aquí $\vec{v}_2 = 2\vec{v}_1$. Son colineales.

Por qué importa en IA: si las *features* (columnas de datos) son linealmente dependientes, hay información redundante. Es lo que se llama **multicolinealidad** en regresión, y rompe muchos algoritmos.

4. Matrices

Una **matriz** es un arreglo rectangular de números:

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix} \in \mathbb{R}^{2 \times 3}$$

Tiene 2 filas y 3 columnas.

En IA:

- Un dataset con m ejemplos y n features es una matriz $m \times n$.
- Los pesos de una capa de red neuronal son una matriz.
- Una imagen en escala de grises **es** una matriz.

Operaciones

Suma (matrices del mismo tamaño):

$$\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} + \begin{pmatrix} 5 & 6 \\ 7 & 8 \end{pmatrix} = \begin{pmatrix} 6 & 8 \\ 10 & 12 \end{pmatrix}$$

Multiplicación por escalar:

$$2 \cdot \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} = \begin{pmatrix} 2 & 4 \\ 6 & 8 \end{pmatrix}$$

Producto matricial (el corazón de las redes neuronales): $A_{m \times n} \cdot B_{n \times p} = C_{m \times p}$. Cada elemento c_{ij} es el producto punto de la fila i de A con la columna j de B .

Ejemplo paso a paso:

$$A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}, \quad B = \begin{pmatrix} 5 & 6 \\ 7 & 8 \end{pmatrix}$$

$$c_{11} = 1 \cdot 5 + 2 \cdot 7 = 19$$

$$c_{12} = 1 \cdot 6 + 2 \cdot 8 = 22$$

$$c_{21} = 3 \cdot 5 + 4 \cdot 7 = 43$$

$$c_{22} = 3 \cdot 6 + 4 \cdot 8 = 50$$

$$AB = \begin{pmatrix} 19 & 22 \\ 43 & 50 \end{pmatrix}$$

Traspuesta (A^T): filas se vuelven columnas.

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix} \Rightarrow A^T = \begin{pmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{pmatrix}$$

Matriz por vector — una matriz *transforma* un vector:

$$\begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 2 \\ 3 \end{pmatrix}$$

Esta idea (matriz = transformación) es fundamental: una capa de red neuronal es exactamente eso, una transformación matricial aplicada a un vector de entrada.

5. Determinantes

El **determinante** es un número asociado a una matriz cuadrada que nos dice:

- Si vale 0 $\rightarrow$ la matriz es **singular** (no invertible, sus columnas son linealmente dependientes).
- Su valor absoluto = cuánto la matriz **escala áreas/volúmenes** al transformar el espacio.

Matriz 2×2 :

$$\det \begin{pmatrix} a & b \\ c & d \end{pmatrix} = ad - bc$$

Ejemplo:

$$\det \begin{pmatrix} 3 & 1 \\ 2 & 4 \end{pmatrix} = 3 \cdot 4 - 1 \cdot 2 = 10$$

Matriz 3×3 (regla de Sarrus):

$$\det \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & i \end{pmatrix} = aei + bfg + cdh - ceg - bdi - afh$$

Ejemplo:

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 4 \\ 5 & 6 & 0 \end{pmatrix}$$

$$\begin{aligned} \det(A) &= 1(1 \cdot 0 - 4 \cdot 6) - 2(0 \cdot 0 - 4 \cdot 5) + 3(0 \cdot 6 - 1 \cdot 5) \\ &= 1(-24) - 2(-20) + 3(-5) = -24 + 40 - 15 = 1 \end{aligned}$$

Como $\det(A) = 1 \neq 0$, la matriz es invertible.

6. Rango, Núcleo e Imagen

Estos tres conceptos describen la “estructura” de una matriz como transformación.

Imagen (Image / Range)

$$\text{Im}(A) = \{A\vec{x} : \vec{x} \in \mathbb{R}^n\}$$

Es el conjunto de todos los vectores que se pueden obtener aplicando A . Es el **span de las columnas** de A .

Núcleo (Kernel / Ker)

$$\text{Ker}(A) = \{\vec{x} : A\vec{x} = \vec{0}\}$$

Es el conjunto de vectores que A “aplasta” al cero.

Rango (Rank)

$$\text{rank}(A) = \dim(\text{Im}(A))$$

Es el número de columnas linealmente independientes de A (equivalentemente, filas independientes).

Teorema Fundamental (Rango-Nulidad)

$$\dim(\text{Ker}(A)) + \text{rank}(A) = n$$

donde n es el número de columnas de A .

Ejemplo completo:

$$A = \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix}$$

- Las columnas son $(1, 2)$ y $(2, 4) = 2(1, 2) \rightarrow$ linealmente dependientes.
- $\text{rank}(A) = 1$.
- $\text{Im}(A) = \text{span}\{(1, 2)\} =$ una recta en $\mathbb{R}^2$.
- $\text{Ker}(A)$: resolvemos $A\vec{x} = \vec{0}$: $x_1 + 2x_2 = 0 \Rightarrow x_1 = -2x_2$. Entonces $\text{Ker}(A) = \{t(-2, 1) : t \in \mathbb{R}\}$, una recta.
- $\dim(\text{Ker}(A)) = 1$. Se cumple: $1 + 1 = 2$ columnas.

Por qué importa en IA: en PCA (Análisis de Componentes Principales), el rango de la matriz de datos indica la dimensión "real" de la información. Si el rango es menor que el número de columnas, hay redundancia y se puede reducir la dimensionalidad.

7. Matrices Especiales

Matriz identidad

$$I = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

Cumple $IA = AI = A$. Es el "1" de las matrices.

Matriz simétrica

$A = A^T$, es decir, $a_{ij} = a_{ji}$.

$$S = \begin{pmatrix} 2 & 3 & 1 \\ 3 & 5 & 4 \\ 1 & 4 & 6 \end{pmatrix}$$

En IA: la matriz de covarianza (base de PCA) y las Hessianas (segundas derivadas, para optimización) son simétricas.

Matriz ortogonal

$Q^T Q = I$, es decir, $Q^{-1} = Q^T$. Sus columnas son vectores unitarios ortogonales entre sí. Representan **rotaciones o reflexiones**: preservan longitudes y ángulos.

Ejemplo (rotación de 90°):

$$Q = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}, \quad Q^T Q = I$$

Matriz definida positiva

Una matriz simétrica A es **definida positiva** si para todo vector $\vec{x} \neq \vec{0}$:

$$\vec{x}^T A \vec{x} > 0$$

Equivalentemente: **todos sus autovalores son positivos**.

Ejemplo:

$$A = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}, \quad \vec{x}^T A \vec{x} = 2x_1^2 + 3x_2^2 > 0$$

En IA: cuando la Hessiana es definida positiva en un punto crítico, ese punto es un **mínimo local**. Es lo que garantiza convergencia en optimización convexa.

Matriz dispersa (sparse)

Una matriz donde la mayoría de las entradas son cero.

$$\begin{pmatrix} 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 0 \\ 5 & 0 & 0 & 0 \\ 0 & 0 & 0 & 7 \end{pmatrix}$$

En IA: matrices de texto (bag-of-words), grafos de redes sociales, matrices de recomendación (usuarios $\times$ películas). Se guardan en formatos especiales (CSR, COO) para ahorrar memoria y acelerar cálculos.

8. Autovalores y Autovectores

Probablemente el **concepto más importante** del módulo.

Un **autovector** $\vec{v}$ de una matriz A es un vector especial que, al ser transformado por la matriz, no cambia de dirección: solo se estira o encoge. Ese factor de estiramiento es el **autovalor** λ .

$$A\vec{v} = \lambda\vec{v}$$

Cómo calcularlos

Se resuelve la **ecuación característica**:

$$\det(A - \lambda I) = 0$$

Ejemplo completo:

$$A = \begin{pmatrix} 4 & 1 \\ 2 & 3 \end{pmatrix}$$

Paso 1 — plantear $A - \lambda I$:

$$A - \lambda I = \begin{pmatrix} 4 - \lambda & 1 \\ 2 & 3 - \lambda \end{pmatrix}$$




Figura 2: Intuición del autovector

Paso 2 — calcular el determinante:

$$\det = (4 - \lambda)(3 - \lambda) - 2 = \lambda^2 - 7\lambda + 10$$

Paso 3 — resolver $\lambda^2 - 7\lambda + 10 = 0$:

$$\lambda = \frac{7 \pm \sqrt{49 - 40}}{2} = \frac{7 \pm 3}{2}$$

$$\lambda_1 = 5, \quad \lambda_2 = 2$$

Paso 4 — para cada λ , hallar el autovector resolviendo $(A - \lambda I)\vec{v} = \vec{0}$.

Para $\lambda_1 = 5$:

$$\begin{pmatrix} -1 & 1 \\ 2 & -2 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \vec{0} \Rightarrow v_1 = v_2 \Rightarrow \vec{v}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

Para $\lambda_2 = 2$:

$$\begin{pmatrix} 2 & 1 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \vec{0} \Rightarrow 2v_1 + v_2 = 0 \Rightarrow \vec{v}_2 = \begin{pmatrix} 1 \\ -2 \end{pmatrix}$$

En IA: PCA encuentra los autovectores de la matriz de covarianza — son las direcciones de máxima varianza. Google PageRank es un problema de autovectores. La estabilidad de sistemas dinámicos depende de autovalores.

9. Teorema Espectral

Una joya del álgebra lineal:

Teorema espectral: Toda matriz simétrica real A puede descomponerse como

$$A = Q\Lambda Q^T$$

donde Q es una matriz ortogonal (columnas = autovectores) y Λ es diagonal (autovalores).

Consecuencias:

- Los autovalores de una matriz simétrica son **reales**.
- Sus autovectores son **ortogonales entre sí**.
- Forman una **base** del espacio.

En IA: este teorema hace funcionar PCA. La matriz de covarianza es simétrica, así que se puede descomponer en direcciones perpendiculares (los componentes principales), cada una con una varianza asociada (el autovalor).

10. Función Convexa

Una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es **convexa** si para todo $\vec{x}, \vec{y}$ y $t \in [0, 1]$:

$$f(t\vec{x} + (1-t)\vec{y}) \leq tf(\vec{x}) + (1-t)f(\vec{y})$$

Geoméricamente: el segmento que une dos puntos del gráfico queda por encima o sobre la curva.




Figura 3: Función convexa

Ejemplos:

- $f(x) = x^2$ es convexa.
- $f(x) = e^x$ es convexa.
- La función de pérdida en **regresión lineal** (MSE) es convexa.

Criterio con matrices: f es convexa si su **Hessiana** (matriz de segundas derivadas) es **definida positiva**. Aquí se conectan todos los conceptos.

Por qué importa muchísimo en IA:

- Si la función de pérdida es convexa $\rightarrow$ el descenso por gradiente encuentra el **mínimo global**.
- Si no lo es (como en redes neuronales profundas) $\rightarrow$ solo encontramos mínimos locales, y por eso entrenar es difícil.

11. Resumen conceptual y conexiones

Concepto	Idea	Uso típico en IA
Vector	Punto/dirección en $\mathbb{R}^n$	Embeddings, features
Producto punto	Medida de similitud	Búsqueda semántica
Matriz	Transformación / dataset	Capas de redes neuronales
Determinante	Escala del volumen	Detectar singularidad
Rango	Info independiente	Reducción de dimensionalidad
$\text{Ker}(A)$	Info que se pierde	Compresión, PCA
Autovalores/vectores	Direcciones invariantes	PCA, PageRank
Teorema espectral	Descomposición simétricas	PCA, SVD
Def. positiva	Curvatura hacia arriba	Optimización
Función convexa	Un solo mínimo	Convergencia garantizada
Ortogonal	Rotación pura	Númerica estable
Dispersa	Casi todo cero	NLP, grafos, recomendación

12. Ejercicios para practicar

1. Calcular $\det \begin{pmatrix} 2 & -1 \\ 3 & 4 \end{pmatrix}$.
2. Verificar si $(1, 2)$ y $(3, 6)$ son linealmente independientes.
3. Multiplicar $\begin{pmatrix} 1 & 0 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} 3 \\ 4 \end{pmatrix}$.
4. Hallar autovalores de $\begin{pmatrix} 2 & 0 \\ 0 & 5 \end{pmatrix}$.
5. Demostrar que $f(x) = x^2 + 3x + 1$ es convexa.

Próximos temas sugeridos:

- SVD (Descomposición en Valores Singulares) — la generalización del teorema espectral.
- Caso práctico de PCA paso a paso con datos reales.
- Implementación en NumPy.