

Matemáticas para la IA

Cálculo aplicado al aprendizaje de modelos

Licenciatura en Inteligencia Artificial · Material introductorio

Contenido
1. Análisis de funciones reales: dominio, imagen, continuidad y gráfica
2. Límites y derivadas: crecimiento, decrecimiento y extremos
3. Integrales indefinidas y definidas: áreas, acumulación, promedios
4. Estudio completo de la pérdida cuadrática (MSE)
5. Ejercicios propuestos

1. Análisis de funciones reales

Bienvenidos. Vamos a recorrer cuatro bloques que forman la columna vertebral del cálculo diferencial e integral orientado a IA. La idea no es memorizar fórmulas, sino **entender qué mira un modelo cuando aprende**. Aprender, matemáticamente, es minimizar una función de pérdida; y para minimizar hay que saber leer funciones.

1.1 ¿Qué es una función y por qué nos importa en IA?

Una función real de variable real es una regla $f : A \subseteq \mathbb{R} \rightarrow \mathbb{R}$ que a cada $x \in A$ le asigna un **único** valor $f(x) \in \mathbb{R}$. En IA aparece constantemente:

- Una **neurona artificial** calcula $y = \sigma(wx + b)$, con σ una activación (sigmoide, ReLU, tanh).
- Una **regresión lineal simple** es $\hat{y} = wx + b$.
- Una **pérdida cuadrática** para un solo dato es $L(w) = (wx - y)^2$.

1.2 Dominio

El dominio $\text{Dom}(f)$ es el conjunto de valores de x para los que $f(x)$ tiene sentido. Reglas prácticas:

- Denominadores $\neq 0$.
- Radicandos de raíces pares ≥ 0 .
- Argumentos de logaritmos > 0 .

Ejemplo 1 — Dominio de una activación

La **sigmoide** $\sigma(x) = 1 / (1 + e^{-x})$ tiene dominio $\mathbb{R}$ completo porque $1 + e^{-x} > 0$ siempre. Puede recibir cualquier «logit» sin romperse.

La **entropía cruzada binaria** $H(p) = -[y \cdot \log(p) + (1-y) \cdot \log(1-p)]$ exige $p \in (0, 1)$ estrictamente, porque $\log(0)$ no existe. Por eso en la práctica se aplica *clipping* o se combina con la sigmoide de forma numéricamente estable.

1.3 Imagen (o rango)

La imagen $\text{Im}(f)$ es el conjunto de valores que efectivamente toma f .




Figura 1. Tres activaciones clásicas. $\text{Im}(\sigma) = (0,1)$; $\text{Im}(\tanh) = (-1,1)$; $\text{Im}(\text{ReLU}) = [0, +\infty)$.

Consecuencias en IA: la sigmoide se interpreta como probabilidad; la tanh está centrada en cero (favorece la propagación de gradientes); la ReLU sólo produce salidas no negativas, lo que genera el fenómeno de «neuronas muertas».

1.4 Continuidad

f es continua en x_0 si $\lim_{x \rightarrow x_0} f(x) = f(x_0)$. Intuitivamente, la gráfica no se corta.




Figura 2. La función escalón es discontinua en 0 (salto de 0 a 1); la ReLU es continua en todo x .

¿Por qué importa? El descenso por gradiente asume regularidad. Una discontinuidad genera saltos que impiden convergencia suave. La función escalón (perceptrón original) no se usa hoy como activación entrenable justamente por eso.

1.5 Comportamiento gráfico

Analizar la gráfica implica estudiar: **simetrías** (par/impar), **asíntotas** (horizontales, verticales, oblicuas), **intersecciones** con los ejes y **signo** por intervalos.

La sigmoide tiene asíntotas horizontales en $y=0$ ($x \rightarrow -\infty$) e $y=1$ ($x \rightarrow +\infty$), y es simétrica respecto al punto $(0, \frac{1}{2})$. Estas propiedades explican por qué **satura**: para $|x|$ grande su pendiente es casi cero. Este hecho es la raíz del problema del *vanishing gradient*, que trataremos en el bloque siguiente.

2. Límites y derivadas

2.1 Límites: aproximación y comportamiento asintótico

El límite $\lim_{x \rightarrow x_0} f(x) = L$ significa que a medida que x se acerca a x_0 , $f(x)$ se acerca arbitrariamente a L . Los límites al infinito describen el comportamiento asintótico.

$$\lim_{x \rightarrow +\infty} \sigma(x) = 1 \quad \lim_{x \rightarrow -\infty} \sigma(x) = 0$$

Estos dos límites **formalizan** la saturación de la sigmoide observada en la Figura 1.

2.2 Derivada: pendiente instantánea y motor del aprendizaje

$$f'(x_0) = \lim_{h \rightarrow 0} [f(x_0+h) - f(x_0)] / h$$

Geométricamente, es la pendiente de la recta tangente. En IA, **es la señal que le dice al modelo hacia dónde moverse para reducir el error**. El descenso por gradiente actualiza los parámetros con:

$$w_{n+1} = w_n - \eta \cdot L'(w_n)$$

donde η es la tasa de aprendizaje. Si no supiéramos derivar, no habría entrenamiento.




Figura 3. La derivada $f'(x_0)$ es la pendiente de la recta tangente a la gráfica en $(x_0, f(x_0))$.

2.3 Reglas fundamentales

- Suma: $(f + g)' = f' + g'$
- Producto: $(f \cdot g)' = f' \cdot g + f \cdot g'$
- Cociente: $(f/g)' = (f' \cdot g - f \cdot g') / g^2$
- Cadena: $(f \circ g)'(x) = f'(g(x)) \cdot g'(x)$

La regla de la cadena es **el corazón matemático del backpropagation**: cuando una red profunda calcula el gradiente de la pérdida respecto a un peso enterrado en varias capas, aplica la cadena repetidamente.

2.4 Crecimiento, decrecimiento, puntos críticos y extremos

Si $f'(x) > 0$ en un intervalo, f es creciente allí; si $f'(x) < 0$, es decreciente. Los puntos donde $f'(x) = 0$ (o no existe) se llaman **puntos críticos**, candidatos a extremos. Criterio de la segunda derivada:

- $f'(x_0) = 0$ y $f''(x_0) > 0 \Rightarrow$ mínimo local (convexa)
- $f'(x_0) = 0$ y $f''(x_0) < 0 \Rightarrow$ máximo local
- $f''(x_0) = 0 \Rightarrow$ el criterio no decide

Ejemplo 2 — Estudio de $f(x) = x^3 - 3x$

Derivamos: $f'(x) = 3x^2 - 3 = 3(x-1)(x+1)$. Los puntos críticos son $x = -1$ y $x = 1$.

Segunda derivada: $f''(x) = 6x$. Entonces $f''(-1) = -6 < 0$ (máximo local) y $f''(1) = 6 > 0$ (mínimo local). Valores: $f(-1) = 2$, $f(1) = -2$.




Figura 4. La función crece donde $f' > 0$ (verde) y decrece donde $f' < 0$ (rojo). Los puntos críticos separan las regiones.

Interpretación en IA. Entrenar un modelo consiste en encontrar un mínimo (idealmente global) de la función de pérdida. El descenso por gradiente busca puntos con $\nabla L = 0$, y la geometría local (segunda derivada, o Hessiana en varias variables) nos dice si estamos en un mínimo genuino o en un punto silla.

2.5 Ejemplo trabajado: derivada de la sigmoide y gradiente que se desvanece

Aplicando cociente y cadena a $\sigma(x) = 1/(1 + e^{-x})$ se llega a la identidad elegante:

$$\sigma'(x) = \sigma(x) \cdot (1 - \sigma(x))$$

Cuando $\sigma(x) \approx 0$ o $\sigma(x) \approx 1$, la derivada es casi cero. Es decir, **el gradiente muere en las zonas saturadas**: por eso las redes profundas con muchas sigmoides son difíciles de entrenar, y este análisis fue una de las motivaciones para adoptar ReLU.




Figura 5. σ (azul) y σ' (rojo). Las bandas rojas marcan las zonas donde el gradiente es prácticamente nulo.

3. Integrales indefinidas y definidas

3.1 Integral indefinida (antiderivada)

Dada f , buscamos F tal que $F'(x) = f(x)$. Se escribe:

$$\int f(x) dx = F(x) + C$$

Es la operación inversa a derivar. La constante C aparece porque muchas funciones tienen la misma derivada.

Ejemplo 3 — Antiderivadas frecuentes en IA

- $\int x^n dx = x^{n+1}/(n+1) + C$ (con $n \neq -1$)
- $\int e^x dx = e^x + C$ (importante en gaussianas, softmax)
- $\int 1/x dx = \ln|x| + C$ (relacionado con entropía y verosimilitud logarítmica)

3.2 Integral definida: área bajo la curva

$$\int_a^b f(x) dx = \text{área con signo entre } f \text{ y el eje } x, \text{ en } [a, b]$$

El **Teorema Fundamental del Cálculo** conecta ambas ideas: si F es cualquier primitiva de f , entonces

$$\int_a^b f(x) dx = F(b) - F(a)$$




Figura 6. La integral definida representa geoméricamente el área encerrada entre la curva y el eje x .

Ejemplo 4 — Cálculo directo

Calcular $\int_0^2 (x^2 + 1) dx$.

Antiderivada: $F(x) = x^3/3 + x$.

$F(2) - F(0) = (8/3 + 2) - 0 = 14/3 \approx 4.667$.

3.3 Acumulación y promedio

La integral es **suma continua**. Si $f(t)$ es una tasa (velocidad, error instantáneo, densidad), la integral acumula. El **promedio** de f en $[a, b]$ es:

$$\bar{f} = (1 / (b - a)) \cdot \int_a^b f(x) dx$$




Figura 7. La línea punteada representa el promedio: el nivel constante que encierra la misma área que la función.

3.4 Aplicación en IA: pérdida media y esperanza

Cuando entrenás con muchos datos, la pérdida global es un promedio (caso discreto):

$$L(\theta) = (1/N) \sum_{i=1..N} \ell(f_{\theta}(x_i), y_i)$$

En el marco teórico, los datos son una distribución $p(x, y)$. La **pérdida esperada** (o riesgo) es una integral:

$$R(\theta) = \iint \ell(f_{\theta}(x), y) \cdot p(x, y) dx dy$$

La suma discreta es una aproximación de Monte Carlo a esta integral. En teoría de la información aparecen integrales similares: entropía diferencial $H(p) = - \int p(x) \log p(x) dx$, divergencia KL, etc.

Ejemplo 5 — El AUC es literalmente un área

El AUC (Area Under the ROC Curve), una métrica clave de clasificación, es exactamente una integral: $AUC = \int_0^1 TPR(FPR^{-1}(t)) dt$. Analizar modelos con curvas ROC, PR o de calibración es analizar áreas.

4. Estudio completo: pérdida cuadrática (MSE)

Vamos a integrar todo lo anterior en un ejemplo que verás en la primera clase de aprendizaje supervisado.

4.1 Planteo

Datos $\{(x_i, y_i)\}_{i=1..N}$; modelo lineal sin sesgo $\hat{y} = w \cdot x$. La pérdida cuadrática media (MSE) es:

$$L(w) = (1/N) \sum_{i=1..N} (w \cdot x_i - y_i)^2$$

Objetivo: encontrar w^* que minimice $L(w)$.

4.2 Análisis de la función $L(w)$

Dominio. $\text{Dom}(L) = \mathbb{R}$ (sin divisiones ni raíces problemáticas).

Imagen. $L(w) \geq 0$ por ser suma de cuadrados. $\text{Im}(L) = [L_{\min}, +\infty)$.

Continuidad y regularidad. Es un polinomio de grado 2 en w , continuo y derivable infinitas veces: el escenario ideal para el descenso por gradiente.

Desarrollando la suma:

$$L(w) = A \cdot w^2 - 2B \cdot w + C, \text{ con } A = (1/N) \sum x_i^2, B = (1/N) \sum x_i y_i, C = (1/N) \sum y_i^2$$

Es una **parábola** que abre hacia arriba ($A \geq 0$). Si al menos un $x_i \neq 0$, hay un **único mínimo global**. Esta propiedad, la **convexidad**, es lo que hace de la regresión lineal un problema «amable».

4.3 Derivada, punto crítico y solución analítica

$$L'(w) = 2A \cdot w - 2B \Rightarrow w^* = B / A = (\sum x_i y_i) / (\sum x_i^2)$$

Segunda derivada: $L''(w) = 2A > 0$ confirma que es **mínimo**. Antes de w^* la función decrece; después crece.




Figura 8. Izquierda: datos y la recta óptima ajustada por mínimos cuadrados. Derecha: la pérdida $L(w)$ como parábola convexa con su mínimo global.

Ejemplo 6 — Cálculo numérico paso a paso

Con 3 puntos: (1, 2), (2, 3.9), (3, 6.1). Entonces:

$$\sum x_i^2 = 1 + 4 + 9 = 14.$$

$$\sum x_i y_i = 1 \cdot 2 + 2 \cdot 3.9 + 3 \cdot 6.1 = 2 + 7.8 + 18.3 = 28.1.$$

Por tanto $w^* = 28.1 / 14 \approx 2.007$. El modelo óptimo es $\blacksquare \approx 2.007 \cdot x$, consistente con la relación aparente $y \approx 2x$.

4.4 Descenso por gradiente: el rol de la tasa de aprendizaje

Aunque tenemos solución cerrada, entrenemos «a mano» con gradiente para ver el mecanismo:

$$w_{n+1} = w_n - \eta \cdot (2A \cdot w_n - 2B)$$

La convergencia depende críticamente de η . Se puede demostrar que hay convergencia si y sólo si $\eta < 1/A$.




Figura 9. Tres regímenes del descenso por gradiente sobre la misma parábola. Estrella verde = mínimo global; puntos rojos = iteraciones sucesivas.

Este es tu primer contacto con el **tuning de hiperparámetros**, y sale enteramente del análisis de la segunda derivada (que determina la curvatura A).

4.5 Interpretación integral: pérdida empírica vs. esperada

Si pensamos los datos como muestras de una distribución conjunta $(X, Y) \sim p$, la pérdida esperada es:

$$R(w) = E[(wX - Y)^2] = \iint (w \cdot x - y)^2 p(x, y) dx dy$$

La $L(w)$ empírica es una aproximación de esta integral: minimizar $L(w)$ es intentar minimizar $R(w)$. Ésta es la conexión formal entre **datos finitos** y **teoría estadística**.

4.6 Decisiones de optimización a partir del estudio gráfico

De la parábola $L(w)$ se leen decisiones prácticas:

- **Valor del mínimo** $L(w^*)$: cuán bien puede ajustar el modelo (mide el ruido irreducible).
- **Curvatura** $2A$: define el paso máximo admisible. A grande $\Rightarrow \eta$ pequeña; A chica $\Rightarrow \eta$ mayor.
- Si A es muy chica, el mínimo está mal condicionado y el entrenamiento será lento e inestable. Esto motiva técnicas como **feature scaling** (normalizar las x_i).

En modelos más complejos (redes profundas), la pérdida deja de ser convexa y aparecen múltiples mínimos locales, puntos silla y regiones planas. Pero las **herramientas conceptuales** son las mismas que usamos hoy: dominio, continuidad, derivadas, puntos críticos, segunda derivada, integrales para promediar.

5. Ejercicios propuestos

1. Determiná dominio, imagen y asíntotas de la función softplus $f(x) = \ln(1 + e^x)$. Mostrá que su derivada es la sigmoide.
2. Sea $f(x) = x^3 - 4x^2$. Encontrá los puntos críticos, clasificalos y hacé un bosquejo.
3. Calculá $\int_0^1 (2x + 3) dx$ y verificá con el TFC.
4. **Ejercicio integrador (recomendado).** Repetir el estudio del bloque 4 con la pérdida cuadrática **con sesgo**: $\hat{y} = w \cdot x + b$. Buscar el mínimo respecto a las dos variables (w , b) e identificar el sistema de ecuaciones normales. Este ejercicio será la puerta natural al cálculo en varias variables, nuestro próximo tema.
5. Con los datos (1, 2), (2, 3.9), (3, 6.1), (4, 8.2), calculá w^* usando la fórmula $w^* = \Sigma x_i y_i / \Sigma x_i^2$ y luego computá $L(w^*)$.

Cierre. Cada concepto de cálculo tiene una traducción concreta en IA: dominio e imagen restringen qué activaciones y pérdidas son válidas; continuidad y derivabilidad habilitan el descenso por gradiente; los límites explican saturaciones y vanishing gradients; las derivadas dirigen la actualización de parámetros; las segundas derivadas informan sobre convexidad y estabilidad; las integrales formalizan promedios, riesgos esperados y métricas de evaluación.