

Matemáticas para la IA

Resumen de clase: vectores, matrices, transformaciones y dependencia lineal

Este documento resume los conceptos fundamentales que discutimos durante nuestra clase introductoria. Está pensado como material de estudio, siguiendo el orden natural de las ideas: partimos de los vectores como forma de representar información, pasamos por las matrices como máquinas de transformación, y llegamos a entender por qué y cómo una transformación puede perder información.

1. Vectores: información en forma de flecha

Un **vector** es una lista ordenada de números. Geométricamente, puede pensarse como una flecha que parte del origen y termina en las coordenadas indicadas.

$$\begin{bmatrix} 3 \\ 2 \end{bmatrix}$$

En Inteligencia Artificial, un vector puede representar **cualquier cosa** descrita con números:

- Una casa: (superficie, habitaciones, baños, antigüedad)
- Una imagen de 28×28 píxeles: vector de 784 dimensiones
- Un embedding de palabra: vector de 768, 1024 o más dimensiones

Idea clave: los vectores son el lenguaje con el que la IA "ve" el mundo.

2. Matrices: tablas que transforman

Una **matriz** es una tabla rectangular de números. Puede leerse de dos formas:

Vista 1 (almacenamiento): guarda datos organizados. Ejemplo: 1000 casas × 4 características.

Vista 2 (acción): es una **máquina que transforma vectores**. Le entrego un vector y me devuelve otro.

$$A \cdot v = w$$

Truco clave para leer una matriz: las columnas nos dicen a dónde van a parar los vectores base. La primera columna es donde termina (1,0); la segunda, donde termina (0,1); y así.

3. Transformaciones lineales

Una transformación lineal mueve los vectores respetando dos reglas:

- Las líneas rectas siguen siendo rectas (no se curvan).
- El origen no se mueve.

Puede **rotar**, **estirar**, **comprimir** o **reflejar** el espacio, pero no puede curvarlo. **Toda transformación lineal se representa con una matriz.**

En una red neuronal, cada capa aplica esencialmente una transformación lineal (más una función no lineal). Al entrenar el modelo, estamos *aprendiendo los números de esas matrices*.

4. Compatibilidad: filas vs columnas

Si A es una matriz de tamaño $m \times n$:

$$A_{(m \times n)} \cdot v_{(n \times 1)} = w_{(m \times 1)}$$

Regla mnemotécnica: las columnas de la matriz tienen que coincidir con las componentes del vector.

Cada rol es distinto:

- **Columnas (n) = dimensión de entrada:** cuántos números tiene el vector que recibo.
- **Filas (m) = dimensión de salida:** cuántos números tiene el vector que produzco.

¿Qué representa cada fila? Cada fila es una "receta" que combina los números del vector de entrada para producir **una sola componente** de la salida. En una red neuronal, **cada fila es una neurona**: sus pesos indican cuánto le importa cada característica de entrada.

Ejemplo de cálculo

Aplicamos la matriz A de 2×3 al vector v de 3 dimensiones:

A =

$$\begin{bmatrix} 2 & 1 & 0 \\ 0 & 3 & 4 \end{bmatrix}$$

v =

$$\begin{bmatrix} 5 \\ 1 \\ 2 \end{bmatrix}$$

$$\text{Fila 1: } 2 \cdot 5 + 1 \cdot 1 + 0 \cdot 2 = \mathbf{11}$$

$$\text{Fila 2: } 0 \cdot 5 + 3 \cdot 1 + 4 \cdot 2 = \mathbf{11}$$

Resultado: w =

$$\begin{bmatrix} 11 \\ 11 \end{bmatrix}$$

5. Combinaciones lineales y span

Una **combinación lineal** de vectores v_1 y v_2 es cualquier expresión de la forma:

$$a \cdot v_1 + b \cdot v_2$$

El **espacio generado (span)** es el conjunto de **todos** los vectores que se pueden construir haciendo combinaciones lineales.

- Span de 1 vector (no nulo) en 2D: una **recta**.
- Span de 2 vectores en direcciones distintas en 2D: **todo el plano**.
- Span de 3 vectores bien orientados en 3D: **todo el espacio**.

6. Dependencia e independencia lineal

Un conjunto de vectores es **linealmente independiente** si ninguno se puede escribir como combinación de los otros. Cada uno aporta una dirección nueva.

Un conjunto es **linealmente dependiente** si al menos uno es redundante: se puede construir a partir de los demás.

Ejemplo de dependencia:

$$v_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad v_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix} \quad \rightarrow v_2 = 2 \cdot v_1$$

Prueba formal: $\{v_1, \dots, v_n\}$ son dependientes si existen coeficientes $a_1, \dots, a_n$ **no todos cero** tales que $a_1 v_1 + \dots + a_n v_n = 0$.

7. Reducción de espacios: pérdida de información

Cuando una matriz tiene columnas dependientes, la transformación **colapsa dimensiones**. Ejemplo:

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$$

Las columnas (1,2) y (2,4) son dependientes. Aplicada esta matriz a cualquier vector del plano, todos terminan sobre **una única recta**: el plano 2D se aplasta a una recta 1D.

El rango de una matriz es el número de columnas linealmente independientes que tiene. Coincide con la dimensión del espacio imagen (a dónde llegan los vectores transformados).

Rangos posibles en una matriz 3×3 aplicada a $\mathbb{R}^3$:

Rango	Columnas independientes	El espacio 3D se transforma en...	Info perdida
3	3	Todo $\mathbb{R}^3$ (sin colapso)	Ninguna
2	2	Un plano	1 dimensión

1	1	Una recta	2 dimensiones
0	0	Solo el origen	Todo

¿Por qué se pierde información? Cuando el rango baja, muchos vectores de entrada distintos terminan en el mismo vector de salida. No hay forma de recuperar la entrada original: no existe matriz inversa. La transformación no se puede deshacer.

8. Espacio ambiente vs. dimensión intrínseca

Esta distinción es la que más confusión genera. Un vector puede tener muchas componentes pero estar restringido a moverse en un subespacio pequeño.

Analogía: una hoja de papel dentro de una habitación 3D. Cada esquina de la hoja se describe con 3 coordenadas (x, y, z), pero la hoja es bidimensional. Vive en 3D, pero solo tiene 2 grados de libertad.

Ejemplo con una matriz de 4x2:

A =

1	0
0	1
1	1
2	-1

Entra un vector de 2 dimensiones y sale uno de 4 componentes. Pero la salida no es "cualquier vector de $\mathbb{R}^4$ ": está restringida. Toda salida (w_1, w_2, w_3, w_4) cumple:

$$w_1 = w_2 + w_3 \quad \text{y} \quad w_4 = 2w_2 - w_3$$

De los 4 números, solo 2 son libres; los otros 2 están forzados. La **imagen** es un **plano 2D dentro del espacio 4D**. El vector tiene 4 componentes, pero solo 2 grados de libertad.

Regla general del rango

El rango de una matriz nunca puede superar el menor entre sus dimensiones:

$$\text{rango}(A) \leq \min(m, n)$$

Podés pensarlo así: **no podés crear información nueva de la nada**. Si entraron 2 dimensiones de información, saldrán a lo sumo 2, no importa cuántas filas tenga la matriz.

Cheat sheet: tres formas de matriz

Forma	Qué hace	Rango máx.	Uso típico en IA
Cuadrada ($n \times n$)	Transforma sin cambiar dimensión	n	Rotaciones, atención
Alta ($m > n$)	Sumerge en mayor dimensión	n	Embeddings, expansión
Ancha ($m < n$)	Comprime a menor dimensión	m	Encoders, PCA, clasificación

9. Por qué esto importa en IA

- **PCA:** reduce dimensiones a propósito, eligiendo direcciones que preserven la información importante.
- **Redes neuronales:** si dos neuronas aprenden lo mismo, la matriz pierde rango efectivo. Técnicas como dropout evitan esto.

- **Autoencoders:** comprimen datos por un cuello de botella, forzando reducción controlada.
- **Embeddings:** palabras representadas como vectores de 768+ dimensiones (información 1D en un contenedor de alta dimensión).
- **Datos redundantes:** features linealmente dependientes (ej: altura en m y cm) son matemáticamente inútiles.

10. Las tres preguntas para leer cualquier matriz

1. **¿Qué dimensión de entrada acepta?** → mirá las columnas.
2. **¿Qué dimensión de salida produce (espacio ambiente)?** → mirá las filas.
3. **¿Cuánta información conserva realmente?** → mirá el rango.

Próxima clase: autovalores, autovectores y descomposición SVD, las herramientas para hacer compresión, recomendaciones y modelos de lenguaje.